# MAPEAMENTO DE SUSCETIBILIDADE A INUNDAÇÃO USANDO MODELO DIGITAL DE TERRENO DE ALTA RESOLUÇÃO E RANDOM FOREST

*Felipe Hideki Makita*[1], *Tatiana Sussel Gonçalves Mendes*[2], *Rogério Galante Negri*[3] *e Felícia França Pereira*[4]

[1]ICT Unesp São José dos Campos, Rodovia Presidente Dutra km 137,8 - Eugênio de Melo, São José dos Campos-SP, felipe.makita@unesp.br, [2]ICT Unesp São José dos Campos, Rodovia Presidente Dutra km 137,8 - Eugênio de Melo, São José dos Campos-SP, tatiana.mendes@unesp.br, [3]ICT Unesp São José dos Campos, Rodovia Presidente Dutra km 137,8 - Eugênio de Melo, São José dos Campos-SP, rogerio.negri@unesp.br e [4]Programa de Pós-Graduação em Desastres Naturais (UNESP/Cemaden), Rodovia Presidente Dutra km 137,8 - Eugênio de Melo, São José dos Campos-SP, felicia.franca@unesp.br.

**RESUMO**

Ocorrências de inundação vêm aumentando nos últimos anos, associado a precipitações extremas e infraestruturas urbanas deficientes. O presente estudo tem como objetivo o mapeamento da suscetibilidade a inundação em dois distritos da cidade de São Paulo-SP, usando um Modelo Digital de Terreno (MDT) de alta resolução. O modelo de suscetibilidade foi elaborado usando o algoritmo $Random\ Forest$ tendo como dados de entrada sete fatores condicionantes. O método proposto pode ser sintetizado em pré-processamento dos dados, geração dos fatores condicionantes, treinamento do modelo, otimização por hiperparâmetros, mapeamento da suscetibilidade, validação e avaliação de desempenho utilizando métricas estatísticas e a curva ROC-AUC. A partir dos resultados experimentais, verificou-se que o modelo de predição apresentou um bom desempenho ao identificar as áreas com suscetibilidade a inundação, com métricas de $Accuracy$= 0,730; $Precision$= 0,696; $Recall$= 0,709; $F1-score$= 0,703; MAE= 0,297; RMSE= 0,545; $R-squared$= -0,189 e ROC-AUC= 0,793.

***Palavras-chave –*** Inundação, Aprendizado de máquina, LiDAR.

***ABSTRACT***

*Flood occurrences have increased in recent years, associated with extreme precipitation and poor urban infrastructure. The present study aims to map the susceptibility to flooding in two districts in the city of São Paulo-SP, using a high resolution Digital Terrain Model (DTM). The susceptibility model was elaborated using the $Random\ Forest$ algorithm with seven conditioning factors as input data. The proposed method can be summarized in data pre-processing, generation of conditioning factors, model training, optimization by hyperparameters, susceptibility mapping, validation and performance evaluation using statistical metrics and ROC-AUC index. From the experimental results, it was found that the prediction model performed well in identifying areas susceptible to flooding, with metrics of $Accuracy$= 0.730; $Precision$= 0.696; $Recall$= 0.709; $F1-score$= 0.703; MAE= 0.297; RMSE= 0.545; $R-squared$= -0.189 and ROC-AUC= 0.793.*

***Key words –*** *Flood, Machine learning, LiDAR.*

## 1. INTRODUÇÃO

Eventos de inundação são considerados como um dos desastres naturais mais destrutivos de maneira global [1], causando danos econômicos e sociais, além de afetar a mobilidade urbana, comércios e residências, associado a riscos à saúde e transtornos sociais, como perdas materiais e até mesmo vidas humanas. Têm-se como um dos principais fatores preponderantes as precipitações intensas ou extremas, que aliado a fatores antrópicos, como a urbanização, podem intensificar a ocorrência de tais eventos.

Neste sentido, grandes cidades são particularmente vulneráveis a ocorrências de inundação, uma vez que ocorre um rápido escoamento superficial de regiões impermeabilizadas como concreto e asfalto, podendo vir a sobrecarregar os sistemas de drenagem pluvial urbanos. Nos últimos anos, um aumento no número de eventos de inundação tem sido observado e cada vez mais tem-se a necessidade do desenvolvimento de estudos que abordem o perigo e o risco de ocorrências de inundação, atuando como importantes ferramentas para o gerenciamento e mitigação dos riscos [2].

Recentemente, com o auxílio de Sistemas de Informação Geográfica (SIG) e sensoriamento remoto, a acurácia de análises de suscetibilidade a inundação têm aumento substancialmente [3]. Deste modo, diversos modelos têm sido aplicados para modelar a suscetibilidade a inundação em diversas áreas de estudo e linhas de pesquisa. Dentre as metodologias utilizadas, destacam-se a modelagem ou simulação hidráulica [4] [5] e mais recentemente, métodos de $machine\ learning$ [6] [7], sendo considerados como ferramentas promissoras para a resolução de problemas não-lineares com alta acurácia. No entanto, sabe-se que a qualidade do mapeamento da suscetibilidade depende diretamente da qualidade dos dados utilizados durante a modelagem, sendo o Modelo Digital de Terreno (MDT) que representa a superfície topográfica um dos dados de maior importância. Logo, a utilização de um MDT de alta qualidade e resolução espacial possibilitará gerar um modelo mais confiável e fidedigno do cenário abordado [8].

Neste sentido, o presente estudo tem como objetivo a utilização de um MDT de alta resolução derivado de dados LiDAR ($Light\ Detection\ And\ Ranging$) para o mapeamento da suscetibilidade de inundação. O modelo de suscetibilidade foi elaborado usando o algoritmo $Random\ Forest$ para dois distritos da cidade de São Paulo - SP (Vila Prudente e Ipiranga). Especificamente, o estudo

visa identificar os principais fatores condicionantes para a ocorrência de inundação e avaliar o desempenho e acurácia do modelo proposto por meio da análise da AUC ($Area\ Under\ Curve$) e de métricas estatísticas.

## 2. MATERIAL E MÉTODOS

A metodologia adotada para o mapeamento de áreas suscetíveis a inundação é ilustrada de acordo com a Figura 1. As etapas metodológicas que compreendem o estudo podem ser elencadas em: pré-processamento dos dados, geração dos fatores condicionantes, treinamento, otimização do modelo, validação e avaliação dos resultados. Para a geração dos fatores condicionantes utilizou-se o software $ArcGIS\ PRO$ enquanto que para o processo de modelagem e manipulação dos dados de entrada, assim como a etapa de validação e avaliação dos resultados foi realizada através da linguagem de programação $Python$.

Os dados utilizados no estudo foram obtidos através da plataforma GEOSAMPA, lançada em 2015 e desenvolvida em parceria com a Secretaria Municipal de Desenvolvimento Urbano (SMDU) e Prodam. Os dados adquiridos tratam-se de pontos de ocorrência de inundação, arquivos vetoriais e dados de LiDAR que representam a superfície topográfica (MDT) da área de estudo, a partir dos quais foram derivados os fatores a serem considerados no modelo.

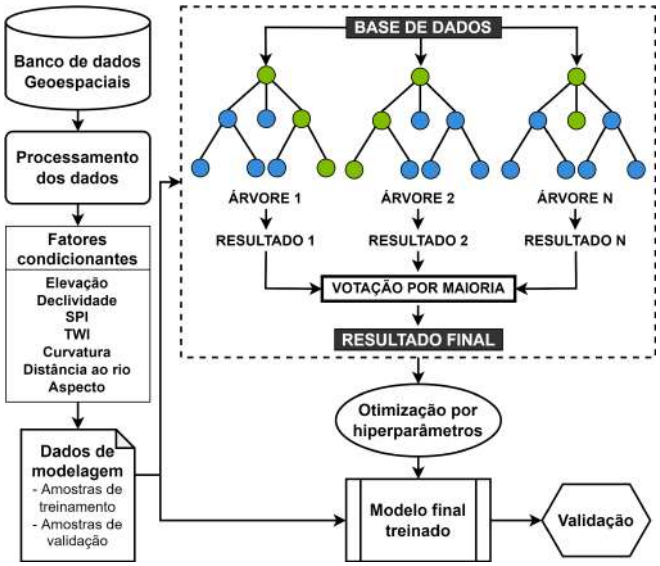



**Figura 1: Metodologia adotada.**

### 2.1. Pré-processamento

O pré-processamento dos dados é um processo de grande importância para o modelo proposto, uma vez que a qualidade dos dados que serão inseridos no modelo irão determinar a sua confiabilidade. Neste sentido, para fins análise de suscetibilidade a inundação faz-se necessário o levantamento de eventos de inundação que ocorreram recentemente [9].

Para a preparação do inventário de eventos de inundação, foram obtidas ocorrências dos eventos (2013 a 2021) com a Prefeitura Municipal de São Paulo, compreendendo de 184 pontos georreferenciados. Tratando-se das amostras de não-ocorrência, foram geradas de maneira randômica a mesma quantidade pontos amostrais distribuídos ao longo da área de estudo. O total de amostras de ocorrência e não ocorrência foi utilizado na etapa de treinamento e validação do modelo proposto, distribuídos em 70% e 30% respectivamente.

### 2.2. Geração dos fatores condicionantes

Para a geração dos fatores condicionantes a serem utilizados no modelo proposto, inicialmente foi realizada uma revisão bibliográfica, objetivando identificar os principais fatores condicionantes considerados pela literatura relacionada a estudos de suscetibilidade de inundação. Deste modo, sete fatores condicionantes derivados do MDT foram considerados no presente estudo: Elevação, Declividade, $Stream\ Power\ Index$ (SPI), $Topographic\ Wetness\ Index$ (TWI), Curvatura combinada, Distância do rio e Aspecto.

### 2.3. Otimização por hiperparâmetros

O processo de otimização por hiperparâmetros é uma abordagem amplamente utilizada em algoritmos de $machine\ learning$, tendo um grande impacto na acurácia final. Logo, a otimização é feita com o intuito de selecionar os valores discretos de parâmetros ideais de acordo com as suas respectivas performances [10]. Diante disso, a otimização do algoritmo foi feita para três dos seus parâmetros ($n_estimators$, $max_depths$ e $max_features$) utilizando o método de $Grid\ Search$.

O $Grid\ Search$ é um dos métodos mais simples de otimização, baseado na variação dos valores discretos adotados para cada um dos parâmetros considerados e nos resultados obtidos para cada iteração de cada uma das combinações possíveis. Os valores a serem considerados pelo $Grid\ Search$ são pré-definidos pelo usuário como uma matriz de valores para cada um dos parâmetros [11].

### 2.4. Validação e avaliação dos resultados

A performance do modelo final é avaliada utilizando métricas estatísticas como $Root\ Mean\ Square\ Error$ (RMSE), $Mean\ Absolute\ Error$ (MAE), $R - squared$ (R2), $Accuracy$, $Precision$, $Recall$ e $F1 - score$. Onde a $Accuracy$ representa a porcentagem das amostras de validação que foram corretamente classificadas pelo modelo. Por sua vez, as métricas $Precision$, $Recall$ e $F1 - score$ correspondem a capacidade de identificar as regiões com suscetibilidade de ocorrência de inundação.

Além disso, o desempenho do modelo final é avaliado com a AUC, sendo um método comumente utilizado para avaliação de mapas de suscetibilidade a inundação [7]. O valor resultante do índice é determinado pela área abaixo da curva $Relative\ Operating\ Characteristic$ (ROC) definida pelo $True\ Positive\ Rate$ em função do $True\ Negative\ Rate$.

## 3. RESULTADOS

Os fatores condicionantes considerados pelo modelo proposto são ilustrados na Figura 2, sendo a Elevação (A); Declividade

(B); SPI (C); TWI (D); Curvatura (E); Distância do rio (F) e Aspecto (G).

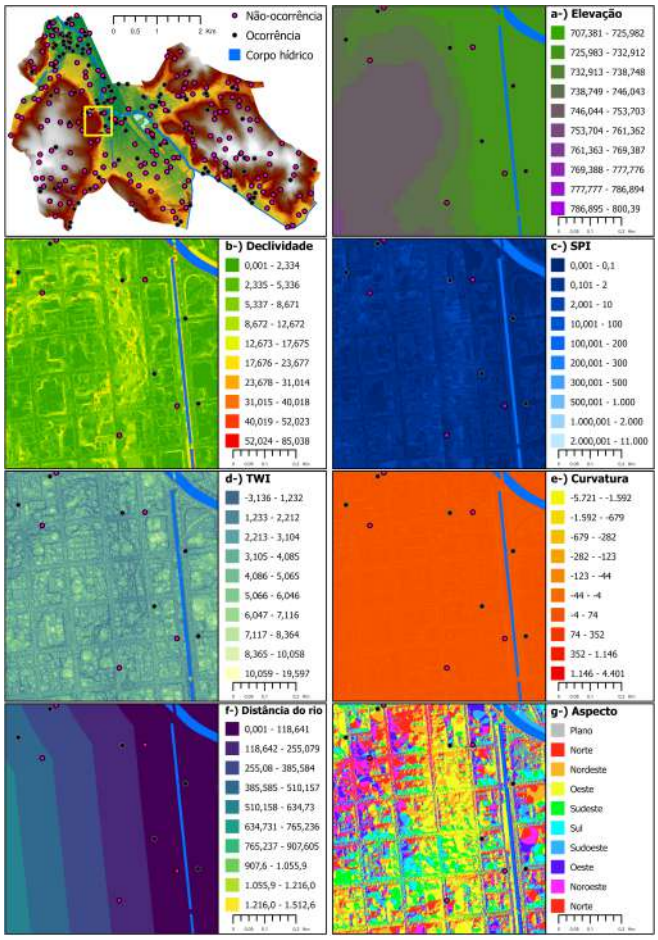



**Figura 2: Fatores condicionantes usados no modelo de predição de suscetibilidade a inundação. (A) Elevação; (B) Declividade; (C) SPI; (D) TWI; (E) Curvatura; (F) Distância do rio; e (G) Aspecto.**

### 3.1. Análise de correlação entre os fatores condicionantes

A análise de correlação entre os fatores condicionantes foi feita através da correlação de Pearson, gerando-se uma matriz de correlação de acordo com a Figura 3. Com valores de -1 a 1, onde valores mais elevados indicam uma alta correlação, podendo apresentar uma correlação negativa ou positiva.

### 3.2. Importância dos fatores condicionantes

O processo de $feature\ ranking$ ou importância dos parâmetros é executado pelo próprio algoritmo, descrevendo a importância de cada um em função do índice de $Gini$, tal processo baseia-se no código desenvolvido por Breiman [12]. A importância de cada um dos fatores condicionantes é elencada na Tabela 1.

### 3.3. Geração do mapa de suscetibilidade

Após a otimização por hiperparâmetros, determinou-se os parâmetros ideais para o algoritmo RF, sendo $max_depth$= 6, $max_features$= 0,4 e $n_estimators$= 200. O treinamento

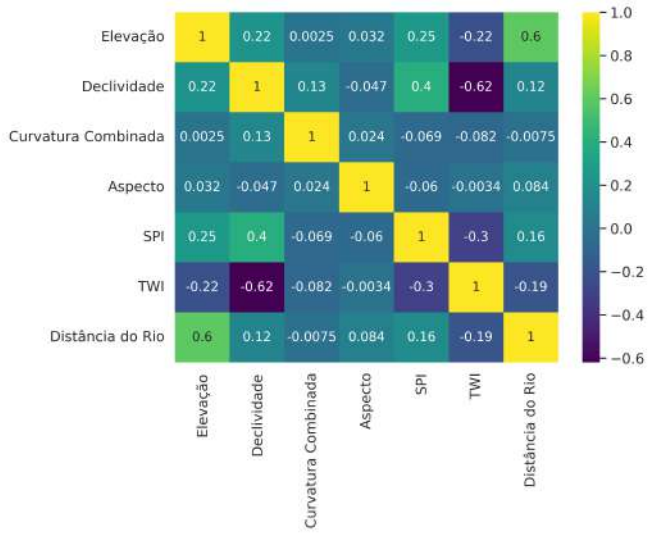



**Figura 3: Matriz de correlação.**

| Fatores condicionantes | Importância |
|---|---|
| Elevação | 0,25345 |
| Declividade | 0,14862 |
| Curvatura | 0,09030 |
| Aspecto | 0,09133 |
| SPI | 0,15451 |
| TWI | 0,12745 |
| Distância do rio | 0,13433 |

**Tabela 1: Importância dos fatores condicionantes.**

do algoritmo foi executado com 70% das amostras, resultando em 129 pontos de ocorrência e não-ocorrência. O resultado obtido apresentou índices de suscetibilidade variando de 0.0316 a 0.977. Após a geração do mapa de suscetibilidade resultante, este foi reclassificado em cinco classes de suscetibilidade com o método de $Natural\ Breaks$, sendo as classes de muito baixa, baixa, moderada, alta e muito alta.

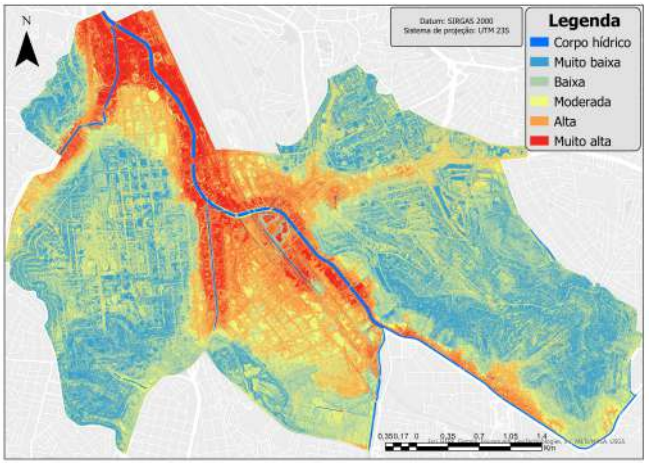



**Figura 4: Mapa de suscetibilidade a inundação.**

### 3.4. Validação do modelo

A análise da performance do modelo foi realizada utilizando as métricas estatísticas apresentadas na Tabela 2. Deste modo, ao analisar os resultados obtidos, nota-se que o

modelo apresentou um bom desempenho para a predição de ocorrência de inundação, com erros medianos se comparado com a literatura relacionada.

| Parâmetros | Valor |
|---|---|
| $Accuracy$ (treino) | 0,949 |
| $Accuracy$ (validação) | 0,730 |
| $Precision$ | 0,696 |
| $Recall$ | 0,709 |
| $F1-score$ | 0,703 |
| MAE | 0,297 |
| RMSE | 0,545 |
| $R-squared$ | -0,189 |
| AUC | 0,793 |

**Tabela 2: Métricas e valores obtidos para a validação e avaliação da performance do modelo de predição.**

## 4. DISCUSSÃO

Na análise da correlação de Pearson, valores acima de 0,7 são indicativo de uma alta colinearidade entre os fatores analisados [13]. Assim, a partir dos resultados obtidos, não foi observado um alto índice de correlação entre os fatores condicionantes analisados. A análise da importância de cada fator condicionante pode evitar a utilização de fatores redundantes e menos relacionados com as áreas suscetíveis a inundação. Na Tabela 1 é possível observar que Elevação, Declividade, SPI, TWI e Distância do rio foram os fatores condicionantes que apresentaram maior impacto na identificação de áreas suscetíveis a inundação. Além disso, não observou-se um parâmetro com uma importância baixa para que pudesse ser desconsiderado pelo modelo. O desempenho do modelo proposto foi considerado bom ao analisar as métricas estatísticas adotadas. Com relação a AUC, sabe-se que: valores de AUC abaixo de 0,6: baixa acurácia; valores entre 0,6 - 0,7: modelo acurado; valores entre 0,7 - 0,8: boa acurácia; e valores acima de 0,8: uma ótima acurácia [14]. Logo, o modelo final possui uma boa acurácia e mostrou-se com potencial para produzir bons resultados.

## 5. CONCLUSÕES

O modelo apresentou bom desempenho na predição da suscetibilidade a inundação, sendo uma ferramenta de grande valor para ser usada em estratégias de redução de risco de desastres. As medidas não-estruturais para análise de cenários de inundação em ambientes urbanos, como o mapa de suscetibilidade desenvolvido no presente estudo, têm potencial para a identificação de áreas mais críticas e de mitigação de impactos econômicos e sociais causados pelos eventos de inundação, auxiliando assim os tomadores de decisão em sua gestão territorial, de modo a reduzir custos operacionais e prover uma melhor infraestrutura urbana.

## 6. REFERÊNCIAS

[1] Wei Chen, Yang Li, Weifeng Xue, Himan Shahabi, Shaojun Li, Haoyuan Hong, Xiaojing Wang, Huiyuan Bian, Shuai Zhang, Biswajeet Pradhan, and Baharin Bin Ahmad. Modeling flood susceptibility using data-driven approaches of naïve bayes tree, alternating decision tree, and random forest methods. *Science of The Total Environment*, 701:134979, jan 2020.

[2] Elham Rafiei-Sardooi, Ali Azareh, Bahram Choubin, Amir H. Mosavi, and John J. Clague. Evaluating urban flood risk using hybrid method of TOPSIS and machine learning. *International Journal of Disaster Risk Reduction*, 66:102614, dec 2021.

[3] Huali Chen, Yuka Ito, Marie Sawamukai, and Tomochika Tokunaga. Flood hazard assessment in the kujukuri plain of chiba prefecture, japan, based on GIS and multicriteria decision analysis. *Natural Hazards*, 78(1):105–120, March 2015.

[4] Seong Jin Noh, Jun-Hak Lee, Seungsoo Lee, Kenji Kawaike, and Dong-Jun Seo. Hyper-resolution 1d-2d urban flood modelling using LiDAR data and hybrid parallelization. *Environmental Modelling amp; Software*, 103:131–145, may 2018.

[5] Luigi Guerriero, Giuseppe Ruzza, Francesco M. Guadagno, and Paola Revellino. Flood hazard mapping incorporating multiple probability models. *Journal of Hydrology*, 587:125020, aug 2020.

[6] Hamid Darabi, Bahram Choubin, Omid Rahmati, Ali Torabi Haghighi, Biswajeet Pradhan, and Bjørn Kløve. Urban flood risk mapping using the GARP and QUEST models: A comparative study of machine learning techniques. *Journal of Hydrology*, 569:142–154, feb 2019.

[7] Gang Zhao, Bo Pang, Zongxue Xu, Dingzhi Peng, and Depeng Zuo. Urban flood susceptibility assessment based on convolutional neural networks. *Journal of Hydrology*, 590:125235, nov 2020.

[8] Nur Atirah Muhadi, Ahmad Fikri Abdullah, Siti Khairunniza Bejo, Muhammad Razif Mahadi, and Ana Mijic. The use of LiDAR-derived DEM in flood applications: A review. *Remote Sensing*, 12(14):2308, jul 2020.

[9] Dieu Tien Bui, Phuong-Thao Thi Ngo, Tien Dat Pham, Abolfazl Jaafari, Nguyen Quang Minh, Pham Viet Hoa, and Pijush Samui. A novel hybrid approach based on a swarm intelligence optimized extreme learning machine for flash flood susceptibility mapping. *CATENA*, 179:184–196, aug 2019.

[10] Deliang Sun, Haijia Wen, Danzhou Wang, and Jiahui Xu. A random forest model of landslide susceptibility mapping based on hyperparameter optimization using bayes algorithm. *Geomorphology*, 362:107201, aug 2020.

[11] Philipp Probst, Marvin N. Wright, and Anne-Laure Boulesteix. Hyperparameters and tuning strategies for random forest. *WIREs Data Mining Knowl Discov*, 9(3), jan 2019.

[12] Zhaoli Wang, Chengguang Lai, Xiaohong Chen, Bing Yang, Shiwei Zhao, and Xiaoyan Bai. Flood hazard risk assessment model based on random forest. *Journal of Hydrology*, 527:1130–1141, aug 2015.

[13] Mahyat Shafapour Tehrany, Simon Jones, and Farzin Shabani. Identifying the essential flood conditioning factors for flood prone area mapping using machine learning techniques. *CATENA*, 175:174–192, apr 2019.

[14] Vincenzo Allocca, Mariano Di Napoli, Silvio Coda, Francesco Carotenuto, Domenico Calcaterra, Diego Di Martire, and Pantaleone De Vita. A novel methodology for groundwater flooding susceptibility assessment through machine learning techniques in a mixed-land use aquifer. *Science of The Total Environment*, 790:148067, oct 2021.