UNIVERSIDADE FEDERAL DE SANTA CATARINA
CENTRO TECNOLÓGICO
DEPARTAMENTO DE ENGENHARIA SANITÁRIA E AMBIENTAL
CURSO DE GRADUAÇÃO EM ENGENHARIA SANITÁRIA E AMBIENTAL

Luiz Felipe da Silva

Aplicação de Algoritmos de Aprendizado de Máquina para o Mapeamento de Suscetibilidade a Inundações da Bacia Hidrográfica do Rio Itajaí

Florianópolis
2025

Luiz Felipe da Silva

Aplicação de Algoritmos de Aprendizado de Máquina para o Mapeamento de Suscetibilidade a Inundações da Bacia Hidrográfica do Rio Itajaí

Trabalho de Conclusão de Curso submetido ao curso de Engenharia Sanitária e Ambiental do Centro Tecnológico da Universidade Federal de Santa Catarina como requisito parcial para a obtenção do título de Bacharel em Engenharia Sanitária e Ambiental.

Orientador: Prof. Pedro Luiz Borges Chaffe, Dr.

Florianópolis

2025

Silva, Luiz Felipe da
Aplicação de Algoritmos de Aprendizado de Máquina para o Mapeamento de Suscetibilidade a Inundações da Bacia Hidrográfica do Rio Itajaí / Luiz Felipe da Silva ; orientador, Pedro Luiz Borges Chaffe, 2025.
80 p.

Trabalho de Conclusão de Curso (graduação) - Universidade Federal de Santa Catarina, Centro Tecnológico, Graduação em Engenharia Sanitária e Ambiental, Florianópolis, 2025.

Inclui referências.

1. Engenharia Sanitária e Ambiental. 2. Suscetibilidade a inundações. 3. Aprendizado de máquina. 4. Sensoriamento remoto. I. Borges Chaffe, Pedro Luiz . II. Universidade Federal de Santa Catarina. Graduação em Engenharia Sanitária e Ambiental. III. Título.

Luiz Felipe da Silva

Aplicação de Algoritmos de Aprendizado de Máquina para o Mapeamento de Suscetibilidade a Inundações da Bacia Hidrográfica do Rio Itajaí

Este Trabalho de Conclusão de Curso foi julgado adequado para obtenção do título de Bacharel e aprovado em sua forma final pelo Curso de Engenharia Sanitária e Ambiental.

Florianópolis, 07 de julho de 2025.

Prof. Dr. Bruno Segalla Pizzolatti
Coordenação do Curso

Banca examinadora

Prof. Pedro Luiz Borges Chaffe, Dr.
Orientador

Prof. Leonardo Hoinaski, Dr.
Universidade Federal de Santa Catarina

Vinicius Bogo Portal Chagas, Dr.
Universidade Federal de Santa Catarina

Florianópolis, 2025.

Dedico este trabalho aos meus pais, com todo o meu amor e gratidão por todo o apoio ao longo dessa jornada.

AGRADECIMENTOS

Em primeiro lugar, agradeço aos meus pais, Marcia e Oldair, pelo apoio incondicional ao longo desses anos. Por cada palavra de incentivo, por todo o suporte e por fazerem o possível, e muitas vezes o impossível, para que eu pudesse alcançar meus sonhos. Nada disso seria possível sem vocês ao meu lado.

Agradeço também aos demais familiares pelo carinho e apoio durante minha trajetória, e a todos que cruzaram meu caminho e, de alguma forma, contribuíram para a minha formação.

Um agradecimento especial aos amigos de longa data e àqueles que tive o prazer de conhecer ao longo desses anos na UFSC. À minha amiga Layla, que me acompanha desde o ensino médio e continua ao meu lado até hoje, sempre me apoiando e incentivando. À Camila, que esteve comigo desde o início, compartilhando os altos e baixos da graduação, das noites em claro com projetos e provas ao alívio e à alegria pelas conquistas alcançadas. E à Ana Júlia, a primeira pessoa com quem conversei na universidade e que segue comigo até hoje, pela parceria, pelo apoio e pelas palavras de incentivo ao longo desse período.

Agradeço também às minhas amigas Cássia e Laura. Que presente foi conhecer vocês durante o BRAFITEC e poder compartilhar juntos os últimos três semestres da graduação. Sem dúvida, esse período não teria sido o mesmo sem a amizade e o apoio de vocês.

Agradeço a todos os professores que compartilharam seus conhecimentos ao longo da minha formação e a todos os profissionais que, de alguma forma, contribuíram para o meu desenvolvimento durante os estágios realizados ao longo do curso. Cada um teve um papel importante na construção do profissional que me tornei. Em especial, sou grato ao professor Pedro pelos ensinamentos, pela orientação e por todos os conselhos que foram fundamentais ao longo deste trabalho.

Por fim, sou imensamente grato por ter estudado em uma universidade pública e de excelência. Foram anos intensos, de muito aprendizado e vivências que levarei comigo por toda a vida.

Muito obrigado!

RESUMO

As inundações fluviais representam um dos desastres naturais mais recorrentes em nível mundial e estão entre os eventos de maior custo econômico global. O mapeamento de suscetibilidade é fundamental para o planejamento territorial, mas demanda grande volume de dados e elevado custo computacional. Nesse contexto, algoritmos de aprendizado de máquina têm se consolidado como alternativas mais acessíveis, em contraste com os modelos hidrodinâmicos tradicionais. Este trabalho teve como objetivo estimar a suscetibilidade a inundações na Bacia Hidrográfica do Rio Itajaí por meio da aplicação de cinco modelos supervisionados: AdaBoost, XGBoost, K-Nearest Neighbors (KNN), Support Vector Machine (SVM) e Random Forest (RF). Os modelos foram treinados com base em um inventário de áreas inundadas, construído a partir de registros da Defesa Civil e o Índice de Diferença Normalizada da Água (NDWI), além de oito variáveis ambientais preditoras selecionadas como fatores condicionantes da ocorrência de inundações. Para avaliar a adequação das variáveis selecionadas, foi analisada sua capacidade discriminativa e realizada uma análise de multicolinearidade, com base no Fator de Inflação da Variância (VIF) e Tolerância (TOL), a fim de reduzir redundâncias. A performance dos modelos foi avaliada por meio da média de cinco métricas de desempenho: acurácia, precisão, *recall*, *F1-score* e Área sob a Curva (AUC). A importância relativa dos fatores condicionantes foi determinada com o método SHAP (SHapley Additive exPlanations). A coerência espacial da mancha gerada ocorreu através da sobreposição com a mancha de inundação do Banco Mundial, referente a um tempo de retorno de 50 anos. Os fatores condicionantes apresentaram bom potencial discriminativo. O modelo RF apresentou os melhores resultados (AUC = 0,99; acurácia = 0,94; precisão = 0,92; recall = 0,98; F1-score = 0,94), seguido por XGBoost e AdaBoost. A análise SHAP para o RF apontou o HAND e a altitude como os fatores condicionantes mais relevantes. O mapa de suscetibilidade gerado com o modelo RF classificou 86,56% da área como muito baixa, 3,62% como baixa, 2,80% como média, 2,38% como alta e 4,65% como muito alta suscetibilidade. As divergências observadas ao comparar as manchas podem ser atribuídas à capacidade do modelo de generalizar padrões em áreas sem registros históricos e às possíveis limitações da mancha de referência. Os resultados evidenciam o potencial do aprendizado de máquina como ferramenta de apoio ao planejamento territorial e à formulação de políticas públicas voltadas à prevenção de inundações.

Palavras-chave: Suscetibilidade a inundações; Aprendizado de máquina; Sensoriamento remoto.

ABSTRACT

Fluvial floods represent one of the most recurrent natural disasters worldwide and are among the events with the highest economic costs globally. Susceptibility mapping is essential for territorial planning but requires large volumes of data and high computational cost. In this context, machine learning algorithms have emerged as more accessible alternatives compared to traditional hydrodynamic models. This study aimed to estimate flood susceptibility in the Itajaí River Basin by applying five supervised models: AdaBoost, XGBoost, K-Nearest Neighbors (KNN), Support Vector Machine (SVM), and Random Forest (RF). The models were trained based on a flood inventory constructed from records provided by the Civil Defense and the Normalized Difference Water Index (NDWI), along with eight environmental predictor variables selected as flood-conditioning factors. To evaluate the adequacy of the selected variables, their discriminative capacity was analyzed, and multicollinearity was assessed using the Variance Inflation Factor (VIF) and Tolerance (TOL) in order to reduce redundancies. Model performance was evaluated based on the average of five metrics: accuracy, precision, recall, F1-score, and Area Under the Curve (AUC). The relative importance of the conditioning factors was determined using the SHAP (SHapley Additive exPlanations) method. The spatial coherence of the generated flood map was assessed through overlay with the World Bank's 50-year return period flood extent. The conditioning factors showed good discriminative potential. The RF model achieved the best results (AUC = 0.99; accuracy = 0.94; precision = 0.92; recall = 0.98; F1-score = 0.94), followed by XGBoost and AdaBoost. The SHAP analysis for the RF model identified HAND and altitude as the most influential conditioning factors. The susceptibility map generated by the RF model classified 86.56% of the area as very low, 3.62% as low, 2.80% as moderate, 2.38% as high, and 4.65% as very high susceptibility. The observed discrepancies between the generated and reference maps may be attributed to the model's ability to generalize patterns in areas without historical records and to possible limitations of the reference flood extent. The results highlight the potential of machine learning as a decision-support tool for territorial planning and the development of public policies aimed at flood prevention.

Keywords: Flood susceptibility; Machine learning; Remote sensing.

LISTA DE FIGURAS

Figura 1: Representação esquemática do algoritmo AdaBoost. 25
Figura 2: Representação esquemática do algoritmo KNN. 26
Figura 3: Representação esquemática do algoritmo SVM. 27
Figura 4: Representação esquemática do algoritmo Random Forest. 28
Figura 5: Localização da Bacia Hidrográfica do Rio Itajaí. 32
Figura 6: Fluxograma metodológico do mapeamento de suscetibilidade a inundações da Bacia do Rio Itajaí. 34
Figura 7: Registros de inundações utilizados na construção do inventário. 36
Figura 8: Detecção de áreas alagadas na Bacia do Rio Itajaí a partir do índice NDWI. 37
Figura 9: Inventário de eventos de inundações (dados históricos e NDWI). 39
Figura 10: Fatores condicionantes de inundação selecionados. a) Altitude; b) Aspecto; c) CN; d) Declividade; e) Dist. da Rede de Drenagem; f) HAND; g) Média Anual da Prec. Máx. Acum. (7 dias); h) TWI. 41
Figura 11: Procedimento de cálculo do HAND. 44
Figura 12: Mancha TR 50 anos – Banco Mundial. 50
Figura 13: Estações fluviométricas selecionadas. 51
Figura 14: Estatísticas *box-plot* dos fatores condicionantes para ocorrência de inundação e não inundação. a) Altitude; b) Aspecto; c) CN; d) Declividade; e) Dist. da Rede de Drenagem; f) HAND; g) Média Anual da Prec. Máx. Acum. (7 dias); h) TWI. 54
Figura 15: Matriz de Correlação. 56
Figura 16: Mapa de suscetibilidade a inundações gerado pelo modelo RF. 59
Figura 17. Mapa de suscetibilidade e manchas de inundação do inventário. 60
Figura 18: SHAP para o modelo Random Forest. 62
Figura 19: Análise comparativa entre o mapeamento gerado pelo RF e pelo Banco Mundial. 66
Figura 20: Mapa de suscetibilidade a inundações gerado pelo modelo AdaBoost. 75
Figura 21: Mapa de suscetibilidade a inundações gerado pelo modelo XGBoost. 75
Figura 22: Mapa de suscetibilidade a inundações gerado pelo modelo KNN. 76
Figura 23: Mapa de suscetibilidade a inundações gerado pelo modelo SVM. 76
Figura 24: SHAP para o modelo AdaBoost. 77

Figura 25: SHAP para o modelo XGBoost. 77
Figura 26: SHAP para o modelo KNN. 78
Figura 27: SHAP para o modelo SVM. 78
Figura 28: Ajuste da amostra para a distribuição de Gumbel – Rio do Sul. 79
Figura 29: Ajuste da amostra para a distribuição de Gumbel – Gaspar. 79
Figura 30: Ajuste da amostra para a distribuição de Gumbel – Brusque. 80
Figura 31: Ajuste da amostra para a distribuição de Gumbel – Blumenau. 80

LISTA DE QUADROS

Quadro 1: Fatores condicionantes aplicados em diferentes estudos. 29

LISTA DE TABELAS

Tabela 1: Registros de inundações utilizados na construção do inventário. 35
Tabela 2: Variáveis condicionantes à inundação, com respectivas fontes de dados e resoluções espaciais. 40
Tabela 3: Avaliação da multicolinearidade entre os fatores condicionantes. 55
Tabela 4. Desempenho dos algoritmos de aprendizado de máquina no conjunto de teste. 57
Tabela 5: Distribuição percentual das classes de suscetibilidade a inundações por modelo. 59
Tabela 6: Níveis estimados de cheia (em metros) por tempo de retorno para as estações selecionadas. 63
Tabela 7: Estimativa dos TRs dos eventos utilizados no inventário. 63

LISTA DE ABREVIATURAS E SIGLAS

ADAboost	*Adaptive Boosting*
ANA	Agência Nacional de Águas e Saneamento Básico
AUC	*Área sob a Curva*
CHIRPS	*Climate Hazards Group InfraRed Precipitation with Station Data*
CN	*Curve Number*
FPR	Taxa de Falsos Positivos
GEE	*Google Earth Engine*
HAND	*Height Above Nearest Drainage*
IBGE	Instituto Brasileiro de Geografia e Estatística
KNN	*K-Nearest Neighbors*
MDE	Modelo Digital de Elevação
NDWI	Índice de Diferença Normalizada da Água
RF	*Random Forest*
ROC	*Receiver Operating Characteristic*
SHAP	*SHapley Additive exPlanations*
SIG	Sistema de Informação Geográfica
SRTM	*Shuttle Radar Topography Mission*
SVM	*Support Vector Machine*
TOL	Índice de Tolerância
TPR	Taxa de Verdadeiros Positivos
TR	Tempo de Retorno
TWI	Índice de Umidade Topográfica
VIF	Fator de Inflação da Variância
XGBoost	*Extreme Gradient Boosting*

SUMÁRIO

1 INTRODUÇÃO 17
1.1 OBJETIVOS 18
1.1.1 Objetivo Geral 18
1.1.2 Objetivos Específicos 18
2 REVISÃO BIBLIOGRÁFICA 19
2.1 INUNDAÇÕES NA BACIA HIDROGRÁFICA DO RIO ITAJAÍ 19
2.2 MAPEAMENTO DE SUSCETIBILIDADE A INUNDAÇÕES COMO MEDIDA DE CONTROLE NÃO-ESTRUTURAL 20
2.3 MODELOS DE APRENDIZADO DE MÁQUINA 22
2.3.1 Adaptive Boosting (AdaBoost) 24
2.3.2 Extreme Gradient Boosting (XGBoost) 25
2.3.3 K-Nearest Neighbors (KNN) 25
2.3.4 Support Vector Machine (SVM) 26
2.3.5 Random Forest 27
2.4 FATORES CONDICIONANTES DE INUNDAÇÕES 28
3 METODOLOGIA 31
3.1 ÁREA DE ESTUDO 31
3.2 MAPEAMENTO DE SUSCETIBILIDADE A INUNDAÇÕES 32
3.2.1 Inventário de Inundações 35
3.2.2 Fatores Condicionantes de Inundações 39
3.2.2.1 Fatores Topográficos – Altitude, Declividade, Aspecto, HAND e TWI 42
3.2.2.2 Cobertura e Uso do Solo – Curve Number (CN) 45
3.2.2.3 Rede de Drenagem – Distância da Rede de Drenagem 45
3.2.2.4 Precipitação – Média Anual da Precipitação Máxima Acumulada em 7 Dias 45
3.2.3 Análise dos Fatores Condicionantes de Inundações 46
3.2.3.1 Capacidade de Discriminação dos Fatores Condicionantes 46
3.2.3.2 Análise de Multicolinearidade 46
3.2.4 Métricas de Avaliação de Desempenho dos Modelos de Aprendizado de Máquina 47
3.2.5 Análise de Contribuição dos Fatores Condicionantes - SHAP 48

3.3 CORRESPONDÊNCIA COM A MANCHA DE INUNDAÇÃO DO BANCO MUNDIAL 49
3.3.1 Modelo de Referência - Banco Mundial 49
3.3.2 Análise de Extremos 50
3.3.3 Análise Comparativa entre o Mapeamento por Aprendizado de Máquina e Modelo de Referência 52
4 RESULTADOS E DISCUSSÃO 53
4.1 ANÁLISE DOS FATORES CONDICIONANTES DE INUNDAÇÕES 53
4.1.1 Capacidade de Discriminação dos Fatores Condicionantes 53
4.1.2 Análise de Multicolinearidade 55
4.2 AVALIAÇÃO DE DESEMPENHO DOS MODELOS DE APRENDIZADO DE MÁQUINA 56
4.3 MAPEAMENTO DE SUSCETIBILIDADE A INUNDAÇÕES 57
4.3.1 Limitações e Recomendações 60
4.4 ANÁLISE DE CONTRIBUIÇÃO DOS FATORES CONDICIONANTES – SHAP 62
4.5 CORRESPONDÊNCIA COM A MANCHA DE INUNDAÇÃO DO BANCO MUNDIAL 63
4.5.1 Análise de Extremos 63
4.5.2 Análise Comparativa entre o Mapeamento por Aprendizado de Máquina e Modelo de Referência 64
5 CONCLUSÃO 67
REFERÊNCIAS 69
APÊNDICE A – MAPAS DE SUSCETIBILIDADE GERADOS PELOS MODELOS AVALIADOS NO ESTUDO 75
APÊNDICE B – ANÁLISE DE CONTRIBUIÇÃO DOS FATORES CONDICIONANTES - SHAP 77
APÊNDICE C – GRÁFICOS DA ANÁLISE DE FREQUÊNCIA COM AJUSTE DA DISTRIBUIÇÃO DE GUMBEL. 79

1 INTRODUÇÃO

As inundações fluviais representam um dos desastres naturais mais recorrentes em nível mundial e figuram como uma das ameaças naturais de maior custo econômico em escala global (UNISDR, 2017). Esses eventos caracterizam-se pelo extravasamento de corpos d'água, desencadeado por fatores naturais ou antrópicos, que resulta no alagamento de áreas habitualmente secas (Tucci, 2007). Estima-se que sua ocorrência aumente nas próximas décadas, em função do crescimento econômico, da expansão urbana desordenada e dos impactos das mudanças climáticas (Winsemius et al, 2015).

De acordo com o Atlas Digital de Desastres no Brasil (CEPED/UFSC, 2025), entre 1991 e 2023, o Brasil registrou 6.183 eventos de inundação, resultando em 644 óbitos e afetando 3.880.419 pessoas, entre desalojados e desabrigados. Em Santa Catarina, foram contabilizados 538 desses eventos, correspondendo a aproximadamente 40% do total registrado na região Sul. As inundações no estado causaram 44 mortes e impactaram 428.970 pessoas, com danos materiais estimados em 1,51 bilhões de reais nesse período (CEPED/UFSC, 2025). Inserida nesse contexto, a Bacia Hidrográfica do Rio Itajaí se destaca como uma das áreas mais afetadas, concentrando parcela significativa dos danos registrados.

Diante da gravidade e recorrência desses eventos, diversos estudos têm buscado identificar e mapear áreas suscetíveis na bacia, por meio de diferentes abordagens. Trabalhos recentes têm aplicado modelos hidrodinâmicos (Fleischmann, Paiva e Collischonn, 2019) e técnicas empíricas como o modelo HAND (Speckhann, 2018; Corrêa, 2022). Destaca-se também a existência de mapas de inundação elaborados pelo Banco Mundial, com base em modelagens hidrológicas e hidráulicas para diferentes tempos de retorno.

Nesse sentido, o mapeamento de suscetibilidade a inundações torna-se uma ferramenta importante para o planejamento territorial, gestão de riscos e elaboração de políticas públicas que visem à redução de danos associados a esses eventos (Goerl; Kobiyama; Pellerin, 2012). Tradicionalmente, modelos hidrodinâmicos 1D e 2D consolidados, como o HEC-RAS (U.S. Army Corps of Engineers, 2016), são amplamente utilizados para o mapeamento de inundações (Alves et al., 2022). No entanto, esses modelos apresentam alto custo computacional e demandam grandes volumes de dados, limitando a sua aplicação a áreas pequenas e dificultando a

escalabilidade para grandes regiões (Mehmood; Conway; Perera, 2021; Alves et al., 2022).

Em contraste com os modelos hidrodinâmicos tradicionais, as abordagens empíricas, como modelos de aprendizagem de máquina, têm se consolidado como alternativas mais acessíveis para o mapeamento de áreas suscetíveis a inundações, uma vez que requerem informações que podem ser facilmente obtidas através de sensoriamento remoto (Kuchinski; Paiva, 2022). Essas abordagens baseiam-se em fatores condicionantes topográficos, hidrológicos e geológicos, que são utilizados como variáveis de entrada no processo de treinamento e validação dos modelos.

Diante da expressiva recorrência de inundações na Bacia Hidrográfica do Rio Itajaí e do crescente uso de modelos de aprendizado de máquina em estudos de suscetibilidade, este trabalho tem como objetivo estimar áreas propensas à inundação na região por meio da aplicação de diferentes algoritmos de aprendizado de máquina, avaliando os seus desempenhos na identificação de áreas suscetíveis à ocorrência desses eventos.

1.1 OBJETIVOS

1.1.1 Objetivo Geral

Estimar a suscetibilidade a inundações da bacia hidrográfica do Rio Itajaí por meio da aplicação de algoritmos de aprendizado de máquina.

1.1.2 Objetivos Específicos

- Avaliar a multicolinearidade entre os fatores condicionantes e sua capacidade discriminativa;
- Comparar diferentes algoritmos de aprendizado de máquina quanto ao desempenho na classificação da suscetibilidade à inundação e analisar a contribuição relativa dos fatores condicionantes em cada modelo;
- Avaliar a correspondência entre o mapa de suscetibilidade gerado e a mancha de inundação disponibilizada pelo Banco Mundial.

2 REVISÃO BIBLIOGRÁFICA

2.1 INUNDAÇÕES NA BACIA HIDROGRÁFICA DO RIO ITAJAÍ

A Bacia Hidrográfica do Rio Itajaí apresenta um histórico recorrente de inundações, resultado da combinação de fatores naturais e antrópicos. Do ponto de vista físico, a geomorfologia da bacia, marcada por vales encaixados, solos pouco desenvolvidos e altitudes que variam de mais de 1.000 metros nas cabeceiras até cerca de 20 metros na região de Blumenau, contribui significativamente para a rápida concentração do escoamento superficial (Alves, 2013; Casagrande, 2015). Além disso, a baixa declividade observada em trechos médios e inferiores da bacia, como entre Blumenau e a foz do Rio Itajaí-Açu, em Itajaí e Navegantes, favorece o acúmulo de água em episódios de chuva intensa (Alves, 2013).

Em relação ao clima, a Bacia Hidrográfica do Rio Itajaí apresenta um volume anual médio de precipitação da ordem de 1.550 mm. De acordo com a classificação climática de Köppen, predominam na região os tipos subtropicalmesotérmico úmido com verões quentes (Cfa), que cobre cerca de 56,72% da área, e o subtropical mesotérmico úmido com verões amenos (Cfb), que abrange os 43,28% restantes. Ambos os tipos são marcados por distribuição regular de chuvas ao longo do ano (Santa Catarina, 2018).

Os fatores antrópicos também desempenham um papel central na intensificação dos impactos das inundações. O crescimento desordenado das áreas urbanas, o avanço da urbanização sobre áreas ribeirinhas e o uso inadequado do solo, têm aumentado significativamente a sua impermeabilização, reduzindo a infiltração e aumentando o escoamento (Alves, 2013). De acordo com Casagrande (2015), cerca de 70% dos municípios da bacia apresentam áreas construídas nas proximidades do leito do Rio Itajaí-Açu ou de seus afluentes.

Em resposta à frequência e severidade desses eventos, algumas medidas estruturais foram implementadas ao longo das décadas. Dentre elas, destacam-se as barragens de Taió, Ituporanga e José Boiteux, construídas com o objetivo de atenuar os picos de cheias (Casagrande, 2015).

Diante da recorrência e da gravidade dos eventos de inundação na região, estudos têm sido realizados com o objetivo de identificar e mapear áreas suscetíveis a esses fenômenos. Speckhann (2018) utilizou o modelo HAND associado à análise

de frequência para mapear o risco de inundação. Fleischmann, Paiva e Collischonn (2019) compararam a modelagem hidrodinâmica com o HEC-RAS e o MGB em diferentes escalas. Senger (2021) avaliou e comparou os métodos HAND e AHP para o mapeamento de manchas de inundação na bacia. Corrêa (2022) combinou aspectos socioeconômicos e o descritor de terreno HAND na análise de risco. Essas iniciativas, baseadas em diferentes metodologias, constituem ferramentas importantes para a análise e compreensão da suscetibilidade a inundações, oferecendo subsídios para o planejamento urbano e a gestão de risco.

2.2 MAPEAMENTO DE SUSCETIBILIDADE A INUNDAÇÕES COMO MEDIDA DE CONTROLE NÃO-ESTRUTURAL

A urbanização desordenada provoca alterações significativas no ciclo hidrológico, principalmente devido à impermeabilização do solo, que reduz a infiltração da água da chuva e aumenta o escoamento superficial (Tucci, 2007). Essas modificações intensificam o risco de eventos hidrológicos extremos, exigindo a adoção de medidas voltadas à mitigação de seus impactos. Tais intervenções, conhecidas como medidas de controle, podem ser classificadas em estruturais e não estruturais.

As medidas estruturais compreendem obras de engenharia projetadas para reduzir o risco de inundações por meio da modificação do sistema fluvial e do ambiente, com o objetivo de gerenciar o fluxo de água. De acordo com Canholi (2015), essas medidas podem ser intensivas, como a canalização e a aceleração do escoamento, ou extensivas, como a construção de pequenos reservatórios, ações de recomposição da vegetação e controle da erosão. Por sua vez, as medidas não estruturais consistem em estratégias de gestão preventiva, com foco no planejamento territorial e na minimização dos impactos das inundações, destacando-se pelo baixo custo de implementação (Canholi, 2015).

Entre essas estratégias, o mapeamento de áreas suscetíveis a inundações constitui uma medida não-estrutural fundamental para a mitigação e enfrentamento de eventos extremos, servindo como subsídio para o gerenciamento de risco e a formulação de políticas públicas de ordenamento urbano (Goerl; Kobiyama; Pellerin, 2012). Dentre as metodologias utilizadas para a elaboração de mapas de perigo de

inundação, destacam-se os modelos físicos/hidrodinâmicos e os modelos empíricos (Teng et al., 2017).

De acordo com Teng et al. (2017), a modelagem baseada em processos físicos, também conhecida como modelagem numérica ou hidrodinâmica, utiliza equações matemáticas que representam os fenômenos físicos associados ao escoamento da água. Esses modelos resolvem equações de fluxo em uma, duas ou três dimensões (1D, 2D ou 3D) e são capazes de simular a propagação da lâmina d'água ao longo do tempo e do espaço. Apesar de sua capacidade de fornecer resultados detalhados, sua aplicação se restringe a pequenas áreas e exige um grande volume de dados de entrada, incluindo parâmetros hidrológicos, geometria da rede de drenagem, topografia de alta resolução e, frequentemente, dados de sensoriamento remoto integrados em Sistemas de Informação Geográfica (SIG) (Ji et al., 2012). Além disso, esses modelos estão sujeitos a incertezas associadas à calibração e podem apresentar limitações na representação de fluxos complexos, como aqueles observados em áreas densamente urbanizadas (Carmo, 2020).

Por outro lado, a modelagem empírica fundamenta-se em dados observacionais e estatísticos. Para isso, são utilizados dados hidrológicos, topográficos, de Modelo Digital de Elevação (MDE) e características geomorfológicas, obtidas via sensoriamento remoto e processadas em ambiente SIG (Wang et al., 2019).

Dentre as abordagens empíricas, destaca-se o uso crescente de modelos de aprendizado de máquina, que têm se mostrado especialmente eficazes no mapeamento da suscetibilidade a inundações. Esses modelos são capazes de capturar a não linearidade dos eventos de inundação a partir de dados históricos, sem a necessidade de compreender os processos físicos subjacentes, identificando relações complexas de forma eficiente (Kaiser; Günnemann; Disse, 2022).

A aplicação de diferentes algoritmos de aprendizado de máquina tem se tornado cada vez mais frequente em estudos voltados à suscetibilidade a inundações. Modelos como Regressão Logística (RL), *Random Forest* (RF), *Support Vector Machine* (SVM), *K-Nearest Neighbors* (KNN), *Adaptive Boosting* (AdaBoost) e *Extreme Gradient Boosting* (XGBoost) foram testados no Kansas, Estados Unidos, com destaque para o desempenho superior do XGBoost e do RF (Demissie et al., 2024). No Brasil, Amaral, Piroli e Santos (2024) avaliaram os modelos RF e SVM na região amazônica, observando que o RF apresentou maior acurácia. Na Baviera,

Alemanha, Kaiser, Günnemann e Disse (2022) compararam os modelos RF, *Gradient Boosting Decision Tree* (GBDT) e CatBoost, sendo este último o mais eficaz. Em Berlim, Seleem et al. (2022) aplicaram *Convolutional Neural Network* (CNN), *Artificial Neural Network* (ANN), RF e SVM, e verificaram que o RF superou os demais em todas as resoluções espaciais avaliadas. Já Dey et al. (2024), ao estudarem a região de Tampa Bay, Flórida, utilizaram cinco algoritmos, *Decision Tree* (DT), SVM, AdaBoost, XGBoost e RF, para simular o risco de inundação, identificando o RF e XGBoost como os modelos com melhor desempenho.

Atualmente, embora esses modelos sejam cada vez mais utilizados, sua aplicação ainda se concentra em bacias hidrográficas com áreas entre 200 e 4.000 km². A modelagem de grandes áreas com alta heterogeneidade ambiental representa um desafio significativo, exigindo avanços metodológicos para garantir a escalabilidade e a precisão das previsões (Kaiser, Günnemann e Disse, 2022).

2.3 MODELOS DE APRENDIZADO DE MÁQUINA

O aprendizado de máquina é um campo da inteligência artificial voltado ao desenvolvimento de algoritmos capazes de identificar padrões e realizar previsões ou decisões baseadas em conjuntos de dados. Surgido na década de 1950, o conceito tem evoluído ao longo do tempo. Samuel (1959), definiu a área como o processo de ensinar máquinas por meio da experiência. Já Shalev-Shwartz e Ben-David (2013) descrevem o aprendizado de máquina como o desenvolvimento de métodos computacionais que extraem conhecimento de dados fornecidos, transformando experiência em informações úteis.

A recente popularização do uso de algoritmos de aprendizado de máquina em diferentes áreas do conhecimento, aliada à disponibilidade de grandes volumes de dados, tem impulsionado avanços significativos na análise e interpretação de fenômenos complexos, gerando uma crescente demanda pelo aprimoramento dessas técnicas (Jordan; Mitchell, 2015; Shinde; Shah, 2018).

No contexto do mapeamento de suscetibilidade a inundações, esses modelos têm se mostrado promissores. Eles utilizam registros históricos de ocorrência desses eventos como base para o treinamento e a validação dos algoritmos. A partir desse processo, o modelo aprende a classificar os dados com base em fatores condicionantes de inundações. Após a etapa de validação, os

algoritmos são aplicados à área de estudo para estimar a probabilidade de ocorrência desses eventos (Mudashiru et al., 2021).

O desenvolvimento de modelos de aprendizado de máquina geralmente segue um fluxo estruturado, que pode ser dividido em cinco etapas principais (Lantz, 2015): coleta de dados, que envolve a obtenção e organização das informações necessárias para o treinamento do modelo; exploração e preparação dos dados, que inclui a análise preliminar, limpeza e transformação dos dados para garantir sua qualidade; treinamento do modelo, no qual o algoritmo aprende padrões e relações a partir do conjunto de treinamento; avaliação do modelo, realizada por meio de diferentes métricas para medir seu desempenho; e aprimoramento e implementação, em que ajustes são realizados para melhorar os resultados do modelo.

Segundo Jordan e Mitchell (2015), esses algoritmos podem ser categorizados de acordo com a forma como aprendem a partir dos dados disponíveis. Existem três abordagens principais de acordo com o autor: (i) aprendizado supervisionado, que utiliza dados históricos rotulados e é amplamente empregado em tarefas de classificação e regressão; (ii) aprendizado não supervisionado, no qual os dados não possuem variáveis de resposta e o algoritmo aprende por meio da identificação de padrões e relações nos dados; e (iii) aprendizado por reforço, baseado na interação contínua do modelo com um ambiente dinâmico, no qual as decisões tomadas recebem recompensas ou penalidades para otimizar o aprendizado ao longo do tempo.

Dentro do aprendizado supervisionado, os algoritmos podem ser agrupados conforme suas diferentes abordagens. Métodos baseados em árvores de decisão, como *Decision Tree*, RF, AdaBoost, CatBoost e XGBoost, constroem regras hierárquicas para classificar os dados, sendo que os três últimos aplicam técnicas de *boosting* para aprimorar o desempenho (Ma et al., 2021). Já algoritmos como o KNN são baseados na proximidade entre instâncias, classificando uma nova amostra com base nos exemplos mais próximos no espaço de atributos (Jahanbani et al., 2024). Por fim, o SVM adota uma abordagem fundamentada em margens ótimas de separação, buscando o hiperplano que melhor divide as classes, podendo ser estendido a problemas não lineares por meio de funções kernel (Jahanbani et al., 2024).

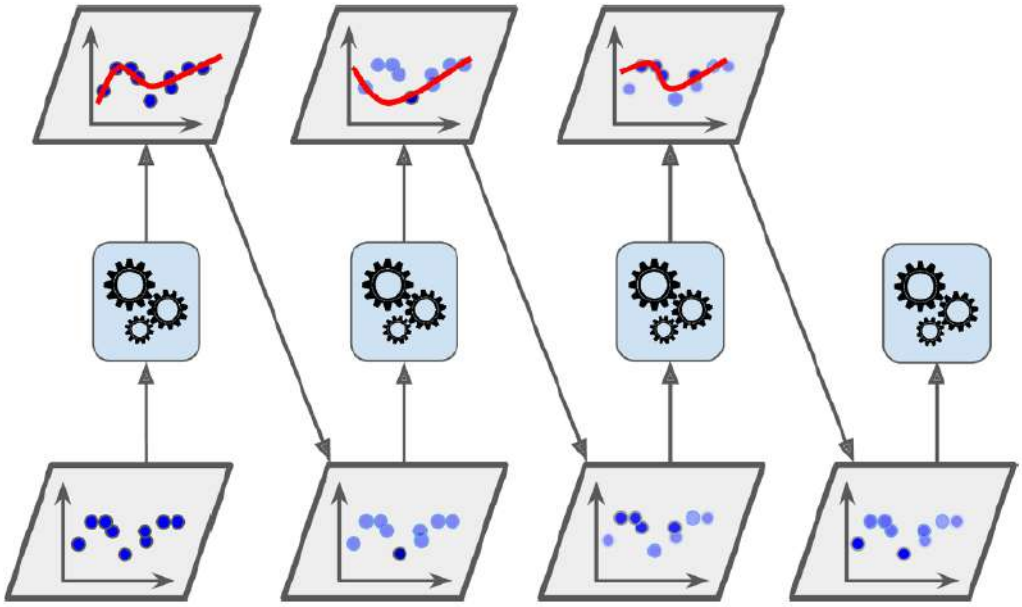
Como descrito no capítulo 2.2, atualmente, existe uma ampla variedade de algoritmos de aprendizado de máquina aplicados aos estudos de suscetibilidade a

inundações, cada um com características específicas e diferentes níveis de desempenho. Neste estudo, serão explorados os algoritmos de aprendizado supervisionado AdaBoost, XGBoost, KNN, RF e SVM, cujos detalhes serão apresentados nas seções 2.3.1 a 2.3.5, respectivamente. A escolha desses modelos fundamenta-se em sua ampla utilização na literatura e na representação de distintas abordagens de aprendizado supervisionado, com o objetivo de comparar o desempenho entre as técnicas e identificar aquela que melhor se adapta ao conjunto de dados empregados.

2.3.1 Adaptive Boosting (AdaBoost)

O algoritmo AdaBoost, introduzido por Freund e Schapire (1997), é uma técnica de aprendizado supervisionado baseada em *boosting* que combina classificadores fracos de forma sequencial para formar um modelo preditivo mais robusto. Inicialmente, o algoritmo treina um classificador base, como uma árvore de decisão simples, atribuindo pesos iguais a todas as amostras do conjunto de treinamento. Em seguida, os exemplos que forem incorretamente classificados recebem maior peso, enquanto os exemplos corretamente classificados têm seus pesos reduzidos. Essa redistribuição de pesos faz com que os classificadores subsequentes se concentrem nos casos mais difíceis. Esse processo iterativo continua com a adição de novos modelos, cada um ajustado para corrigir os erros do anterior, até que o conjunto de classificadores atinja uma boa performance preditiva (Géron, 2019). Uma representação esquemática do funcionamento do AdaBoost é apresentada na Figura 1.

Figura 1: Representação esquemática do algoritmo AdaBoost.



Fonte: Géron (2019).

2.3.2 Extreme Gradient Boosting (XGBoost)

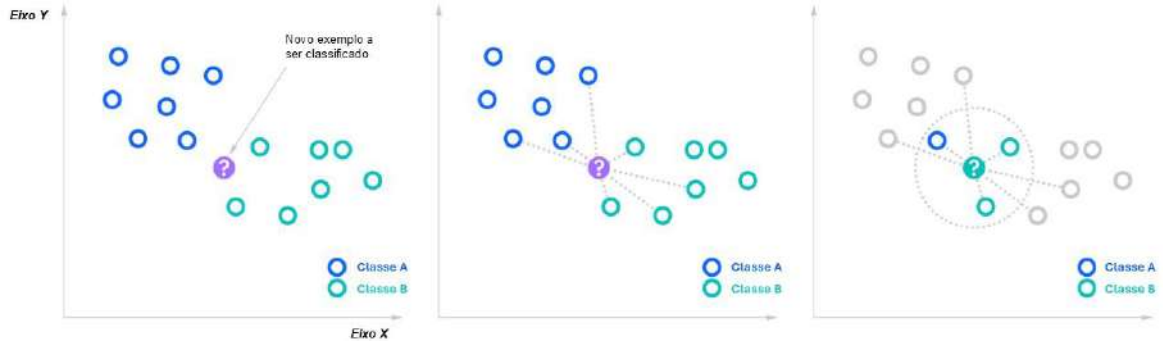
O algoritmo XGBoost, desenvolvido por Chen e Guestrin (2016), é uma extensão aprimorada das técnicas de *boosting* baseadas em árvores de decisão. De acordo com Ma et al. (2021), assim como o AdaBoost, o XGBoost constrói seus classificadores de forma sequencial, onde cada novo modelo busca corrigir os erros do anterior. No entanto, diferentemente do AdaBoost, que ajusta os pesos das amostras a cada iteração, o XGBoost ajusta os novos modelos aos erros residuais dos anteriores (Géron, 2019). Esse procedimento permite capturar com mais precisão as falhas do modelo e corrigi-las de forma mais eficaz.

2.3.3 K-Nearest Neighbors (KNN)

O algoritmo KNN é um método de aprendizado supervisionado amplamente aplicado em tarefas de classificação e regressão (Guanjun Liu et al., 2022). Seu princípio baseia-se na suposição de que amostras próximas no espaço de atributos tendem a compartilhar o mesmo rótulo. Para realizar a predição de uma nova instância, o KNN identifica os k elementos mais próximos no conjunto de treinamento, com base em uma métrica de similaridade, comumente a distância

euclidiana (Jahanbani et al., 2024). A classe atribuída à nova amostra é determinada por meio de um processo de votação majoritária entre os vizinhos selecionados, conforme representado na Figura 2.

Figura 2: Representação esquemática do algoritmo KNN.

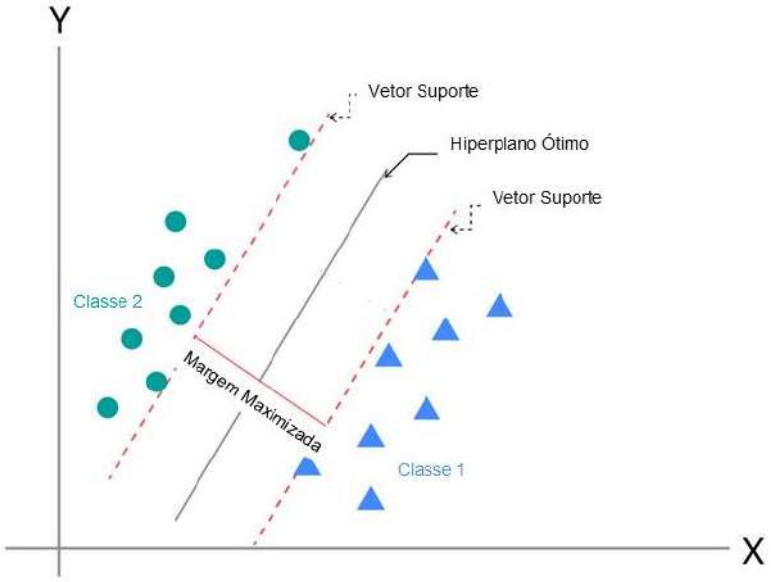


Fonte: Adaptado de IBM (2025a).

2.3.4 Support Vector Machine (SVM)

O SVM é um algoritmo supervisionado que busca identificar o hiperplano ótimo que melhor separa as classes em um espaço de atributos (Jahanbani et al., 2024). Desenvolvido por Cortes e Vapnik (1995), o SVM maximiza a margem entre os pontos de diferentes classes, proporcionando boa capacidade de generalização. Em aplicações com múltiplos atributos, o algoritmo opera em espaços com *n* dimensões, preservando o princípio da margem máxima observado em representações bidimensionais, como ilustrado na Figura 3. Em casos em que os dados não são linearmente separáveis, utiliza-se uma função kernel para projetar os dados em um espaço de maior dimensão, onde a separação torna-se possível (Jahanbani et al., 2024).

Figura 3: Representação esquemática do algoritmo SVM.



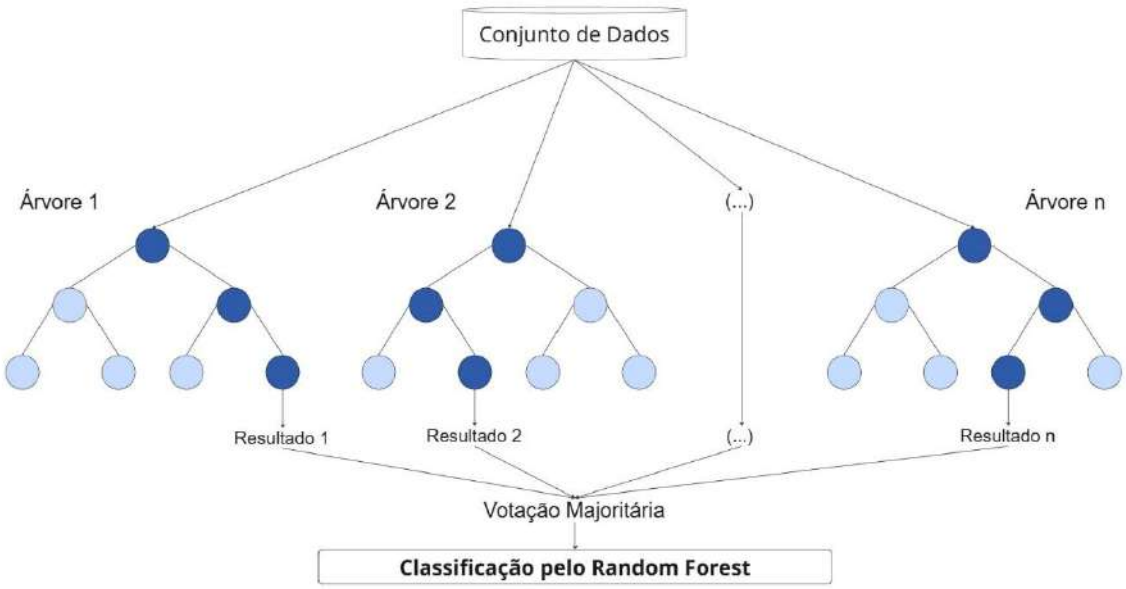
Fonte: Adaptado de IBM (2025b).

2.3.5 Random Forest

O algoritmo Random Forest, proposto por Breiman (2001), é um modelo de classificação supervisionada amplamente utilizado em tarefas de classificação e regressão devido à sua robustez e alta capacidade preditiva. Ele se baseia no conceito de aprendizagem por conjunto, onde múltiplas árvores de decisão são treinadas de forma independente, buscando minimizar a correlação entre elas para melhorar a generalização do modelo (Breiman, 2001).

De acordo com Rodrigues (2020), seu funcionamento pode ser descrito em três etapas principais. Primeiro, ocorre a fase de amostragem, na qual são geradas amostras aleatórias a partir do conjunto de dados original, utilizando o método de amostragem com reposição. Em seguida, para cada amostra, é criada uma árvore de decisão, seguindo regras previamente estabelecidas. Após a construção das árvores de decisão, o modelo Random Forest passa a ser composto pela coleção dessas árvores. Por fim, na etapa de predição, o resultado varia conforme o tipo de problema, onde para regressão, é retornada a média das previsões realizadas por todas as árvores, enquanto para classificação, a classe final é determinada pela maior quantidade de votos entre as árvores do modelo. A Figura 4 ilustra esquematicamente o algoritmo Random Forest aplicado à classificação.

Figura 4: Representação esquemática do algoritmo Random Forest.



Fonte: Adaptado de Wahba et al (2024).

2.4 FATORES CONDICIONANTES DE INUNDAÇÕES

A identificação dos fatores condicionantes é fundamental na modelagem de suscetibilidade a inundações. Eles refletem características morfométricas, climáticas e de uso do solo que influenciam diretamente a dinâmica do escoamento superficial e a probabilidade de ocorrência desses eventos. A compreensão integrada dessas variáveis é indispensável para prever com precisão a ocorrência desse fenômeno (Mudashiru et al., 2021).

Embora não exista um consenso na literatura sobre um conjunto ideal de fatores a ser utilizado nesse tipo de análise, diversos trabalhos têm contribuído para a identificação dos fatores mais relevantes.

Kaiser, Günnemann e Disse (2022) analisaram 23 estudos sobre a aplicação de algoritmos de aprendizado de máquina para o mapeamento de suscetibilidade a inundações. De acordo com os autores, os fatores condicionantes mais empregados podem ser agrupados em seis categorias principais: topografia, solo e geologia, cobertura do solo, rede de drenagem, características da precipitação e fatores antrópicos. Dentre essas, os parâmetros topográficos, como declividade, aspecto, elevação e índice de umidade topográfica (TWI), foram os utilizados com maior frequência, com destaque para a declividade, presente em todos os estudos

avaliados. Para os autores, a representação minimamente adequada da ocorrência de inundações por meio de algoritmos de aprendizado de máquina requer a consideração de variáveis relacionadas à topografia, litologia, uso do solo e rede de drenagem.

Neste trabalho, o levantamento sistematizado por Kaiser, Günnemann e Disse (2022) norteou a seleção dos fatores condicionantes. No entanto, a escolha final dos fatores também considerou variáveis complementares reconhecidas na literatura. Dessa forma, buscou-se integrar diferentes categorias de fatores identificados nos estudos analisados, priorizando aqueles mais recorrentes e relevantes em aplicações semelhantes. A sistematização completa dos estudos avaliados por Kaiser, Günnemann e Disse (2022) encontra-se no Quadro 1.

Quadro 1: Fatores condicionantes aplicados em diferentes estudos.

Fatores Condicionantes	**N° de Estudos**
Topografia	
Aspecto	16
Razão de Circularidade	1
Curvatura	8
Altitude	15
Fator LS	3
Curvatura do Plano	8
Curvatura do Perfil	8
Declividade	23
Índice de Posição Topográfica (TPI)	8
Índice de Rugosidade Topográfica (TRI)	1
Índice de Umidade Topográfica (TWI)	14
Sombra Topográfica	3
Solo e Geologia	
Grupo Hidrológico do Solo	6
Litologia	19
Profundidade do Solo	1
Umidade do Solo	1
Capacidade de Retenção de Água do Solo	1
Cobertura do Solo	
Curve Number (CN)	4
Fração de Cobertura Vegetal	2
Uso do Solo	14
Índice de Vegetação por Diferença Normalizada (NDVI)	7
Rugosidade da Superfície	1
Rede de Drenagem	
Índice de Convergência	8
Distância até o Rio	8

Fatores Condicionantes	N° de Estudos
Acumulação/Contribuição de Fluxo	3
Direção de Fluxo	1
Densidade de Drenagem	10
Índice de Energia do Fluxo	6
Características da Precipitação	
Intensidade Máx. de Precipitação (várias durações)	2
Precipitação Média (várias durações)	6
Índice de Fourier Modificado	2
Volume de Precipitação do Evento	6
Fatores Antrópicos	
Produto Interno Bruto	1
População	1
Investimentos em Prevenção	1

Fonte: Adaptado de Kaiser, Günnemann e Disse (2022).

Diante disso, os fatores condicionantes selecionados para o presente estudo incluem: altitude, declividade, aspecto, o descritor de terreno *High Above Nearest Drainage* (HAND) e TWI, como variáveis topográficas; distância até a rede de drenagem mais próxima, representando a rede de drenagem; média anual da precipitação máxima acumulada em 7 dias, como variável associada a precipitação; e o Curve Number (CN), representando a cobertura e uso do solo.

3 METODOLOGIA

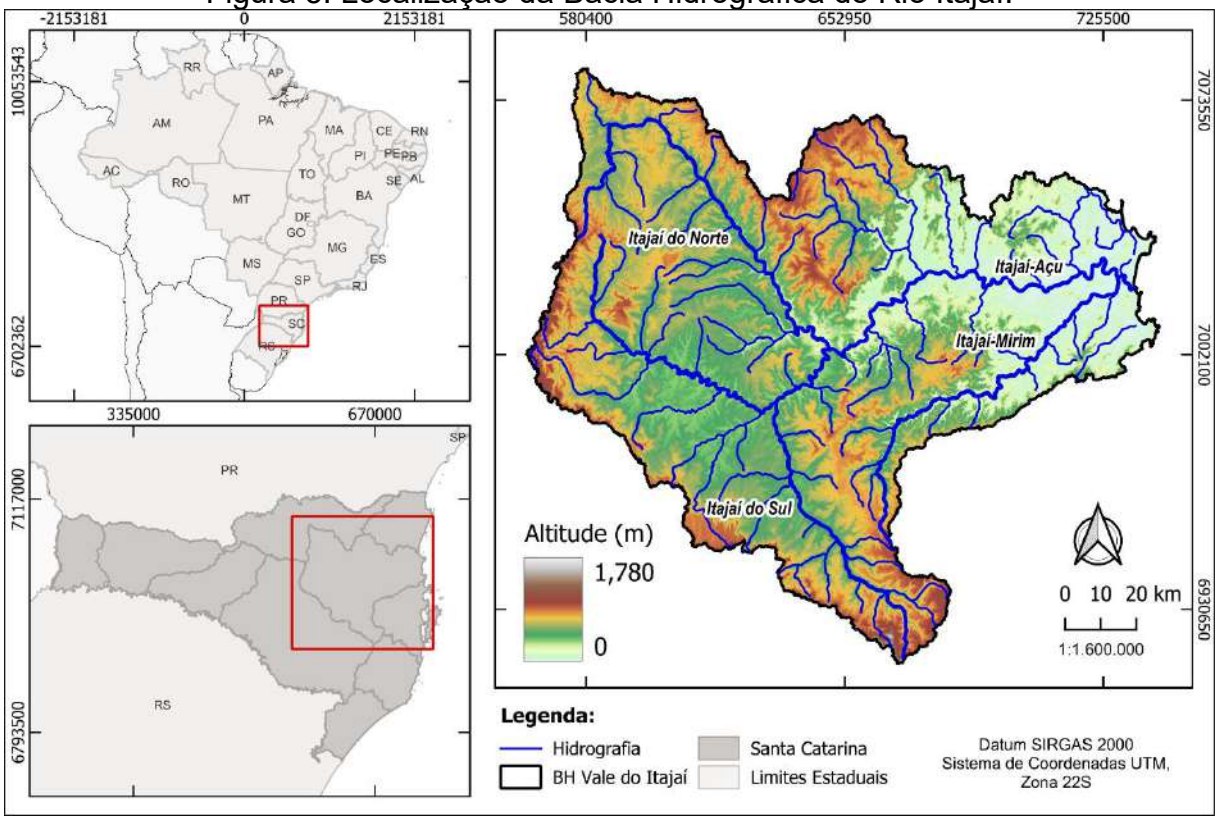
3.1 ÁREA DE ESTUDO

A Bacia Hidrográfica do Rio Itajaí, situada na região leste de Santa Catarina, abrange uma área de aproximadamente 15.000 km², configurando-se como a segunda maior entre as dez regiões hidrográficas do estado (Figura 5). Entre os principais rios que compõem a bacia, destacam-se o Itajaí-Açu, Itajaí do Norte, Itajaí do Sul, e o rio Itajaí-Mirim, que juntos formam a principal rede hidrográfica da região.

A hipsometria da bacia evidencia um predomínio de áreas de baixa altitude nos trechos médios e inferiores, onde se concentram os principais núcleos urbanos. Essa configuração favorece a acumulação de escoamento superficial e dificulta a drenagem natural durante eventos de chuva intensa, contribuindo para a recorrência de inundações nessas regiões.

Com um contingente populacional superior a 1,24 milhão de habitantes, a bacia hidrográfica do Itajaí apresenta significativa ocupação urbana. A população urbana, em torno de 1.040.000 habitantes está distribuída em 49 sedes municipais (Santa Catarina, 2018). Blumenau e Itajaí se destacam como os municípios mais populosos, sendo Blumenau o principal polo econômico regional, com mais de 361 mil habitantes (IBGE, 2022).

Figura 5: Localização da Bacia Hidrográfica do Rio Itajaí.



Fonte: O autor (2025).

3.2 MAPEAMENTO DE SUSCETIBILIDADE A INUNDAÇÕES

O fluxograma metodológico apresentado na Figura 6 resume as principais etapas do processo de modelagem adotado nesse estudo para o mapeamento da suscetibilidade a inundações na Bacia Hidrográfica do Rio Itajaí. A estrutura integra técnicas de geoprocessamento e algoritmos de aprendizado de máquina supervisionado.

Inicialmente, são coletados e processados os fatores condicionantes de inundações derivados das bases *Shuttle Radar Topography Mission (SRTM)*, Agência Nacional de Águas e Saneamento Básico (ANA) *e Climate Hazards Group InfraRed Precipitation with Station data (CHIRPS)*. Essas variáveis são então submetidas a uma análise de multicolinearidade, com base em Fator de Inflação da Variância (VIF) e do Índice de Tolerância (TOL), visando eliminar redundâncias.

Simultaneamente, são organizados os dados de resposta a partir de pontos de inundação e não inundação obtidos através do contato com a Defesa Civil e da análise do Índice de Diferença Normalizada da Água (NDWI), derivado de imagens

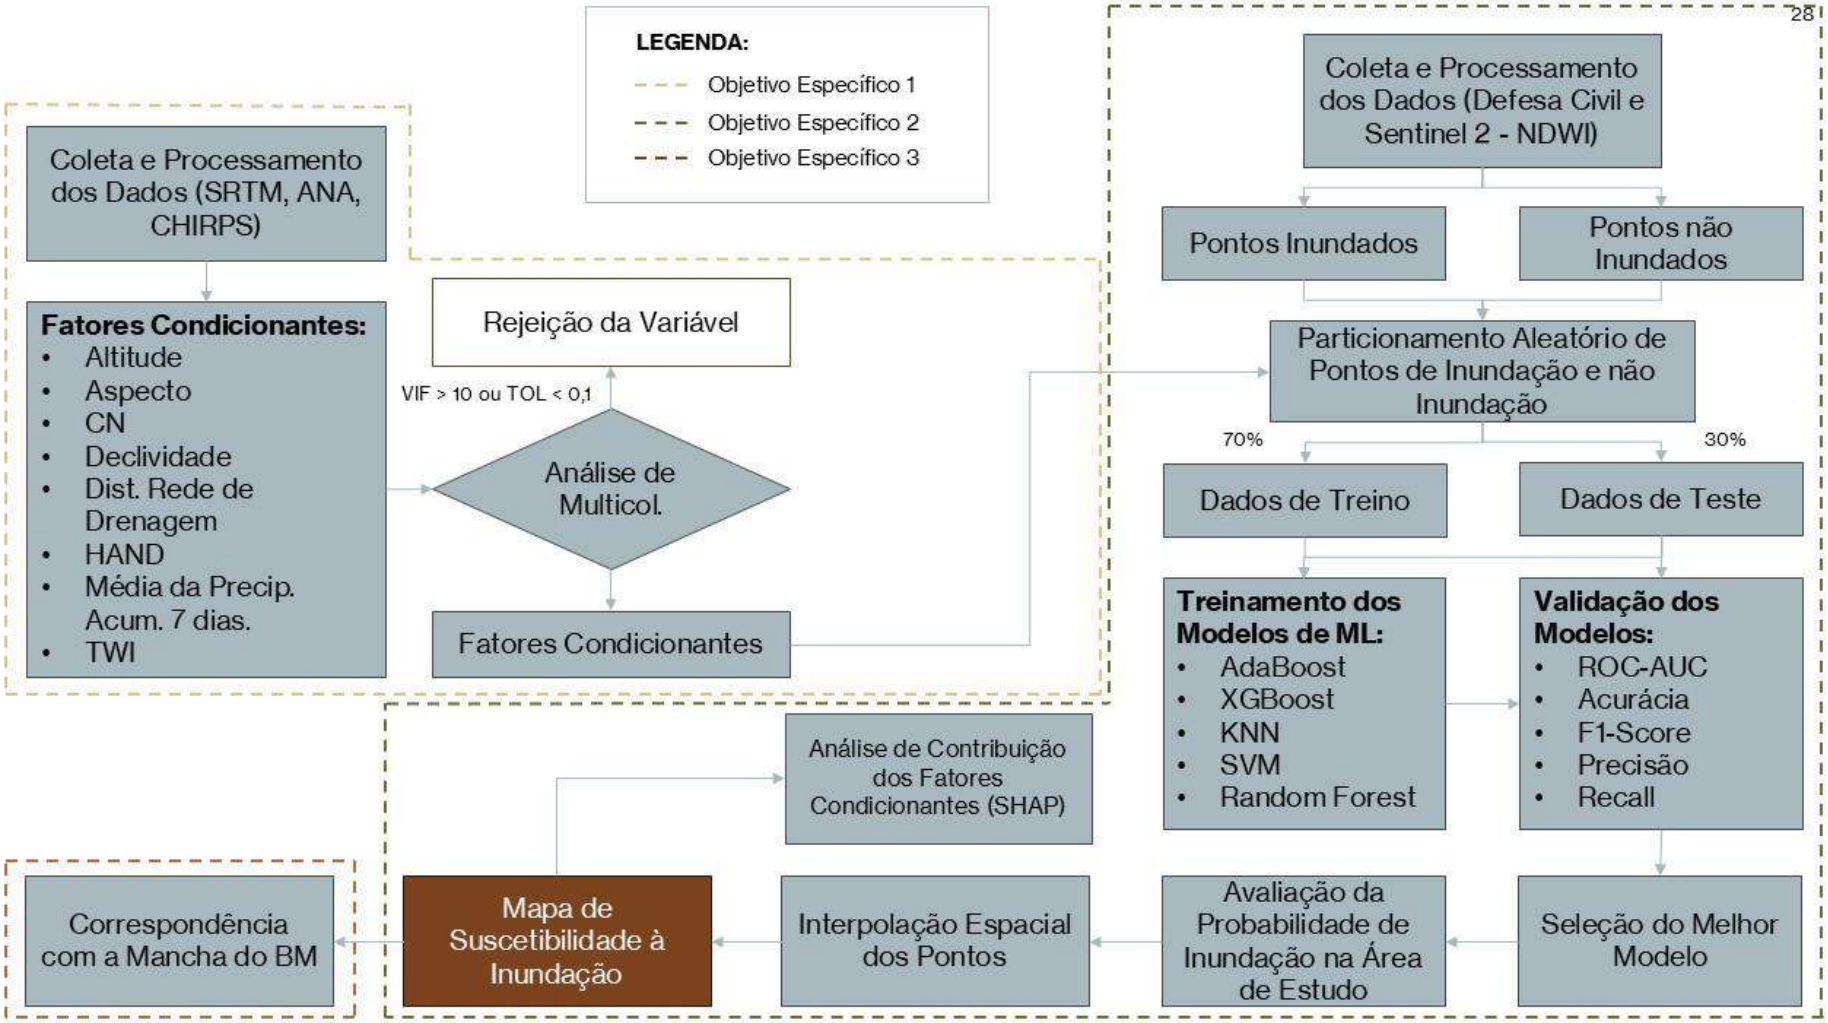
Sentinel-2. Esses pontos são balanceados e divididos em conjuntos de treino (70%) e teste (30%) para permitir a construção e validação dos modelos.

Os algoritmos empregados incluem AdaBoost, XGBoost, KNN, SVM e RF. Cada modelo é treinado com os fatores selecionados, e seu desempenho é avaliado com base em métricas como acurácia, *F1-score*, precisão, *recall* e área sob a curva ROC. Vale destacar que, neste estudo, não foi realizado ajuste de hiperparâmetros, sendo adotadas as configurações padrão de cada algoritmo. Após a avaliação, o melhor modelo é selecionado e utilizado para gerar o mapa final de suscetibilidade à inundação. Para isso, os resultados foram transferidos para uma malha regular com espaçamento de 100 metros, cobrindo toda a área de estudo, e os valores de probabilidade foram interpolados por meio do método TIN (*Triangulated Irregular Network*) para a geração do mapa final. A aplicação e avaliação dos modelos foram realizadas por meio da linguagem Python, utilizando as bibliotecas Scikit-learn e XGBoost.

Além disso, é realizada uma análise da contribuição individual de cada fator condicionante utilizando o método *SHapley Additive exPlanations* (SHAP), permitindo interpretar a influência de cada variável sobre os resultados da classificação. Esse mapa é, por fim, validado com base na mancha de inundação disponibilizada pelo Banco Mundial.

As etapas apresentadas no fluxograma foram organizadas de modo a refletir diretamente os objetivos específicos deste trabalho. A análise dos fatores condicionantes, por meio da avaliação de multicolinearidade (Objetivo Específico 1); a construção e avaliação comparativa dos modelos de aprendizado de máquina (Objetivo Específico 2); e a validação do mapeamento de suscetibilidade com base na mancha de inundação disponibilizada pelo Banco Mundial (Objetivo Específico 3) compõem a estrutura metodológica adotada. O detalhamento de cada uma dessas etapas é apresentado nas seções a seguir.

Figura 6: Fluxograma metodológico do mapeamento de suscetibilidade a inundações da Bacia do Rio Itajaí.



Fonte: O autor (2025).

3.2.1 Inventário de Inundações

O inventário de inundações desempenha um papel central, servindo como base para o treinamento e a validação dos modelos. Para isso, é necessário coletar dados representativos de áreas historicamente afetadas e não afetadas. A partir da comparação entre essas localidades, os algoritmos aprendem a reconhecer padrões espaciais e condições que favorecem a ocorrência do fenômeno (Kaiser; Günnemann; Disse, 2022).

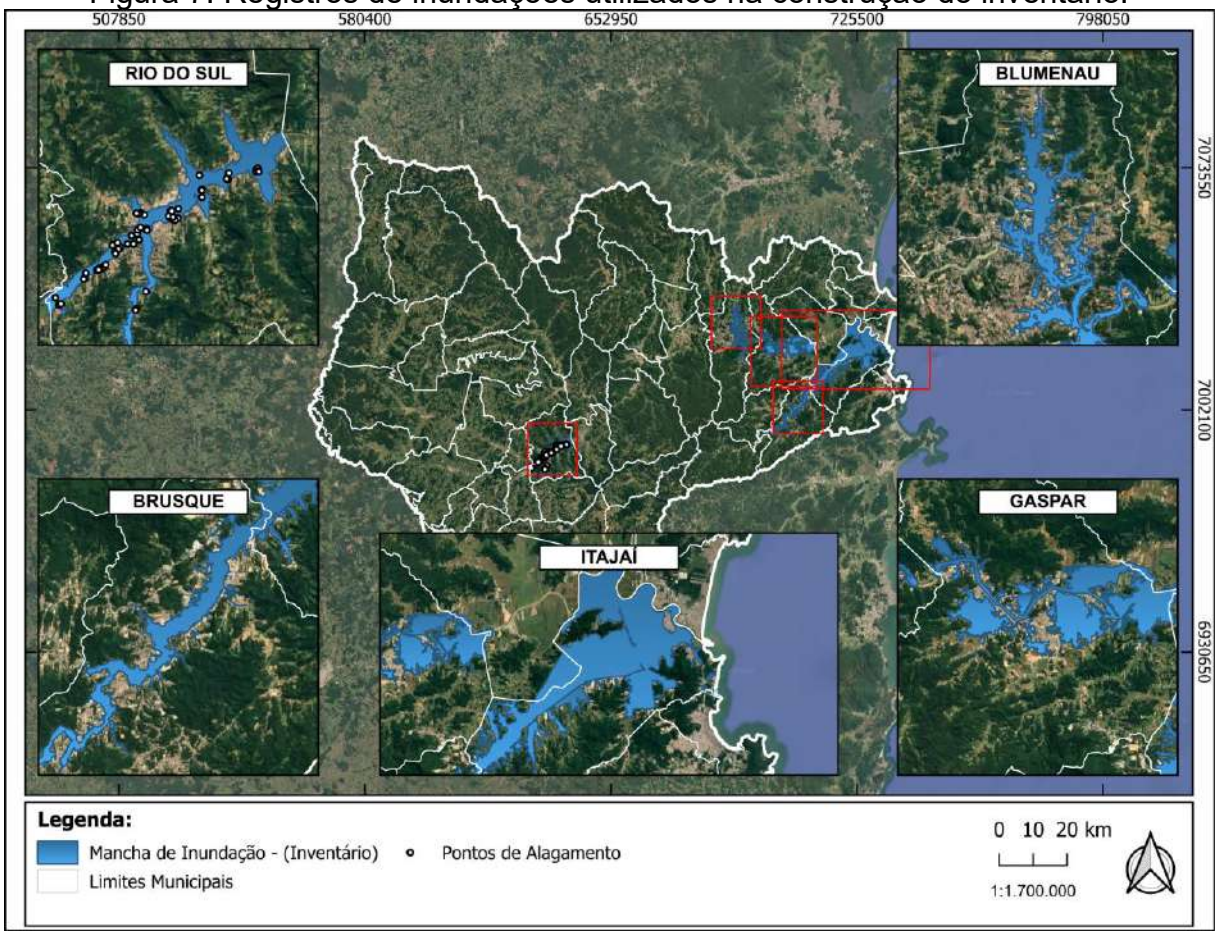
Neste estudo, o inventário foi elaborado com base em registros disponibilizados pelas Defesas Civis dos municípios de Blumenau, Brusque, Gaspar, Itajaí e Rio do Sul, todos localizados na bacia hidrográfica do Rio Itajaí. Os dados compreendem tanto polígonos delimitando áreas afetadas por eventos de inundação quanto pontos georreferenciados de ocorrência. Para cada município, os registros de diferentes eventos foram unificados no software QGIS, resultando em uma única mancha representativa de inundação por cidade. A Figura 7 ilustra a localização e a extensão das manchas de inundação obtidas a partir dos registros descritos na Tabela 1.

Tabela 1: Registros de inundações utilizados na construção do inventário.

Município	Ano do Evento	Tipo de Dado
Blumenau	1983, 2011, 2013	Polígono
Brusque	2011	Polígono
Gaspar	2011	Polígono
Itajaí	1983, 1984, 2001, 2008, 2011	Polígono
Rio do Sul	2011, 2013, 2015	Pontos e Polígonos

Fonte: O autor (2025).

Figura 7: Registros de inundações utilizados na construção do inventário.



Fonte: O autor (2025).

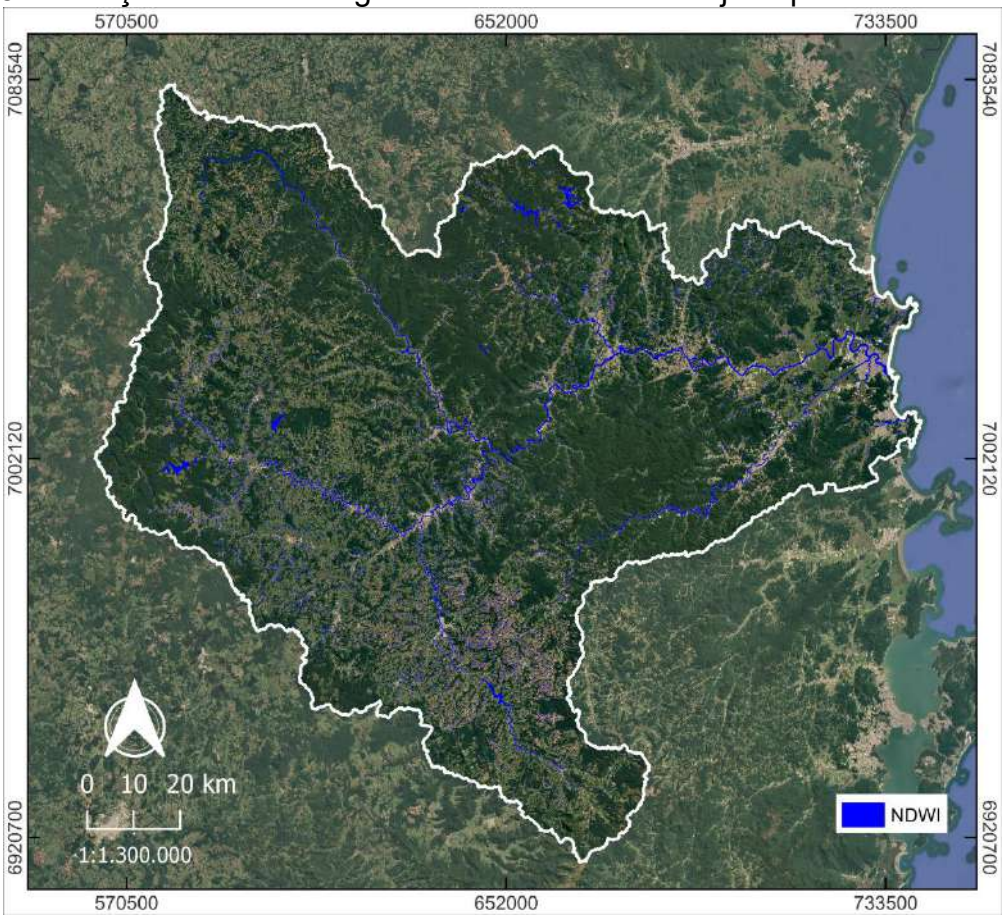
Para viabilizar a análise de suscetibilidade a inundações em toda a bacia e ampliar a representatividade do inventário, os dados da Defesa Civil foram complementados por análises baseadas no Índice de Diferença Normalizada da Água (NDWI), calculado a partir de imagens do satélite Sentinel-2, no período de 2015 a 2024, por meio da plataforma *Google Earth Engine* (GEE). Esse índice realça áreas com presença de água superficial ao combinar as bandas verde (B3) e infravermelho próximo (B8), conforme a Equação (1).

$$NDWI = \frac{(B3 - B8)}{(B3 + B8)} \qquad \text{Equação (1)}$$

No presente estudo foram selecionadas apenas imagens com cobertura de nuvens inferiores a 20%. Após o cálculo do NDWI, as imagens foram transformadas em rasters binários considerando como áreas alagadas os píxeis com valores

superiores a 0,3. A Figura 8 apresenta o resultado da aplicação do NDWI sobre a bacia do Rio Itajaí, destacando as áreas alagadas no período analisado.

Figura 8: Detecção de áreas alagadas na Bacia do Rio Itajaí a partir do índice NDWI.



Fonte: O autor (2025).

Embora o NDWI seja uma ferramenta útil na identificação de áreas inundadas, suas limitações devem ser consideradas. A detecção pode ser influenciada por fatores como cobertura de nuvens, sombra de relevo, superfícies urbanas com alta refletância e presença de corpos d'água. Além disso, a resolução espacial e temporal do sensor pode comprometer a identificação de eventos breves ou localizados, especialmente em áreas densamente urbanizadas. Adicionalmente, parte dos corpos hídricos permanentes, especialmente reservatórios artificiais, foram identificados no resultado do NDWI e removidos manualmente na etapa de pós-processamento, de modo a evitar interferências. Diante disso, os pontos identificados a partir do NDWI devem ser interpretados e considerados como uma

complementação aos registros documentados, contribuindo para uma maior abrangência do inventário.

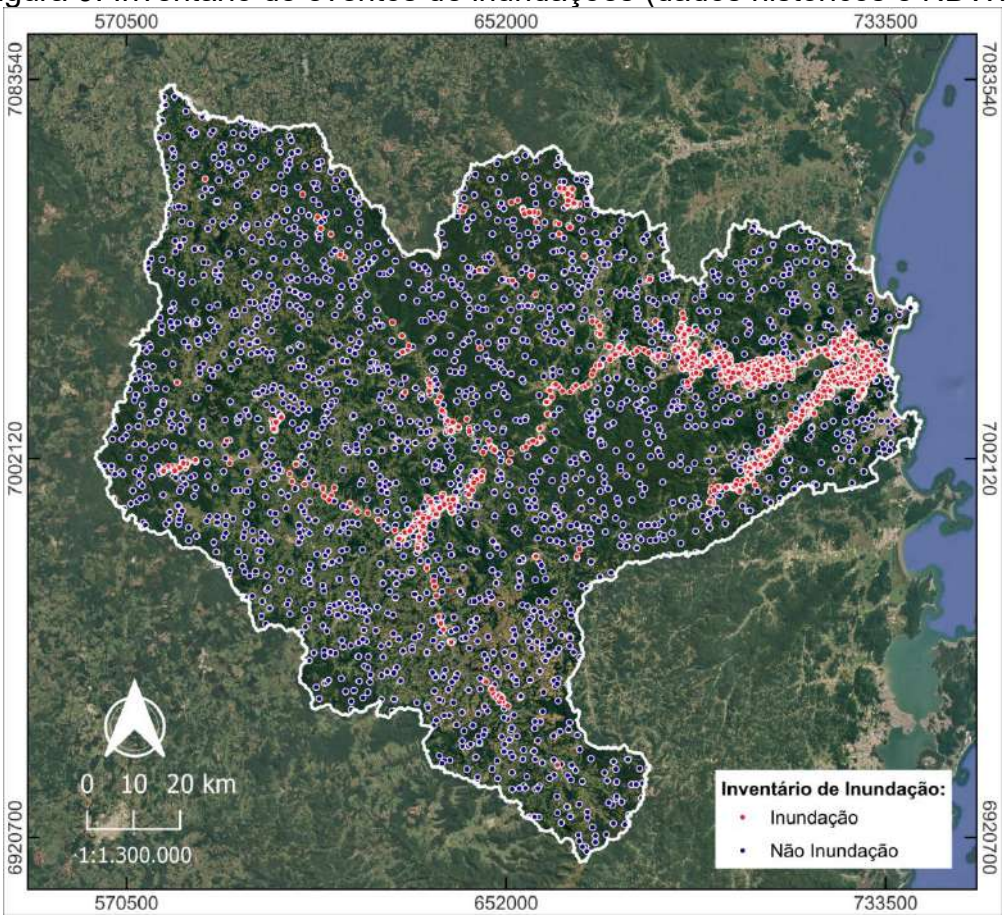
A integração entre os registros históricos e os dados extraídos via NDWI foi realizada por meio da união de todas as manchas históricas e NDWI em um único polígono no QGIS. Em seguida, foi gerada uma única mancha consolidada de inundação, representando a área total afetada por inundações na bacia.

Buscou-se, por meio da integração entre registros históricos e as áreas alagadas extraídas via sensoriamento remoto, fortalecer a robustez dos modelos de aprendizado de máquina e ampliar sua capacidade de generalização frente à variabilidade das condições ambientais presentes na área de estudo.

A partir da área identificada como inundada, com aproximadamente 230 km², foram gerados aleatoriamente 2.000 pontos da classe de inundação. Para compor a classe oposta, 2.000 pontos não inundados foram igualmente gerados aleatoriamente, com base na região restante da bacia hidrográfica, excluindo-se as áreas afetadas por inundação. Essa abordagem garantiu o balanceamento entre as classes, condição fundamental para evitar viés nos algoritmos e assegurar maior consistência na etapa de modelagem.

A Figura 9 apresenta a distribuição espacial dos pontos considerados para o desenvolvimento do inventário de inundações.

Figura 9: Inventário de eventos de inundações (dados históricos e NDWI).



Fonte: O autor (2025).

3.2.2 Fatores Condicionantes de Inundações

A seleção dos fatores condicionantes neste estudo teve como objetivo representar de forma abrangente os principais processos que influenciam a ocorrência de inundações. A definição dessas variáveis considerou, além da relevância teórica, a disponibilidade de dados para a área de estudo e sua aplicabilidade no mapeamento de suscetibilidade a inundações. Os dados foram obtidos de diferentes fontes e processados em ambiente de Sistema de Informação Geográfica (SIG).

A Tabela 2 apresenta essas variáveis juntamente com suas respectivas fontes de dados e resoluções espaciais utilizadas no estudo.

Tabela 2: Variáveis condicionantes à inundação, com respectivas fontes de dados e resoluções espaciais.

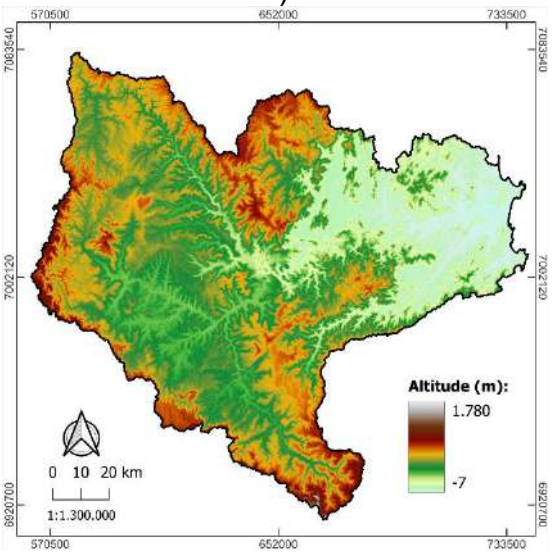
Categoria	Variável	Fonte de Dados	Resolução Horizontal
Topografia	Altitude	MDT (SRTM)	1 arco-segundos
	Declividade	MDT (SRTM)	1 arco-segundos
	Aspecto	MDT (SRTM)	1 arco-segundos
	HAND	MDT (SRTM)	1 arco-segundos
	TWI	MDT (SRTM)	1 arco-segundos
Cobertura e Uso do Solo	CN	ANA (2024)	30 m
Rede de Drenagem	Distância da Rede de Drenagem	Rede derivada do MDT	1 arco-segundos
Precipitação	Média Anual da Precipitação Máx. Acumulada em 7 dias	CHIRPS	0,05°

Fonte: O autor (2025).

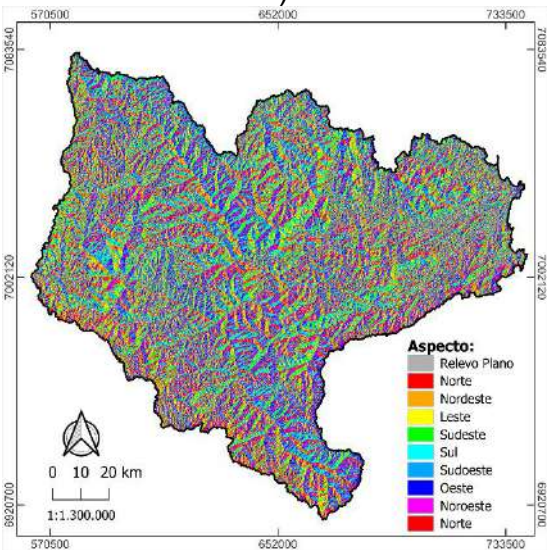
Com base nos fatores identificados na revisão bibliográfica, foi realizado o pré-processamento dos dados para a geração dos fatores condicionantes aplicados à área de estudo. A Figura 10 ilustra os fatores condicionantes selecionados. Ressalta-se que essas variáveis compõem um conjunto inicial, sujeito à análise de multicolinearidade, que orientará a definição final dos fatores a serem utilizados na modelagem do presente estudo.

Figura 10: Fatores condicionantes de inundação selecionados. a) Altitude; b) Aspecto; c) CN; d) Declividade; e) Dist. da Rede de Drenagem; f) HAND; g) Média Anual da Prec. Máx. Acum. (7 dias); h) TWI.

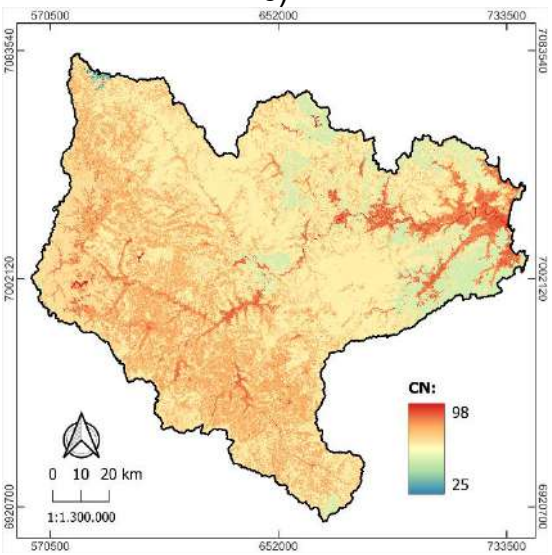
a)



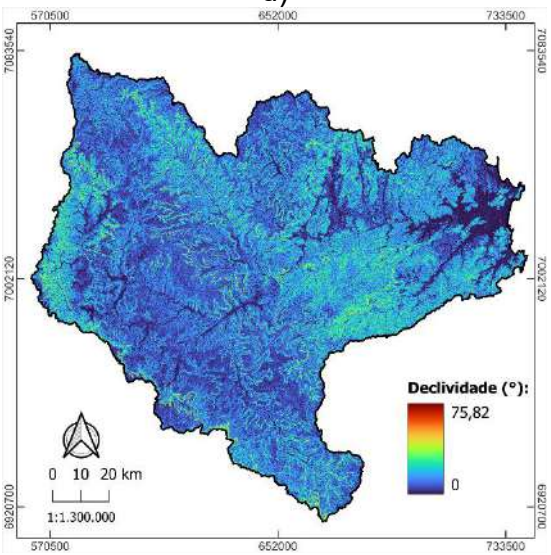
b)



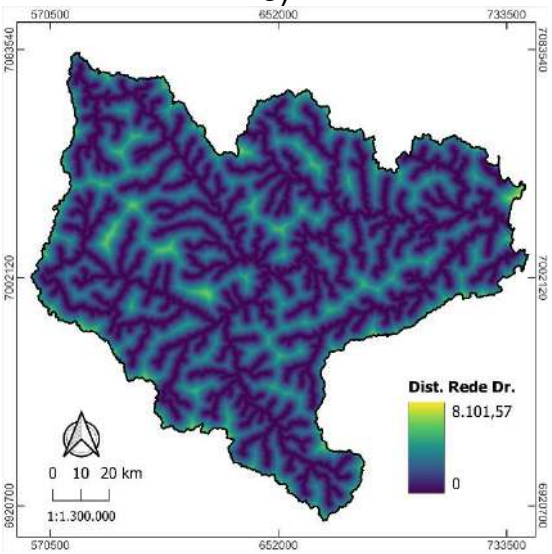
c)



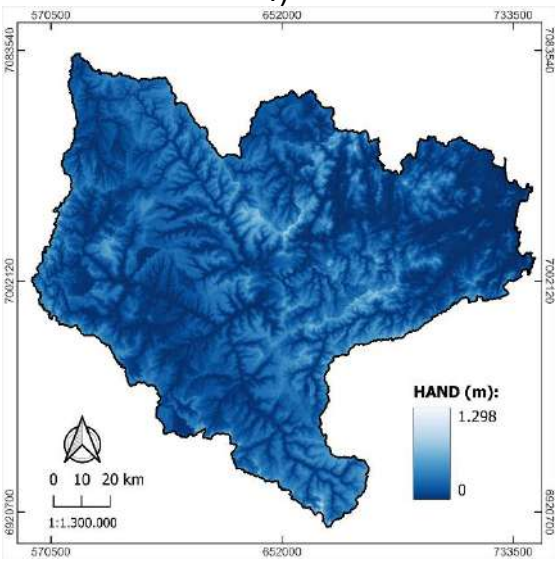
d)



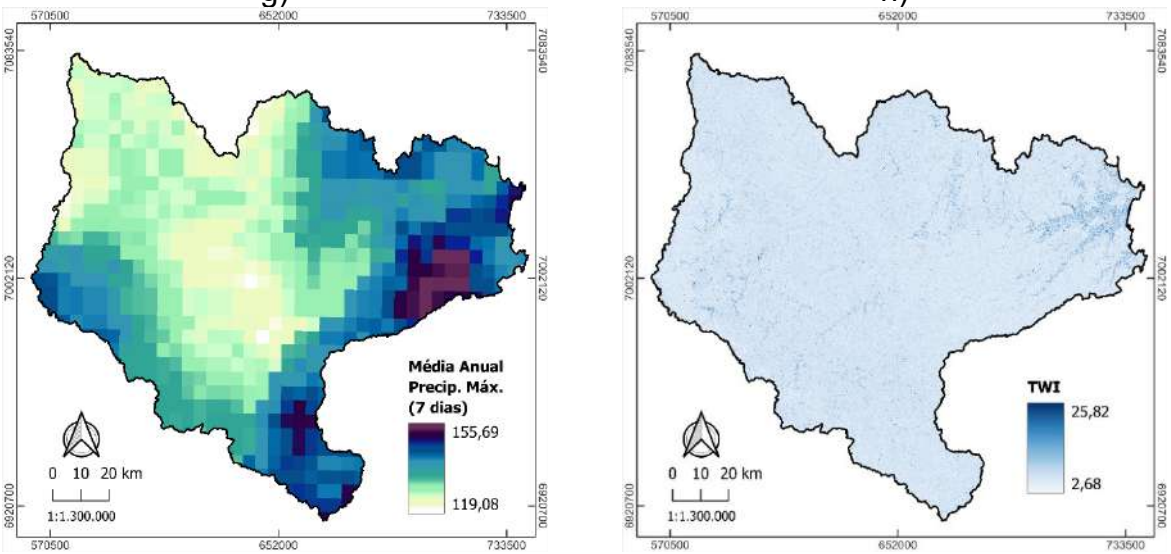
e)



f)



g) h)



Fonte: O autor (2025).

3.2.2.1 Fatores Topográficos – Altitude, Declividade, Aspecto, HAND e TWI

Os fatores topográficos exercem influência direta sobre os padrões de escoamento superficial e, consequentemente, sobre a suscetibilidade a inundações. No presente estudo, foram consideradas a altitude, declividade, aspecto e o HAND como fatores condicionantes relacionados à topografia.

A altitude refere-se à elevação do terreno em relação ao nível do mar e influencia diretamente a energia potencial da água. Áreas situadas em maiores altitudes tendem a ser menos suscetíveis a inundações, enquanto regiões de menores altitudes apresentam maior probabilidade de acumulação de água, especialmente em eventos de precipitação intensa (Seleem et al., 2021).

A declividade expressa a inclinação do terreno em relação à horizontal e é um fator determinante para o comportamento do escoamento superficial. Áreas com baixa declividade favorecem o acúmulo de água na superfície, aumentando a suscetibilidade a inundações, enquanto terrenos mais inclinados tendem a acelerar o escoamento e reduzir o acúmulo de água (Kaiser; Günnemann; Disse, 2022). No QGIS, a declividade é calculada a partir do MDT utilizando a função “*Slope”*.

O aspecto descreve a direção da máxima inclinação do terreno, indicando para qual lado a água tende a escoar a partir de cada célula do modelo de elevação. Essa variável está diretamente associada ao padrão de escoamento superficial e à

dinâmica de concentração de fluxos (Seleem et al., 2021). No QGIS, o aspecto é calculado a partir do MDT utilizando a função "*Aspect"*.

O índice TWI é um indicador derivado do relevo que expressa o potencial de acúmulo de umidade no solo, considerando a área de contribuição do escoamento e a declividade local. Ele reflete a influência da topografia na saturação do terreno e na geração de escoamento superficial (Seleem et al., 2021). O TWI é calculado através da Equação (2).

$$TWI = \ln\left(\frac{A}{\tan(\beta)}\right) \qquad \text{Equação (2)}$$

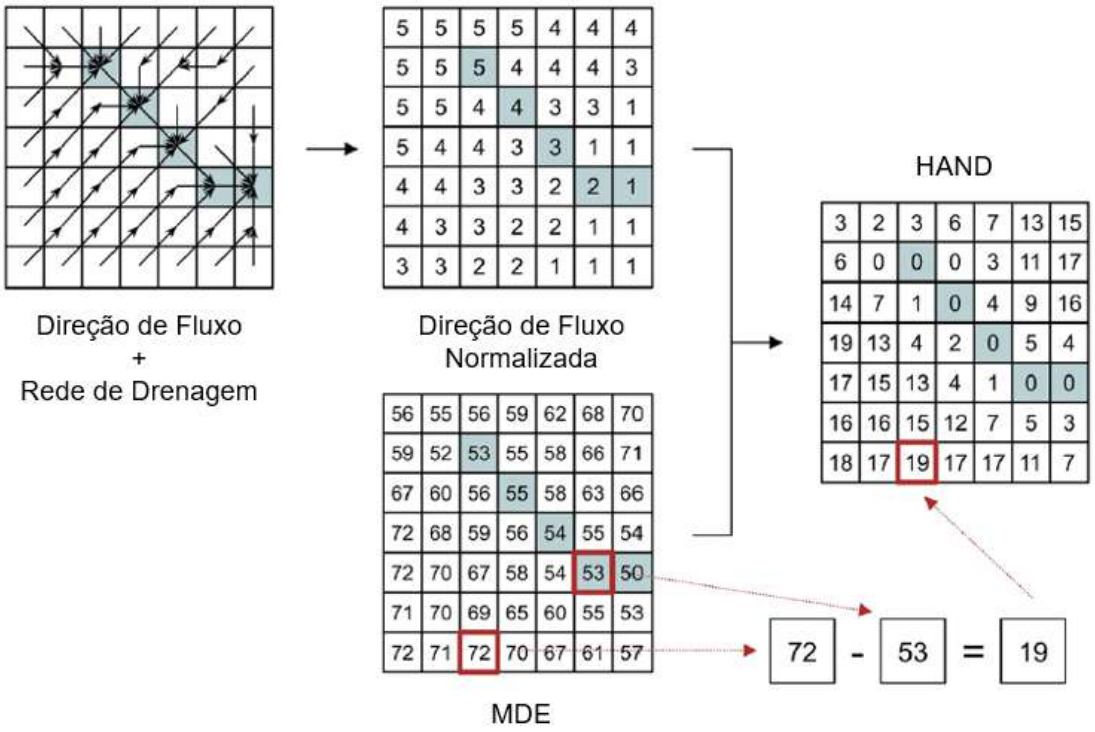
Onde A é a área de contribuição, calculada utilizando a função "*Flow Accumulation"* do SAGA, no QGIS, e β a declividade.

O modelo HAND é uma técnica que deriva informações do Modelo Digital de Elevação (MDE) para calcular a diferença altimétrica entre cada célula do terreno e o curso de água mais próximo (Rennó et al., 2008). Esse valor representa a altura relativa de um ponto em relação à drenagem adjacente, funcionando como um indicador do potencial de inundação. Assim, áreas cujo HAND é inferior ou igual a um determinado nível de água podem ser consideradas suscetíveis à inundação.

Para a geração do HAND, utiliza-se um MDE corrigido para a remoção de depressões e descontinuidades, juntamente com a definição da direção de fluxo e a geração da rede de drenagem. A partir dessas informações, calcula-se a diferença de altitude entre cada célula do terreno e o canal de drenagem mais próximo, conforme ilustrado na Figura 11.

Diversos estudos destacam a relevância do HAND no mapeamento de suscetibilidade a inundações, demonstrando sua capacidade de representar áreas inundáveis (Speckhann, 2018; Souza, 2021; Corrêa, 2022). Devido à sua simplicidade operacional e desempenho robusto, o HAND tornou-se uma ferramenta amplamente empregada em estudos de mapeamento de suscetibilidade a inundações.

Figura 11: Procedimento de cálculo do HAND.



Fonte: Adaptado de Rennó et al. (2008).

Os fatores altitude, aspecto, declividade e HAND foram derivadas a partir do Modelo Digital de Elevação (MDE) da missão *Shuttle Radar Topography Mission* (SRTM) (USGS, 2016), com resolução espacial de 30 metros. Para todas essas variáveis, o pré-processamento incluiu o preenchimento de depressões no relevo, com o objetivo de garantir a continuidade do escoamento superficial.

No caso do descritor de terreno HAND, foi realizada inicialmente a extração da rede de drenagem a partir do MDE, utilizando a biblioteca Pysheds (Bartos, 2024). A partir da rede de drenagem gerada, foi calculada a altura relativa de cada célula em relação ao canal mais próximo, utilizando a biblioteca Descriptools (Souza, 2021).

A ferramenta Descriptools, desenvolvida por Souza (2021) em linguagem Python, disponibiliza rotinas para o cálculo de diferentes descritores de terreno. A sua implementação se destaca pelo uso de processamento paralelo baseado na plataforma NVIDIA CUDA, o que permite o aproveitamento da capacidade de computação de placas gráficas (GPU).

3.2.2.2 Cobertura e Uso do Solo – Curve Number (CN)

O CN é um índice amplamente utilizado para representar a capacidade de retenção de água do solo, integrando informações sobre o uso, cobertura e grupo hidrológico do solo. Esse parâmetro influencia diretamente o volume de escoamento superficial gerado após eventos de precipitação (Seleem et al., 2021).

O CN foi obtido a partir do mapa desenvolvido pela Agência Nacional de Águas e Saneamento Básico (ANA) (ANA, 2024), correspondente ao ano de 2022, disponibilizado em formato *raster* com resolução espacial de 30 metros. Para a geração deste dado, as classes hidrológicas de solos, atribuídas com base na classificação de Sartori et al. (2005), foram cruzadas com os dados de uso e ocupação do solo do MapBiomas (resolução espacial de 30 metros, escala 1:60.000).

3.2.2.3 Rede de Drenagem – Distância da Rede de Drenagem

A distância da rede de drenagem representa a distância euclidiana entre um ponto e o rio mais próximo. É amplamente aplicada no mapeamento de suscetibilidade a inundações, por refletir a probabilidade de uma área ser afetada pelo transbordamento de corpos hídricos (Seleem et al., 2021). Assim como os fatores topográficos, a variável foi derivada a partir da rede extraída do MDE, representando a distância euclidiana entre cada célula do terreno e o canal de drenagem mais próximo. A rede de drenagem foi gerada no QGIS por meio do módulo *r.watershed* do ambiente GRASS.

3.2.2.4 Precipitação – Média Anual da Precipitação Máxima Acumulada em 7 Dias

A precipitação é reconhecida como um fator determinante para a ocorrência de inundações. No presente trabalho, foi utilizada a média anual da precipitação máxima acumulada em janelas móveis de sete dias.

A variável foi obtida da base CHIRPS (*Climate Hazards Group InfraRed Precipitation with Station data*) (Funk et al., 2015), acessada por meio da plataforma

GEE. O CHIRPS combina dados de satélite e observações de estações pluviométricas, fornecendo estimativas de precipitação com resolução espacial de aproximadamente 5 km. Considerou-se a média da precipitação máxima acumulada em janelas móveis de sete dias, ao longo do período de 2020 a 2024.

3.2.3 Análise dos Fatores Condicionantes de Inundações

3.2.3.1 Capacidade de Discriminação dos Fatores Condicionantes

A fim de verificar a capacidade discriminante dos fatores condicionantes entre áreas classificadas como inundadas e não inundadas, foi realizada uma análise estatística utilizando o teste de Wilcoxon. Trata-se de um teste não paramétrico apropriado para comparar distribuições de variáveis contínuas em dois grupos distintos, especialmente quando não se pode assumir a normalidade dos dados. A abordagem foi empregada igualmente no estudo de Amaral, Piroli e Santos (2024).

Para cada fator condicionante, a distribuição dos valores foi comparada entre os pontos rotulados como classe 0 (não inundado) e classe 1 (inundado). O principal resultado considerado foi o p-valor. Valores de p inferiores a 0,05 indicam que há evidência estatística de que o fator analisado apresenta diferença significativa entre as classes, sugerindo capacidade de discriminar áreas suscetíveis de não suscetíveis à inundação.

3.2.3.2 Análise de Multicolineariedade

Antes de se proceder com o processo de predição da suscetibilidade, é essencial verificar a adequabilidade dos fatores condicionantes. Em modelos preditivos, a presença de multicolinearidade indica a não independência entre os fatores condicionantes, o que pode comprometer a robustez do modelo (Dormann et al., 2013).

Neste estudo, a avaliação da multicolinearidade entre os fatores condicionantes selecionados foi realizada por meio do Fator de Inflação da Variância (VIF) e do Índice de Tolerância (TOL) para os pontos amostrais. De acordo com Dormann et al. (2013), valores de VIF iguais ou superiores a 10 indicam forte

colinearidade entre os fatores, enquanto valores de TOL inferiores a 0,1 apontam para uma situação de multicolinearidade. As equações utilizadas para o cálculo são apresentadas a seguir:

$$VIF = \frac{1}{TOL} \quad \text{Equação (3)}$$

$$TOL = 1 - R_v^2 \quad \text{Equação (4)}$$

Onde R_v^2 representa o coeficiente de determinação da regressão da variável explicativa em função das demais variáveis do modelo.

3.2.4 Métricas de Avaliação de Desempenho dos Modelos de Aprendizado de Máquina

Para a avaliação e comparação do desempenho dos modelos de aprendizado de máquina, foram empregadas 5 métricas de desempenho: acurácia, precisão, *recall*, *F1-Score* e AUC-ROC. Essas métricas, amplamente utilizadas na literatura (Kaiser; Günnemann; Disse, 2022; Amaral; Piroli; Santos, 2024; Dey et al.; 2024), são descritas a seguir.

A acurácia mede a proporção de classificações corretas em relação ao total de amostras analisadas, sendo definida como:

$$Acurácia = \frac{TP + TN}{TP + TN + FP + FN} \quad \text{Equação (5)}$$

Onde *TP* representa os verdadeiros positivos, *TN* os verdadeiros negativos, *FP* os falsos positivos e *FN* os falsos negativos.

A precisão indica a proporção de amostras classificadas como positivas que são realmente positivas, sendo calculada como:

$$Precisão = \frac{TP}{TP + FP} \quad \text{Equação (6)}$$

Onde *TP* representa os verdadeiros positivos e *FP* os falsos positivos.

Recall ou sensibilidade, mede a capacidade do modelo em identificar corretamente as amostras positivas, é definida por:

$$Recall = \frac{TP}{TP + FN} \quad \text{Equação (7)}$$

Onde *TP* representa os verdadeiros positivos e *FN* os falsos negativos.

O *F1-Score* é a média harmônica entre precisão e *recall*, buscando equilibrar ambas as métricas, e é dado por:

$$F1\ Score = \frac{2TP}{2TP + FP + FN} \quad \text{Equação (8)}$$

Onde *TP* representa os verdadeiros positivos, *FP* os falsos positivos e *FN* os falsos negativos.

Adicionalmente, foi utilizada a curva ROC (*Receiver Operating Characteristic Curve*) para a avaliação do desempenho dos classificadores. A curva ROC ilustra a relação entre a taxa de verdadeiros positivos (TPR) e a taxa de falsos positivos (FPR) em diferentes limiares de classificação. O AUC, que corresponde à área sob a curva ROC, é utilizado como um indicador quantitativo de desempenho. Quanto maior o valor de AUC, melhor é o desempenho do classificador em discriminar entre as classes positivas (áreas inundadas) e negativas (áreas não inundadas).

Com o objetivo de selecionar o modelo com melhor desempenho, foi adotada uma abordagem baseada na média simples das métricas consideradas. Para cada modelo, foi calculado o valor médio das cinco métricas descritas, conforme a seguinte fórmula:

$$Score\ Médio\ = \frac{Acurácia + Precisão + Recall + F1 - Score + AUC}{5} \quad \text{Equação (9)}$$

3.2.5 Análise de Contribuição dos Fatores Condicionantes - SHAP

Para interpretar a contribuição individual de cada fator condicionante na predição da suscetibilidade a inundações, foi utilizada a técnica SHAP (*SHapley Additive exPlanations*).

A técnica foi implementada por meio da biblioteca SHAP em Python, a qual permitiu calcular os valores de contribuição de cada variável para as predições do modelo. Esses valores expressam o impacto individual de cada fator condicionante sobre a probabilidade prevista de inundação, indicando a magnitude e o sentido (positivo ou negativo) de sua influência.

No presente estudo, os valores SHAP foram obtidos a partir de uma amostra representativa dos dados de entrada e visualizados por meio de gráficos de resumo que indicam a magnitude e a direção da influência de cada variável. Essa abordagem tem sido amplamente empregada em estudos de suscetibilidade a inundações (Kaiser; Günnemann; Disse, 2022; Seleem et al.; 2022, Dey et al.; 2024),

3.3 CORRESPONDÊNCIA COM A MANCHA DE INUNDAÇÃO DO BANCO MUNDIAL

Com o objetivo de validar o mapeamento gerado pelo modelo de melhor desempenho dentre os algoritmos de aprendizado de máquina avaliados neste estudo, foi realizada uma validação utilizando como referência a mancha de inundação disponibilizada pelo Banco Mundial, correspondente a um evento com tempo de retorno (TR) de 50 anos.

3.3.1 Modelo de Referência - Banco Mundial

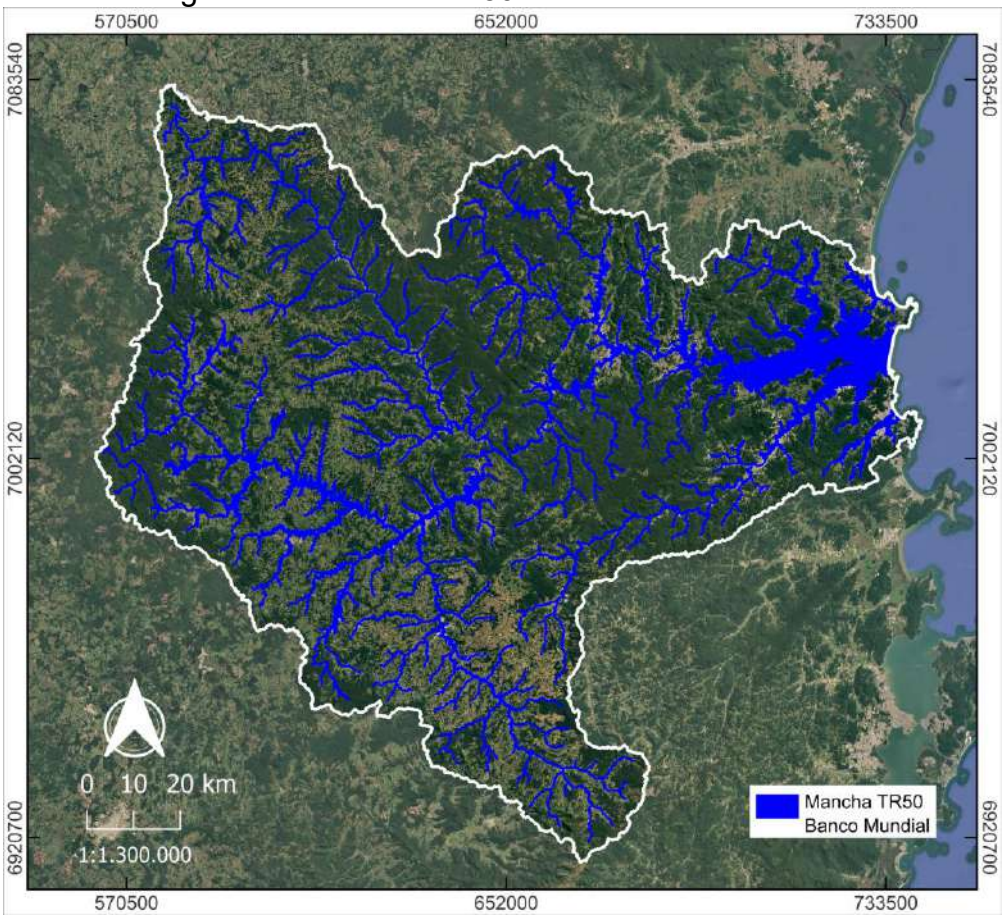
Em função da recorrência de eventos hidrológicos extremos e dos impactos socioeconômicos associados, o governo de Santa Catarina, em parceria com o Banco Mundial, desenvolveu um estudo com o objetivo de estruturar um modelo de catástrofes.

O projeto envolveu a integração de dados geoespaciais e socioeconômicos, incluindo o censo demográfico de 2010, informações sobre uso e ocupação do solo, além de registros hidrometeorológicos, como séries históricas de precipitação e vazões. Essas informações foram incorporadas a um modelo hidrológico, que simulou os hidrogramas dos rios do estado com base na precipitação. Posteriormente, aplicou-se um modelo hidráulico bidimensional para representar o

escoamento superficial sobre áreas urbanas e planícies aluviais, resultando em mapas de inundação para diferentes cenários (Banco Mundial, 2016).

O modelo contempla todo o território catarinense e apresenta três cenários distintos, correspondentes a TRs de 50, 100 e 1000 anos. No presente estudo, foi adotado o cenário de 50 anos como base de referência para a avaliação da coerência dos resultados obtidos com os modelos de aprendizado de máquina. A Figura 12 ilustra a mancha de inundação associada ao tempo de retorno de 50 anos.

Figura 12: Mancha TR 50 anos – Banco Mundial.



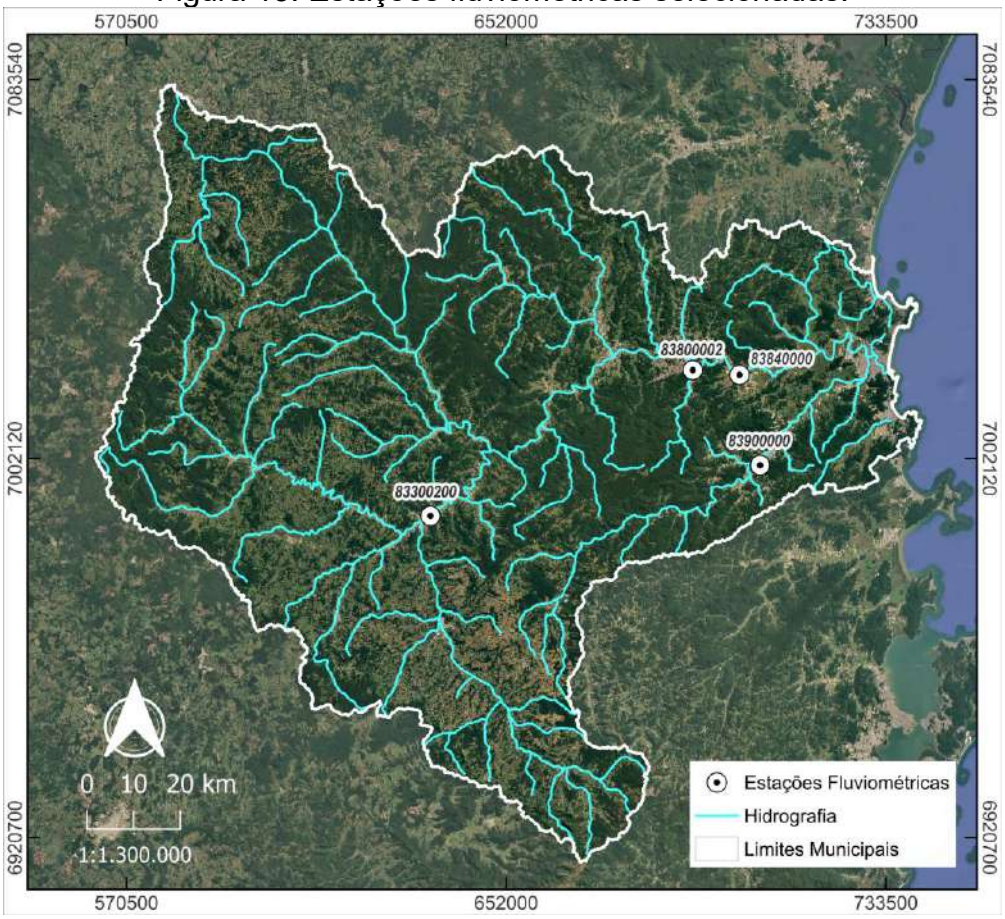
Fonte: O autor (2025).

3.3.2 Análise de Extremos

Com o objetivo de avaliar a compatibilidade entre o resultado gerado pelo algoritmo de aprendizado de máquina e a mancha de inundação do Banco Mundial, foi realizada uma análise de frequência dos eventos máximos anuais de cota, visando à estimativa dos TRs associados. Para essa etapa, foram selecionadas

quatro estações fluviométricas (Figura 13) localizadas nos municípios de Blumenau (83800002), Brusque (83900000), Gaspar (83840000) e Rio do Sul (83300200). O município de Itajaí foi retirado da análise por não dispor de séries históricas com período superior a 30 anos.

Figura 13: Estações fluviométricas selecionadas.



Fonte: O autor (2025).

A seleção dessas localidades se justifica pelo fato de estarem associadas aos eventos que compõem o inventário de inundações utilizado no treinamento e do modelo, assegurando coerência com os dados empregados na modelagem. As séries históricas foram obtidas junto à plataforma Hidroweb (ANA, 2024).

Para cada estação, foram extraídas as cotas máximas anuais de inundação, que serviram de base para a análise de frequência. O ajuste das distribuições estatísticas foi realizado com a distribuição de Gumbel. A partir desse ajuste, foram estimados os níveis de cheia correspondentes a diferentes tempos de retorno (TR = 2, 5, 10, 25, 50 e 100 anos). A função de probabilidade da distribuição de Gumbel é

dada pela Equação (10), onde α é o parâmetro de escala, Equação (11), e β é o parâmetro de posição, Equação (12), funções da média $\bar{x}$ e do desvio padrão δ.

$$f(x) = \frac{1}{\alpha} exp\left[-\frac{x-\beta}{\alpha} - \exp\left(\frac{x-\beta}{\alpha}\right)^2\right] \quad \text{Equação (10)}$$

$$\alpha = \frac{\delta}{1{,}283} \quad \text{Equação (11)}$$

$$\beta = \bar{x} - 0{,}45\delta \quad \text{Equação (12)}$$

3.3.3 Análise Comparativa entre o Mapeamento por Aprendizado de Máquina e Modelo de Referência

Após a definição da mancha de referência e da contextualização da magnitude dos eventos históricos utilizados no inventário de inundações, foi realizada uma análise comparativa entre o mapeamento gerado pelo modelo de aprendizado de máquina e a mancha de inundação de tempo de retorno igual a 50 anos disponibilizada pelo Banco Mundial.

A validação foi realizada a partir da sobreposição direta entre a mancha gerada pelo modelo de aprendizado de máquina e a mancha TR50 do Banco Mundial, com o objetivo de avaliar a coerência espacial entre as fontes. Essa análise permitiu identificar áreas de convergência e de divergência, possibilitando a interpretação da abrangência do modelo de referência frente ao resultado gerado pelo modelo de aprendizado de máquina.

4 RESULTADOS E DISCUSSÃO

4.1 ANÁLISE DOS FATORES CONDICIONANTES DE INUNDAÇÕES

Nesta seção, são apresentadas duas análises preliminares que antecedem a modelagem preditiva, com o objetivo de avaliar a adequabilidade das variáveis ambientais enquanto fatores condicionantes de inundações. A primeira análise permite verificar se as variáveis selecionadas são capazes de distinguir áreas inundadas das não-inundadas. A segunda consiste na avaliação da multicolinearidade, com o intuito de identificar eventuais redundâncias e interdependências entre os fatores condicionantes.

4.1.1 Capacidade de Discriminação dos Fatores Condicionantes

A Figura 14 apresenta a análise da distribuição estatística dos fatores condicionantes em relação às classes de inundação (não-inundado e inundado). A avaliação foi realizada por meio da aplicação do teste de Wilcoxon para comparação entre os grupos.

Observa-se que todos os fatores condicionantes selecionados apresentaram diferenças estatisticamente significativas (p-valor < 0.05), evidenciando sua capacidade de distinguir entre áreas suscetíveis e não suscetíveis à inundação.

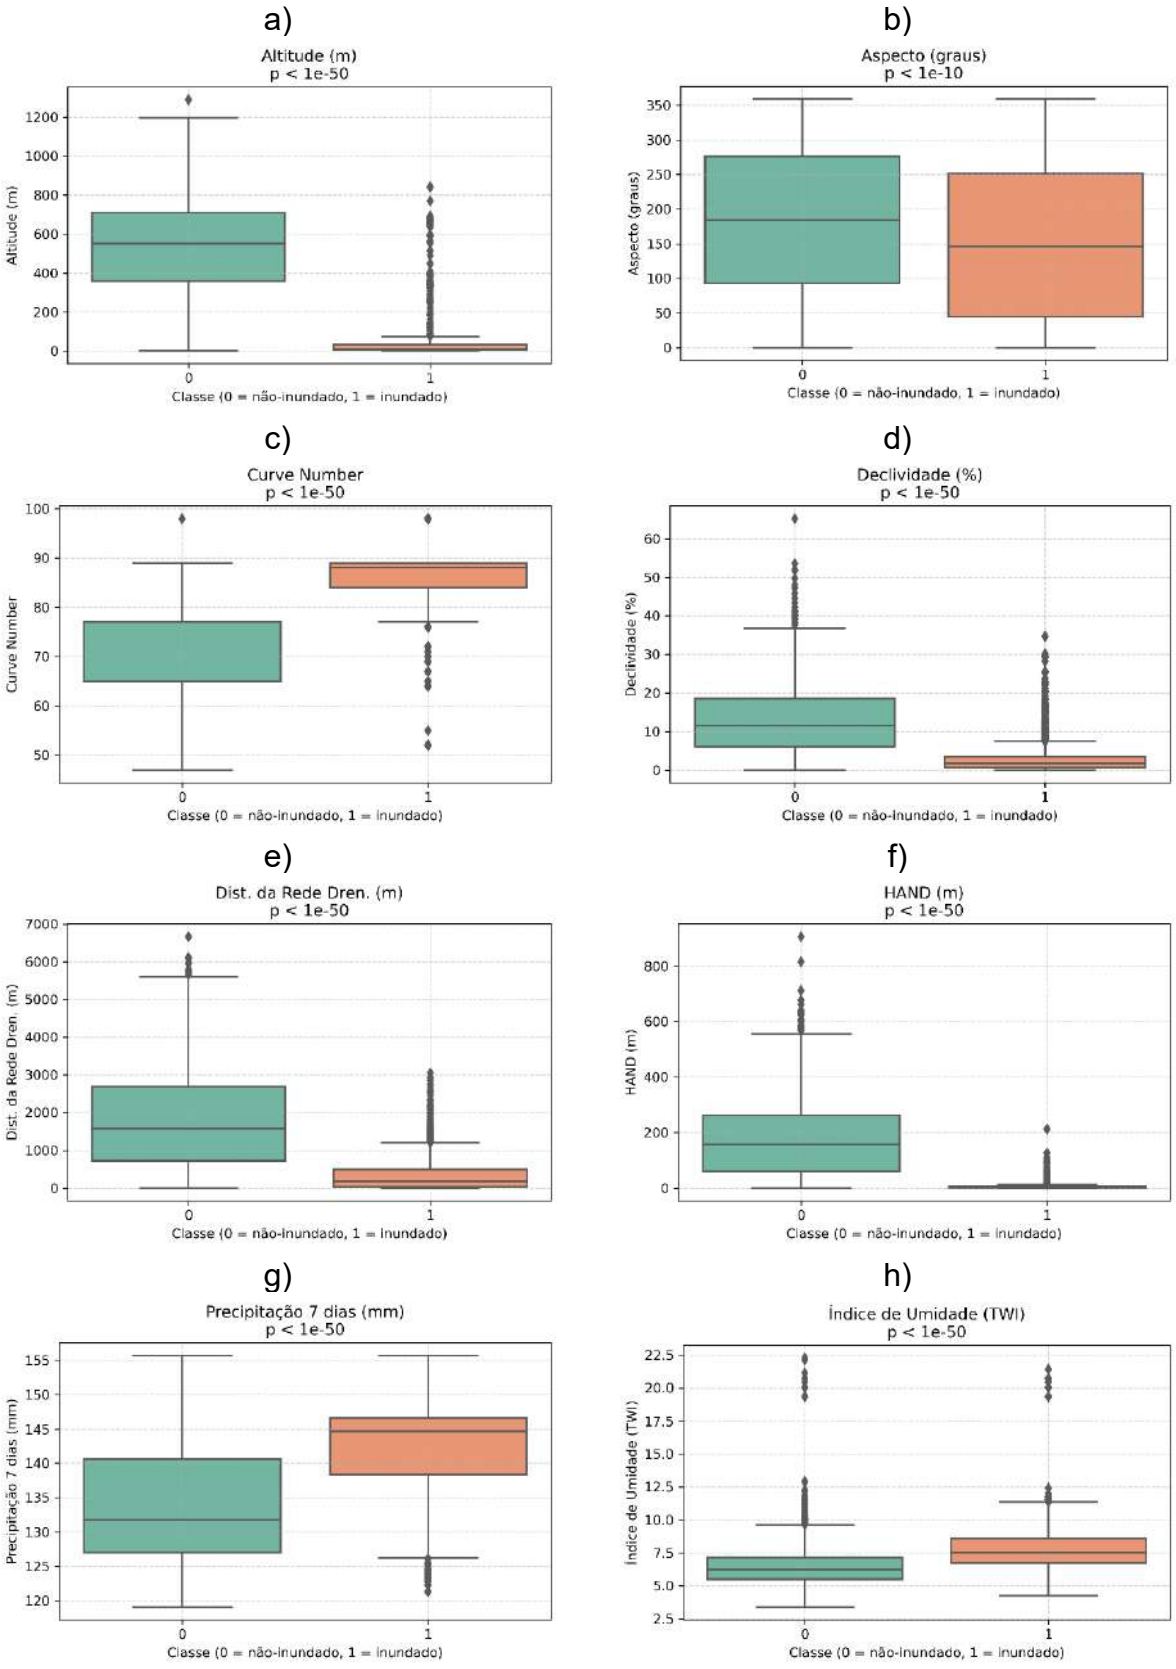
Os fatores HAND, altitude, distância da rede de drenagem e declividade apresentaram valores medianos consideravelmente menores nas áreas inundadas, o que corrobora a tendência esperada de que regiões topograficamente mais baixas e próximas à drenagem principal possuem maior propensão à inundação.

O CN e a média anual da precipitação máxima acumulada em 7 dias apresentaram medianas mais elevadas nas áreas inundadas, sugerindo que condições de maior escoamento superficial e precipitação também contribuem para a ocorrência de inundações.

Já as variáveis TWI e Aspecto demonstraram diferenças mais sutis, mas ainda assim significativas.

Os resultados evidenciam que os fatores condicionantes selecionados têm potencial discriminativo adequado para serem utilizados como preditores na modelagem realizada neste estudo.

Figura 14: Estatísticas *box-plot* dos fatores condicionantes para ocorrência de inundação e não inundação. a) Altitude; b) Aspecto; c) CN; d) Declividade; e) Dist. da Rede de Drenagem; f) HAND; g) Média Anual da Prec. Máx. Acum. (7 dias); h) TWI.



Fonte: O autor (2025).

4.1.2 Análise de Multicolinearidade

A análise da multicolinearidade foi conduzida por meio do cálculo do Fator de Inflação da Variância (VIF) e da Tolerância (TOL). Os resultados estão apresentados na Tabela 3. Também foi elaborada a matriz de correlação (Figura 15), permitindo identificar relações lineares diretas entre os pares de variáveis ambientais consideradas.

Observa-se que a maioria das variáveis apresentou valores de VIF inferiores a 10 e TOL acima de 0,1, indicativos de ausência de multicolinearidade. No entanto, a variável CN apresentou VIF de 11,89 e TOL de 0,084, ultrapassando os limites aceitáveis e indicando uma forte correlação com outras variáveis do conjunto. Esse comportamento também é visível na matriz de correlação, na qual o CN apresenta correlação negativa moderada com Declividade, Altitude e HAND. Além disso, a matriz destaca outras correlações relevantes, como entre Altitude e HAND e entre HAND e Distância da Rede de Drenagem.

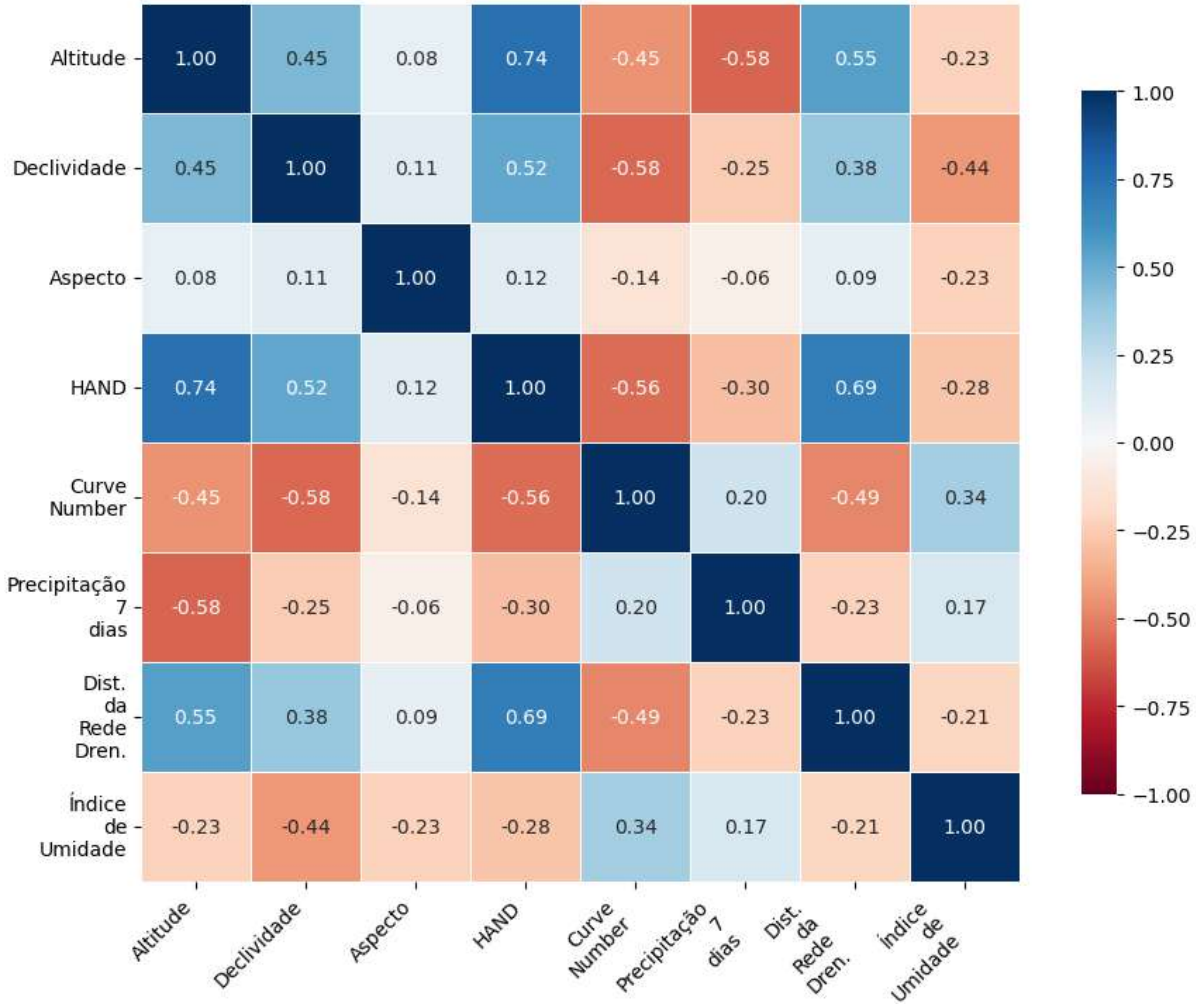
Diante desse resultado, optou-se por remover o CN da etapa de modelagem, com o objetivo de evitar redundância. As demais variáveis foram mantidas.

Tabela 3: Avaliação da multicolinearidade entre os fatores condicionantes.

Fator Condicionante	VIF	TOL
CN	11,89	0,084
Média Anual da Precipitação Máxima Acumulada em 7 Dias (mm)	7,22	0,139
Altitude (m)	6.05	0,165
HAND (m)	5,11	0,196
Índice de Umidade (TWI)	4,16	0,240
Dist. da Rede Dren. (m)	3,44	0,291
Aspecto (graus)	3,37	0,297
Declividade (%)	2,67	0,374

Fonte: O autor (2025)

Figura 15: Matriz de Correlação.



Fonte: O autor (2025)

4.2 AVALIAÇÃO DE DESEMPENHO DOS MODELOS DE APRENDIZADO DE MÁQUINA

Foram avaliados os cinco algoritmos de aprendizado de máquina selecionados no estudo: Adaptive Boosting (AdaBoost), Extreme Gradient Boosting (XGBoost), K-Nearest Neighbors (KNN), Support Vector Machine (SVM) e Random Forest (RF). A avaliação de desempenho considerou as métricas AUC, acurácia, *F1-score*, precisão e *recall*, cujos resultados estão apresentados na Tabela 4.

Com o objetivo de compará-los e apoiar a escolha do modelo mais adequado para o mapeamento de suscetibilidade da bacia hidrográfica do Rio Itajaí, foi calculada a média simples entre as métricas de cada algoritmo. Com base nessa

média, os modelos AdaBoost, XGBoost e Random Forest apresentaram desempenhos semelhantes, seguidos por SVM e KNN.

Diante do empate entre AdaBoost, XGBoost e RF, optou-se por selecionar o Random Forest, por apresentar o maior valor de AUC entre os modelos, indicando melhor capacidade de discriminar corretamente entre áreas suscetíveis e não suscetíveis a inundações.

Nota-se, a robustez dos modelos baseados em árvores de decisão, que obtiveram os melhores desempenhos nas métricas avaliadas. Resultados semelhantes foram obtidos por Demissie et al. (2024), que aplicaram diferentes algoritmos no estado do Kansas e destacaram o desempenho superior do XGBoost e do RF. No Brasil, Amaral, Piroli e Santos (2024) também observaram resultados mais expressivos com o uso do Random Forest em comparação ao SVM. Na Alemanha, Kaiser, Günnemann e Disse (2022) relataram elevado desempenho de modelos baseados em árvores, como RF e GBDT. De forma semelhante, Dey et al. (2024), ao analisarem a região de Tampa Bay, identificaram os algoritmos RF e XGBoost como os mais eficazes na simulação do risco de inundação.

Tabela 4. Desempenho dos algoritmos de aprendizado de máquina no conjunto de teste.

Modelo	AUC	Acurácia	F1-Score	Precisão	Recall	Média
AdaBoost	0,98	0,94	0,94	0,91	0,97	0,95
XGBoost	0,98	0,94	0,94	0,92	0,97	0,95
KNN	0,96	0,92	0,92	0,88	0,96	0,93
SVM	0,97	0,92	0,93	0,88	0,97	0,93
RF	0,99	0,94	0,94	0,92	0,98	0,95

Fonte: O autor (2025).

4.3 MAPEAMENTO DE SUSCETIBILIDADE A INUNDAÇÕES

A partir do modelo Random Forest, selecionado como o de melhor desempenho neste estudo, foi realizado o mapeamento da suscetibilidade a inundações para a Bacia Hidrográfica do Rio Itajaí. A suscetibilidade foi expressa pela probabilidade prevista de cada ponto amostrado ser classificado como área inundada. Para isso, a previsão foi transferida para uma malha de pontos

regularmente espaçados a cada 100 metros ao longo da bacia. Posteriormente, os pontos foram interpolados, permitindo a representação da suscetibilidade.

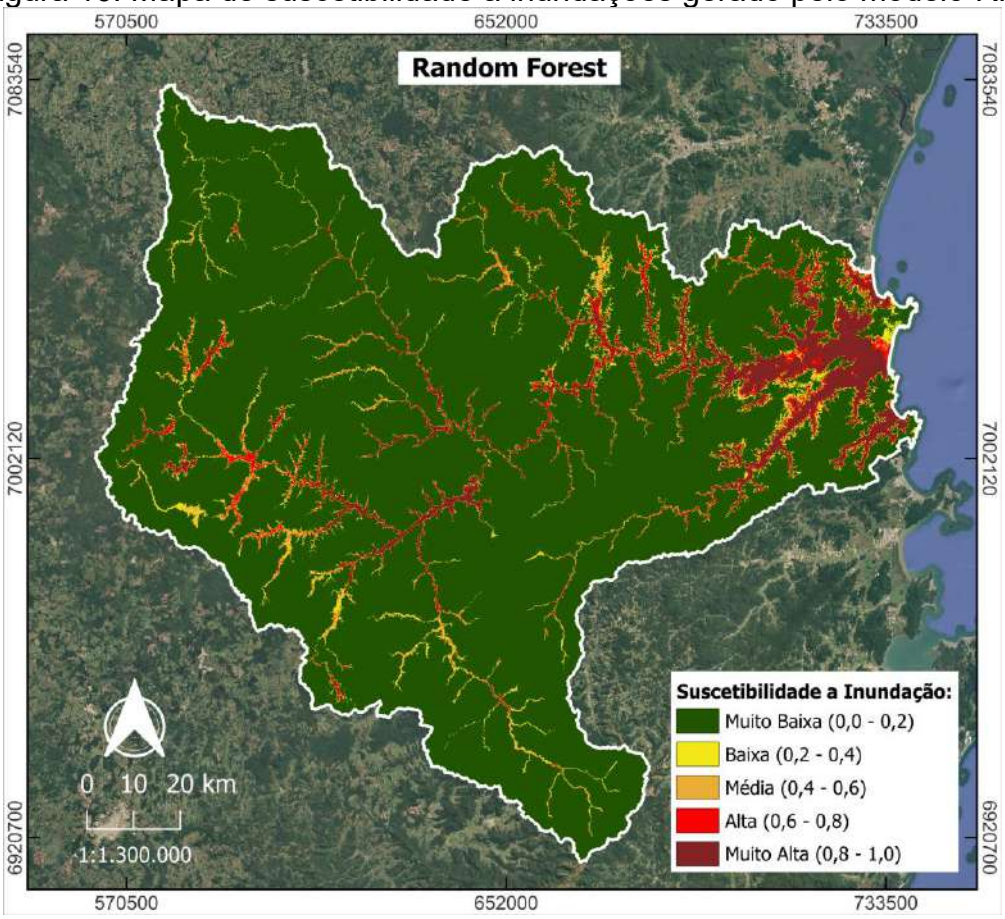
Para fins de visualização, as probabilidades de suscetibilidade à inundação foram reclassificadas em cinco classes ordenadas: Muito Baixa, Baixa, Média, Alta e Muito Alta. A classificação foi realizada por meio de uma divisão simples dos valores de probabilidade em intervalos regulares de 20%, resultando em classes com limites fixos: Muito Baixa (0–0,20), Baixa (0,20–0,40), Média (0,40–0,60), Alta (0,60–0,80) e Muito Alta (0,80–1,00). Essa abordagem direta foi adotada para garantir padronização entre os modelos e facilitar a comparação dos resultados.

A Figura 16 apresenta o mapa de suscetibilidade gerado com o modelo Random Forest. As classes Muito Baixa, Baixa, Média, Alta e Muito Alta representaram, respectivamente, 88,56%, 2,74%, 2,22%, 1,91% e 4,57% da área da bacia, conforme detalhado na Tabela 5. As classes Alta e Muito Alta somam aproximadamente 6,50% da bacia, indicando as regiões com maior risco e maior prioridade para ações de prevenção e gestão de inundações.

De modo geral, observa-se que todos os modelos apresentaram forte predominância da classe Muito Baixa, com valores superiores a 80% da área total. No entanto, a proporção de áreas classificadas como Alta e Muito Alta variou entre os modelos, sendo mais expressiva no SVM (9,42%) e KNN (9,45%), e mais restrita no XGBoost, que concentrou 90,26% da bacia na classe Muito Baixa e apenas 6,25% nas classes superiores.

O mapeamento gerado para os demais algoritmos (AdaBoost, XGBoost, SVM e KNN) estão disponíveis no Apêndice A.

Figura 16: Mapa de suscetibilidade a inundações gerado pelo modelo RF.



Fonte: O autor (2025).

Tabela 5: Distribuição percentual das classes de suscetibilidade a inundações por modelo.

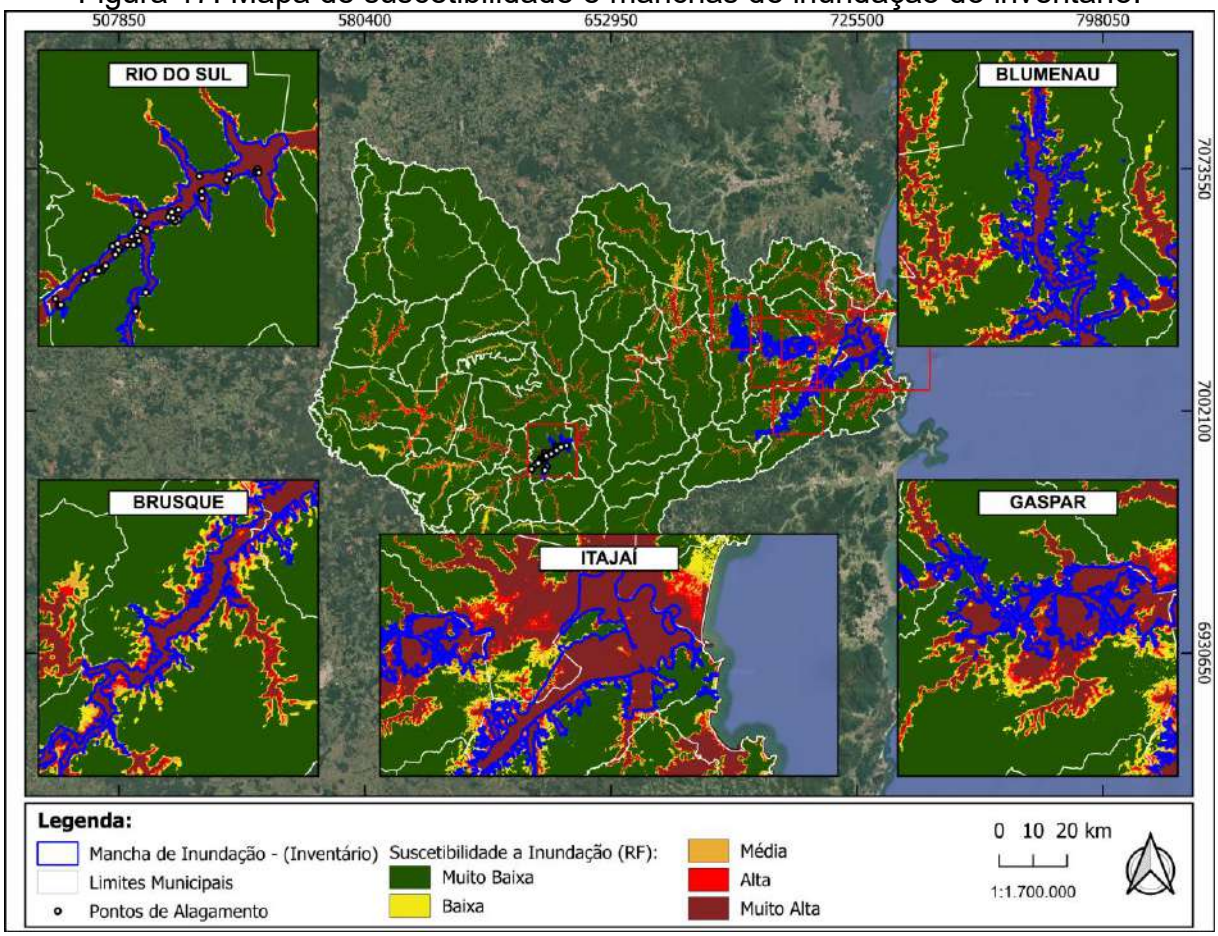
Modelo	Muito Baixa (%)	Baixa (%)	Média (%)	Alta (%)	Muito Alta (%)
AdaBoost	82,96	5,48	3,71	3,52	4,33
KNN	81,80	5,18	3,58	3,61	5,84
RF	88,56	2,74	2,22	1,91	4,57
SVM	81,35	5,48	3,75	3,64	5,78
XGBoost	90,26	1,98	1,50	1,43	4,82

Fonte: O autor (2025).

A fim de verificar a coerência entre o mapeamento gerado pelo modelo RF e os registros históricos utilizados como entrada, foi realizada a sobreposição entre o mapa de suscetibilidade e as manchas de inundação do inventário de eventos. Conforme ilustrado na Figura 17, observa-se uma forte correspondência espacial

entre as áreas classificadas como alta e muito alta suscetibilidade e os locais documentados nos municípios de Itajaí, Rio do Sul, Brusque, Gaspar e Blumenau. É importante destacar que as manchas históricas utilizadas se restringem ao interior dos limites municipais de onde os dados foram obtidos, não abrangendo a totalidade da bacia. Ainda assim, essa convergência reforça a capacidade do modelo em reconhecer os padrões associados à ocorrência de inundações.

Figura 17. Mapa de suscetibilidade e manchas de inundação do inventário.



Fonte: O autor (2025).

4.3.1 Limitações e Recomendações

Ainda que os modelos tenham apresentado desempenho satisfatório, algumas limitações relevantes da metodologia devem ser consideradas. Em primeiro lugar, destaca-se a alta dependência da qualidade e representatividade dos dados utilizados como entrada, em especial os registros históricos de inundações. A ausência de eventos recentes e uma maior cobertura espacial compromete a

robustez da variável resposta e, consequentemente, a capacidade de generalização do modelo. Embora tenha sido utilizado o índice NDWI para a detecção de áreas alagadas, limitações relacionadas à cobertura de nuvens resultaram em um inventário concentrado essencialmente ao longo dos cursos d'água principais, deixando de representar adequadamente áreas alagadas mais difusas.

Outro aspecto a ser considerado refere-se ao processo de interpolação das probabilidades de suscetibilidade para uma malha regular com espaçamento de 100 metros. Essa resolução foi adotada com o intuito de garantir ampla cobertura espacial e viabilizar a representação contínua dos resultados em escala regional. No entanto, tal abordagem pode ter atenuado variações locais mais sutis, potencialmente relevantes para a identificação precisa de áreas suscetíveis a inundações. Cabe destacar que a escolha desse espaçamento também levou em conta limitações computacionais, uma vez que resoluções mais finas demandariam elevado poder de processamento.

Além disso, não foram aplicadas técnicas de validação cruzada durante a fase de avaliação dos modelos, o que pode ter restringido a análise da estabilidade e da robustez dos resultados frente a diferentes subconjuntos de dados. A inclusão desse procedimento em trabalhos futuros pode contribuir para uma avaliação mais abrangente do desempenho dos modelos. Da mesma forma, não foi realizada a otimização dos hiperparâmetros dos algoritmos, sendo utilizados os valores padrão (*default*) de cada modelo.

Outra limitação diz respeito à etapa de espacialização dos resultados. Neste estudo, as probabilidades previstas para os pontos amostrais foram interpoladas para gerar superfícies contínuas. Alternativamente, a aplicação direta dos modelos a um raster multibanda contendo as variáveis preditoras permitiria gerar mapas contínuos de suscetibilidade sem a necessidade de interpolação, reduzindo possíveis distorções espaciais e aumentando a fidelidade das previsões.

Por fim, a metodologia empregada, baseada em algoritmos de classificação, não permite a estimativa direta de parâmetros como nível da água, profundidade de inundação ou velocidade do escoamento. Dessa forma, a análise permanece restrita à estimativa da probabilidade espacial de ocorrência de inundações, sem fornecer informações quantitativas sobre sua magnitude.

4.4 ANÁLISE DE CONTRIBUIÇÃO DOS FATORES CONDICIONANTES – SHAP

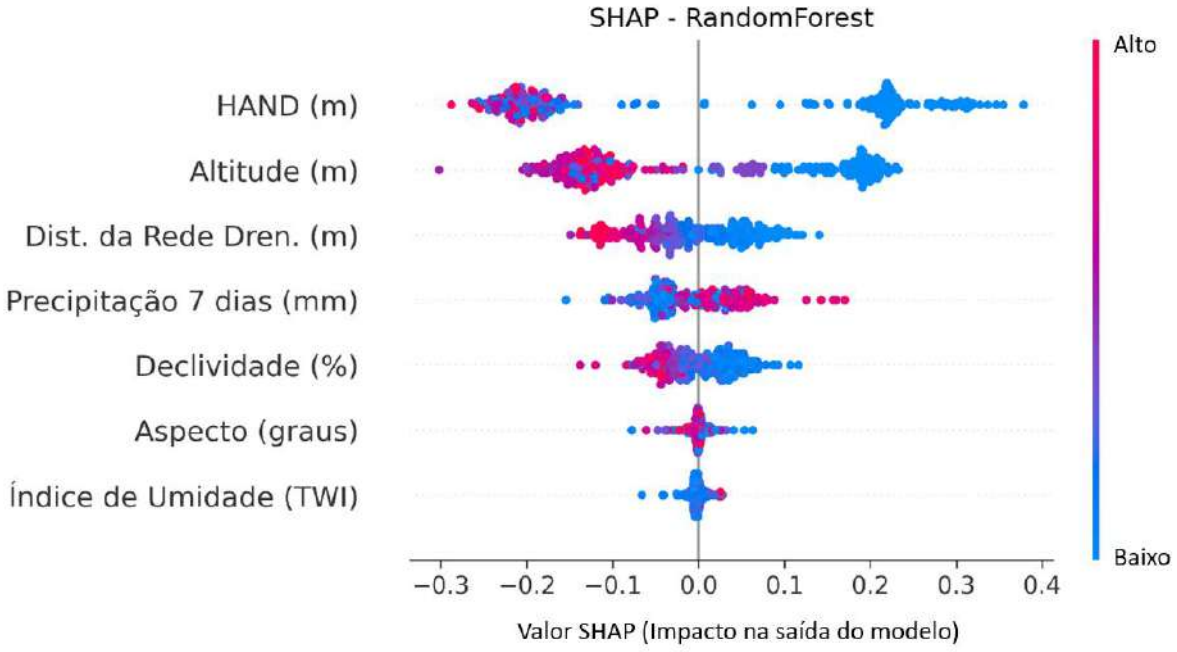
A Figura 18 apresenta a análise SHAP aplicada ao modelo Random Forest. O gráfico evidencia a contribuição individual de cada variável condicionante na predição da suscetibilidade a inundações. As variáveis estão ordenadas de acordo com sua importância relativa no modelo, sendo o HAND a mais influente, seguido por altitude, distância da rede de drenagem e média da precipitação máxima acumulada em sete dias.

Observa-se que valores baixos de HAND e altitude (em azul) estão fortemente associados a um aumento na probabilidade de ocorrência de inundações, indicando que as áreas mais baixas e próximas à rede de drenagem estão mais sujeitas à inundação. A distância da rede de drenagem também se destacou, indicando que valores baixos, ou seja, mais próximos da rede de drenagem, aumentam significativamente a influência positiva na classificação de áreas como suscetíveis.

Variáveis como declividade, aspecto e TWI apresentaram menor impacto relativo, embora ainda contribuam para a decisão do modelo.

Os gráficos de importância SHAP para os demais algoritmos avaliados estão apresentados no Apêndice B.

Figura 18: SHAP para o modelo Random Forest.



Fonte: O autor (2025).

4.5 CORRESPONDÊNCIA COM A MANCHA DE INUNDAÇÃO DO BANCO MUNDIAL

4.5.1 Análise de Extremos

Para contextualizar a magnitude dos eventos que compõem o inventário de inundações utilizado como entrada do modelo, foi realizada uma análise de frequência das cotas máximas anuais de inundação para quatro estações fluviométricas: Blumenau, Brusque, Gaspar e Rio do Sul. Os dados foram ajustados à distribuição de Gumbel, permitindo a estimativa das cotas associadas a diferentes tempos de retorno (Tabela 6). Os gráficos com os ajustes das distribuições de Gumbel estão apresentados no Apêndice C.

Tabela 6: Níveis estimados de cheia (em metros) por tempo de retorno para as estações selecionadas.

Estação	Cidade	TR2	TR5	TR10	TR25	TR50	TR100
83900000	Rio do Sul	7,16	9,07	10,34	11,94	13,12	14,30
83300200	Gaspar	6,29	8,11	9,32	10,85	11,98	13,10
83840000	Brusque	4,51	5,66	6,42	7,37	8,09	8,79
83800002	Blumenau	7,84	10,22	11,80	13,80	15,28	16,75

Fonte: O autor (2025).

Com base nos ajustes pela distribuição de Gumbel, foi realizada a estimativa do TR para cada evento de inundação incluído no inventário (Tabela 1). Para isso, utilizaram-se as cotas máximas observadas em cada ano. A Tabela 7 apresenta, para cada município e ano de evento, a cota máxima registrada e o TR estimado. Os eventos de inundação considerados apresentam tempos de retorno estimados entre 3 e 48 anos.

Tabela 7: Estimativa dos TRs dos eventos utilizados no inventário.

Estação	Cidade	Ano do Evento	Cota Máxima (m)	TR Estimado (anos)
83900000	Rio do Sul	2011	12,33	31

Estação	Cidade	Ano do Evento	Cota Máxima (m)	TR Estimado (anos)
83900000	Rio do Sul	2013	10,31	10
83900000	Rio do Sul	2015	10,58	11
83300200	Gaspar	2011	8,89	08
83840000	Brusque	2011	7,90	42
83800002	Blumenau	1983	15,19	48
83800002	Blumenau	2011	8,85	03
83800002	Blumenau	2013	9,64	04

Fonte: O autor (2025).

4.5.2 Análise Comparativa entre o Mapeamento por Aprendizado de Máquina e Modelo de Referência

A Figura 19 apresenta a comparação entre o mapeamento de suscetibilidade a inundações gerado a partir do modelo Random Forest e a mancha de inundação com tempo de retorno de 50 anos, disponibilizada pelo Banco Mundial. O objetivo da sobreposição é avaliar a coerência entre a abordagem baseada em aprendizado de máquina e o cenário de referência.

Para viabilizar a comparação, o mapa contínuo de probabilidades gerado pelo modelo foi convertido em um mapa binário, no qual foram consideradas como suscetíveis apenas as áreas com probabilidade igual ou superior a 50%. Essa transformação possibilitou a identificação direta das regiões mais propensas à ocorrência de inundações, permitindo a análise de sobreposição com a mancha do Banco Mundial.

É importante destacar que as duas abordagens analisadas possuem finalidades distintas. Enquanto o modelo de aprendizado de máquina representa a suscetibilidade, ou seja, a probabilidade de ocorrência de inundações, a mancha de referência do Banco Mundial representa uma simulação hidráulica específica para o cenário de TR 50 anos, estimando a extensão potencial máxima de inundação para esse evento.

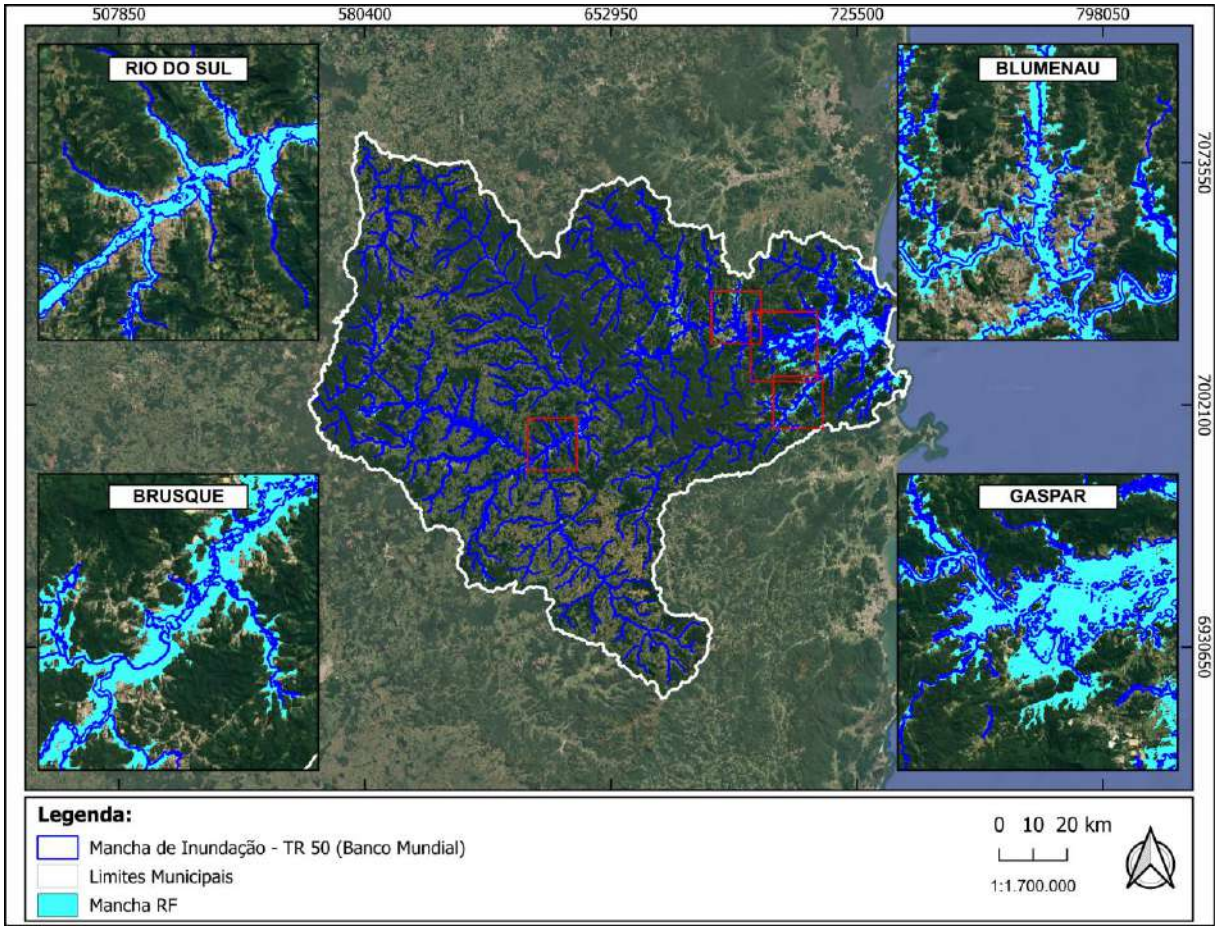
De maneira geral, observa-se uma convergência significativa entre as áreas suscetíveis (≥ 50% de probabilidade) previstas pelo modelo e os trechos mapeados pela mancha de referência nos municípios avaliados.

No entanto, chama atenção o fato de que os eventos de inundação utilizados como entrada no modelo apresentam tempos de retorno estimados inferiores a 50 anos, ou seja, são eventos de menor magnitude em comparação ao cenário TR50. Dessa forma, seria esperado que o mapeamento resultante apresentasse manchas de inundação menos extensas do que aquelas representadas na mancha de referência.

Esse comportamento pode estar associado a dois fatores principais. O primeiro é a capacidade do modelo de generalizar padrões de suscetibilidade com base nas características do terreno e dos fatores condicionantes, mesmo em regiões onde não há registros históricos no inventário. O segundo diz respeito a possíveis limitações da própria mancha de referência, que pode não representar integralmente todas as áreas de risco, subestimando locais suscetíveis a ocorrência desses eventos.

Por outro lado, também foram observadas regiões incluídas na mancha TR50 que não foram identificadas como suscetíveis pelo modelo. Esse tipo de divergência pode estar relacionado à ausência de registros históricos dessas áreas no inventário utilizado como entrada, ou ainda à limitação das variáveis condicionantes consideradas no modelo, que podem não ter captado adequadamente as condições locais responsáveis pela ocorrência das inundações simuladas no cenário de referência. Além disso, o processo de interpolação das probabilidades para uma malha regular com espaçamento de 100 metros pode ter suavizado variações relevantes, dificultando a representação mais precisa de áreas suscetíveis.

Figura 19: Análise comparativa entre o mapeamento gerado pelo RF e pelo Banco Mundial.



Fonte: O autor (2025).

5 CONCLUSÃO

Este trabalho teve como objetivo aplicar diferentes algoritmos de aprendizado de máquina para o mapeamento da suscetibilidade a inundações na Bacia Hidrográfica do Rio Itajaí, combinando dados ambientais derivados de sensoriamento remoto com registros históricos de eventos de inundação.

A adequabilidade e contribuição das variáveis ambientais utilizadas como fatores condicionantes de inundações foram avaliadas. A análise de multicolinearidade indicou que, com exceção do CN, todas os fatores apresentaram valores de VIF e TOL abaixo do limite, sendo mantidas na modelagem. Posteriormente, a aplicação da técnica SHAP permitiu interpretar a contribuição individual de cada variável para o resultado do modelo. Destacaram-se o HAND, a altitude e a declividade como os fatores mais relevantes na determinação da suscetibilidade.

Foram testados cinco modelos supervisionados, Random Forest, XGBoost, AdaBoost, Support Vector Machine e K-Nearest Neighbors, avaliados por meio das métricas de desempenho como AUC, acurácia, *F1-score*, precisão e *recall*. A análise revelou desempenhos equivalentes entre os modelos baseados em árvores, com o Random Forest selecionado para as etapas finais de análise e mapeamento por apresentar a maior AUC. Aproximadamente 6,50% da área da bacia foi classificada como de Alta ou Muito Alta suscetibilidade. Adicionalmente, foi realizada a sobreposição com as manchas utilizadas como entrada no modelo, o que demonstrou forte correspondência.

Foi avaliada a correspondência do mapa gerado com a mancha de inundação com tempo de retorno de 50 anos, disponibilizada pelo Banco Mundial. A análise evidenciou uma significativa sobreposição entre as áreas classificadas como de alta suscetibilidade e os trechos inundáveis previstos pela mancha de referência, indicando coerência entre as abordagens. No entanto, considerando que os eventos utilizados para treinar o modelo apresentaram TRs menores que 50 anos, seria esperado que as manchas de inundação geradas fossem mais restritas. A abrangência observada pode ser explicada tanto pela capacidade de generalização do modelo quanto por possíveis limitações da própria mancha de referência.

Com base nos resultados e limitações identificadas neste estudo, recomenda-se que pesquisas futuras ampliem a base de dados de eventos de inundação,

incorporando registros mais recentes e detalhados. A utilização de imagens de radar, como as obtidas por sensores, pode contornar as limitações associadas à cobertura de nuvens e contribuir para a construção de um inventário mais robusto, capaz de captar de forma mais eficaz eventos extremos e áreas alagadas. Adicionalmente, sugere-se que os modelos sejam aplicados diretamente sobre rasters multibanda contendo as variáveis preditoras, em vez de interpolar os resultados de pontos, o que pode aprimorar a fidelidade espacial dos mapas gerados. Recomenda-se ainda a aplicação de validação cruzada para uma avaliação mais robusta do desempenho dos modelos, bem como a otimização dos hiperparâmetros, a fim de explorar ao máximo o potencial preditivo de cada algoritmo.

Os resultados reforçam o potencial do aprendizado de máquina como ferramenta de apoio ao mapeamento de suscetibilidade a inundações, servindo como subsídio ao planejamento territorial e à formulação de políticas públicas voltadas à prevenção. Além disso, a abordagem empregada demonstrou capacidade de lidar com áreas de estudo naturalmente heterogêneas e extensas, mesmo diante de conjuntos de dados limitados, viabilizando a geração de mapas de suscetibilidade em escala regional.

REFERÊNCIAS

ALVES, M. P. A. **Análise comparativa dos fatores ambientais nos eventos de inundações na bacia hidrográfica do Vale do Itajaí: novembro de 2008 e setembro de 2011**. 2013. 160 p. Trabalho de Conclusão de Curso (Graduação em Geografia) – Universidade Federal de Santa Catarina, Florianópolis, 2013. Disponível em: http://www.labclima.ufsc.br/files/2010/04/An%C3%A1lise-comparativa-dos-fatores-ambientais-nos-eventos-de-inunda%C3%A7%C3%B5es-na-bacia-hidrogr%C3%A1fica-do-Vale-do-Itaja%C3%AD-novembro-de-2008-e-setembro-de-2011.pdf. Acesso em: fev. 2025.

ALVES, M.; FAN, F.; PAIVA, R. C. D.; SIQUEIRA, V.; FLEISCHMANN, A.; BREDA, J.; LAIPELT, L.; ARAUJO, A. Assessing the capacity of large-scale hydrologic-hydrodynamic models for mapping flood hazard in southern Brazil. **Revista Brasileira de Recursos Hídricos (RBRH)**, v. 27, 2022. Disponível em: https://doi.org/10.1590/2318-0331.272220220009. Acesso em: mar. 2025.

AMARAL, F. H. F. do; PIROLI, E. L.; SANTOS, V. C. Mapeamento da suscetibilidade à inundação usando os modelos Floresta Aleatória e Máquina Vetor de Suporte com diferentes tipos de kernel. **Revista do Departamento de Geografia**, São Paulo, v. 44, e213348, 2024. DOI: https://doi.org/10.11606/eISSN.2236-2878.rdg.2024.213348. Acesso em: mar. 2025.

ANA - Agência Nacional de Águas e Saneamento Básico. Curva Número na Base Ottocodificada (1985, 2014 e 2022). Brasília: ANA, 2024. Disponível em: https://metadados.snirh.gov.br/geonetwork/srv/api/records/d1c36d85-a9d5-4f6a-85f7-71c2dc801a67. Acesso em: jan. 2025.

ANA – Agência Nacional de Águas e Saneamento Básico. Brasília: ANA, 2024. Hidroweb. Disponível em: https://www.snirh.gov.br/hidroweb. Acesso em: jun. 2024.

BANCO MUNDIAL. **Santa Catarina: A gestão de riscos de desastres no contexto do planejamento estratégico para o aumento da resiliência a perigos naturais.** Washington: Banco Mundial, 2016. Disponível em: <https://documents1.worldbank.org/curated/en/625351496862211155/pdf/115244-WP-OUO-9-PORTUGESE-disasters.pdf>. Acesso em mar. 2025.

BARTOS, M. **Pysheds**. Disponível em: https://github.com/mdbartos/pysheds. Acesso em: out. 2024.

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. DOI: 10.1023/A:1010933404324. Disponível em: https://doi.org/10.1023/A:1010933404324. Acesso em: abr. 2025.

CANHOLI, A. P. Drenagem urbana e controle de enchentes. 2. ed. São Paulo: Oficina de Textos, 2015.

CARMO, J. S. A. Physical modelling vs. numerical modelling: complementarity and learning. Preprints, [S. l.], 2020. v. 1. Disponível em: https://doi.org/10.20944/preprints202007.0753.v1. Acesso em: mar. 2025.

CASAGRANDE, L. **Previsão de cheias na bacia hidrográfica do rio Itajaí-Açu, SC, usando previsão numérica de tempo e modelagem hidrológica**. 2015. 150 p. Tese (Doutorado em Ciência do Sistema Terrestre) – Instituto Nacional de Pesquisas Espaciais (INPE), São José dos Campos, 2015. Disponível em: http://mtc-m21b.sid.inpe.br/col/sid.inpe.br/mtc-m21b/2015/11.09.20.47/doc/publicacao.pdf. Acesso em. fev. 2025.

CEPED/UFSC - Centro Universitário de Estudos e Pesquisas dobre Desastres. Atlas Digital de Desastres no Brasil. Brasília: Ministério da Integração e do Desenvolvimento Regional, 2025. Disponível em: https://atlasdigital.mdr.gov.br/paginas/index.xhtml. Acesso em: mar. 2025.

CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. In: ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 22., 2016, San Francisco. Proceedings. New York: ACM, 2016. p. 785–794. Disponível em: https://dl.acm.org/doi/10.1145/2939672.2939785. Acesso em: Abr. 2025.

CORRÊA, D. D. **Mapeamento de risco de inundação na Bacia Hidrográfica do Rio Itajaí utilizando descritor de terreno e aspectos socioeconômicos**. 2022. 67 p. Trabalho de Conclusão de Curso (Bacharelado em Engenharia Sanitária e Ambiental) - Universidade Federal de Santa Catarina, Florianópolis, 2022. Disponível em: https://mobile.repositorio.ufsc.br/xmlui/handle/123456789/236908?show=full. Acesso em. set. 2024.

CORTES C, VAPNIG V (1995) Support-vector networks. **Machine Learning** Volume 20:273–297. Disponível em: https://doi.org/10.1007/BF00994018. Acesso em: abr. 2025

DEMISSIE, Z.; RIMAL, P.; SEYOUM, W. M.; DUTTA, A.; RIMMINGTON, G. Flood susceptibility mapping: integrating machine learning and GIS for enhanced risk assessment. **Applied Computing and Geosciences**, [S. l.], v. 23, 100183, 2024. Disponível em: https://www.sciencedirect.com/science/article/pii/S2590197424000302. Acesso em: mar. 2025.

DEY, H.; HAQUE, M. M.; SHAO, W.; VANDYKE, M.; HAO, F. Simulating flood risk in Tampa Bay using a machine learning driven approach. **npj Natural Hazards**, v. 1, art. 40, 2024. Disponível em: https://www.nature.com/articles/s44304-024-00045-4. Acesso em: mar. 2025.

DORMANN, C. F.; ELITH, J.; BACHER, S.; CARRÉ, G. C. G.; GARCÍA MÁRQUEZ, J. R.; GRUBER, B.; LAFOURCADE, B.; LEITAO, P. J.; MÜNKEMÜLLER, T.; MCCLEAN, C. J.; OSBORNE, P. E.; RENEKING, B.; SCHRÖDER, B.; SKIDMORE, A. K.; ZURELL, D.; LAUTENBACH, S. Collinearity. a review of methods to deal with it and a simulation study evaluating their performance: open access. **Ecography**. v.*36*, 27-46, 2013. DOI:10.1111/j.1600-0587.2012.07348.x. Disponível em:

https://nsojournals.onlinelibrary.wiley.com/doi/10.1111/j.1600-0587.2012.07348.x. Acesso em: jun. 2025.

FLEISCHMANN, A.; PAIVA, R.; COLLISCHONN, W. Can regional to continental river hydrodynamic models be locally relevant? A cross-scale comparison. **Journal of Hydrology**, v. 3, 100027, 2019. disponível em: https://www.sciencedirect.com/science/article/pii/S2589915519300112.100027. Acesso em: fev. 2025.

FREUND, Y.; SCHAPIRE, R. E. A decision-theoretic generalization of on-line learning and an application to boosting. **Journal of Computer and System Sciences**, v. 55, p. 119–139, 1997. Disponível em: https://www.sciencedirect.com/science/article/pii/S002200009791504X. Acesso em: mai. 2025.

FUNK, C.; PETERSON, P.; LANDSFELD, M.; PEDREROS, D.; VERDIN, J.; SHUKLA, S.; HUSAK, G.; ROWLAND, J.; HARRISON, L.; HOELL, A.; MICHAELSEN, J. The climate hazards infrared precipitation with stations — a new environmental record for monitoring extremes. **Scientific Data**, v. 2, 150066, 2015. DOI: 10.1038/sdata.2015.66. Disponível em: https://www.nature.com/articles/sdata201566. Acesso em: jan. 2025.

GÉRON, A. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: concepts, tools, and techniques to build intelligent systems. 2. ed. Sebastopol: O'Reilly Media, 2019.

GOERL, R. F.; KOBIYAMA, M; PELLERIN, J. R. G. M. Proposta metodológica para mapeamento de áreas de risco a inundação: estudo de caso do município de Rio Negrinho SC. **Boletim de Geografia**. Maringá. v. 30, n. 1, p. 81-100, 2012. Disponível em: https://periodicos.uem.br/ojs/index.php/BolGeogr/article/view/13519/9407. Acesso em: mar. 2025.

IBGE - INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. **Censo Demográfico 2022.**

IBM. K-Nearest Neighbors (KNN). IBM Brasil, 2025a. Disponível em: https://www.ibm.com/br-pt/think/topics/knn. Acesso em: mai. 2025.

IBM. Support Vector Machines (SVM). IBM Brasil, 2025b. Disponível em: https://www.ibm.com/br-pt/think/topics/support-vector-machine . Acesso em: mai. 2025.

JAHANBANI, M.; VAHIDNIA, M. H.; AGHAMOHAMMADI, H.; AZIZI, Z. Flood susceptibility mapping through geoinformatics and ensemble learning methods, with an emphasis on the AdaBoost–Decision Tree algorithm, in Mazandaran, Iran. **Earth Sci. Inform.**, v. 17, p. 1433–1457, 15 jan. 2024. Disponível em: https://link.springer.com/article/10.1007/s12145-023-01213-2#ref-CR40. Acesso em: jun. 2025.

JORDAN, M. I.; MITCHELL, T. M. Machine learning: Trends, perspectives, and prospects. **Science**, v. 349, n. 6245, p. 255–260, 2015. Disponível em: https://www.cs.cmu.edu/~tom/pubs/Science-ML-2015.pdf. Acesso em: mar. 2025.

JI, J.; CHOI, C.; YU, M.; YI, J. Comparison of a data-driven model and a physical model for flood forecasting. **WIT Transactions on Ecology and the Environment**, Southampton, v. 159, p. 133–141, 2012. DOI: 10.2495/FRIAR120111.Disponível em: https://www.witpress.com/elibrary/wit-transactions-on-ecology-and-the-environment/159/23357. Acesso em: jun. 2025.

KAISER, M.; GÜNNEMANN, S.; DISSE, M. Regional-scale prediction of pluvial and flash flood susceptible areas using tree-based classifiers. **Journal of Hydrology**, v. 612, Part A, 128088, 2022. disponível em: https://doi.org/10.1016/j.jhydrol.2022.128088. acesso em: mar. 2025.

KUCHINSKI, V.; PAIVA, R. C. D. Análise comparativa de modelos de aprendizado de máquina para mapeamento de inundações. In: SIMPÓSIO BRASILEIRO DE RECURSOS HÍDRICOS, 25., 2023, Aracaju. *Anais* [...]. ABRHidro, 2023. Disponível em: https://anais.abrhidro.org.br/job.php?Job=15186. Acesso em: mar. 2025.

LANTZ, B. Machine learning with R: learn how to use R to apply powerful machine learning methods and gain an insight into real-world applications. Birmingham: Packt Pub Ltd, 2013. 375 p. ISBN 978-1782162148.

MA, M.; ZHAO, G.; HE, B.; LI, Q.; DONG, H.; WANG, S.; WANG, Z. XGBoost-based method for flash flood risk assessment. **Journal of Hydrology**, v. 598, 126382, 2021. Disponível em: https://www.sciencedirect.com/science/article/pii/S0022169421004297. Acesso em mai. 2025.

MEHMOOD, H.; CONWAY, C.; PERERA, D. Mapping of Flood Areas Using Landsat with Google Earth Engine Cloud Platform. **Atmosphere**, 12, 866. 2021. Disponível em: https://doi.org/10.3390/atmos12070866. Acesso em: mar. 2025.

MUDASHIRU, R.B., SABTU, N., ABUSTAN, I., BALOGUN, W., 2021. Flood hazard mapping methods: A review. **Journal of Hydrology**, v. 603, 126846. Disponível em: https://doi.org/10.1016/j.jhydrol.2021.126846. Acesso em: mar. 2025.

RENNÓ, C. D. et al. HAND, a new terrain descriptor using SRTM-DEM: Mapping terra-firme rainforest environments in Amazonia. Remote Sensing of Environment, v. 112, n. 9, p. 3469–3481, 2008. ISSN 0034-4257. Disponível em: https://www.sciencedirect.com/science/article/pii/S003442570800120X. Acesso em: jan. 2025.

RODRIGUES, S. G. **Mapeamento de perigo de deslizamentos de terra e inundações: proposição de abordagem utilizando processamento de linguagem natural e aprendizado de máquina.** 2020. 137 p. Dissertação (Mestrado em Engenharia de Produção) – Universidade Federal de Pernambuco, Centro Acadêmico do Agreste, Caruaru, 2020. Disponível em: https://repositorio.ufpe.br/handle/123456789/37813. Acesso em mar. 2025.

SAMUEL, A. L. Some studies in machine learning using the game of checkers. **IBM Journal of Research and Development**, v. 3, n. 3, p. 601–617, 1959. Disponível em: https://www.cs.virginia.edu/~evans/greatworks/samuel.pdf. Acesso em: mar. 2025.

SANTA CATARINA. Secretaria de Estado do Desenvolvimento Sustentável e Meio Ambiente. **Plano Estadual de Recursos Hídricos de Santa Catarina (PERH/SC)**. Florianópolis, 2018. Disponível em: <https://www.aguas.sc.gov.br/jsmallfib_top/DHRI/Plano%20Estadual/Documento%20Sintese/documento_sintese_do_plano_2018-03-15.pdf >. Acesso em: jun. 2025.

SARTORI, A.; LOMBARDI, N. F.; GENOVEZ, A. M. Classificação hidrológica de solos brasileiros para a estimativa da chuva excedente com o método do Serviço de Conservação do Solo dos Estados Unidos: parte 1: classificação. **Revista Brasileira de Recursos Hídricos**, v. 10, n. 4, p. 5–18, 2005. Disponível em: https://biblat.unam.mx/hevila/RBRHRevistabrasileiraderecursoshidricos/2005/vol10/no4/1.pdf. Acesso em: jan. 2025.

SCIKIT-LEARN. **Scikit-learn**. Disponível em: https://scikit-learn.org/stable/. Acesso em: jan. 2025.

SELEEM, O.; AYZEL, G.; SOUZA, A. C. T.; BRONSTERT, A.; HEISTERMANN, M. Towards urban flood susceptibility mapping using data-driven models in Berlin, Germany. **Geomatics, Natural Hazards and Risk**, v. 13, n. 1, p. 1640–1662, 2022. Disponível em: https://doi.org/10.1080/19475705.2022.2097131. Acesso em: mar. 2025.

SENGER, G. **Mapeamento de mancha de inundação no Vale do Itajaí: uma comparação entre os métodos HAND e AHP**. 2021.114 p. Dissertação (Mestrado em Desastres Naturais) – Universidade Federal de Santa Catarina, Florianópolis, 2021. Disponível em: https://repositorio.ufsc.br/handle/123456789/231065. Acesso em: fev. 2025.

SHALEV-SHWARTZ, S; BEN-DAVID, S. Understanding machine learning. Cambridge: Cambridge University Press, 2014. 414 p. ISBN 978-1107057135.

SHINDE, P. P.; SHAH, S. A review of machine learning and deep learning applications. Fourth International Conference on Computing Communication Control and Automation (ICCUBEA), 2018, Pune, Índia. Disponível em: https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=8697857. Acesso em: mar. 2025.

SOUZA, J. V. B. **Uso de descritores de terreno para o mapeamento de áreas suscetíveis à inundação**. 2021. 93 p. Dissertação (Mestrado em Engenharia Ambiental) – Universidade Federal de Santa Catarina, Florianópolis, 2021. Disponível em: https://www.labhidro.ufsc.br/Artigos/Dissertacao_Jose_Vinicius_Boing_de_Souza.pdf . Acesso em: set. 2024.

SOUZA, J. V. B. **Descriptools**. Disponível em: https://github.com/JVBSouza/descriptools. Acesso em: out. 2024.

SPECKHANN, G. A. **Uma proposta de mapeamento de risco de inundação na bacia do Rio Itajaí utilizando descritores de terreno**. 2018. 92 p. Dissertação (Mestrado em Engenharia Ambiental) – Universidade Federal de Santa Catarina, Florianópolis, 2018. Disponível em: https://repositorio.ufsc.br/handle/123456789/192967. Acesso em: set. 2024.

TENG, J.; JAKEMAN, A. J.; VAZE, J.; CROKE, B. F. W.; DUTTA, D.; KIM, S. Flood inundation modelling: A review of methods, recent advances and uncertainty analysis. **Environmental Modelling Software**, v. 90, p. 201–216, 2017. Disponível em: https://www.sciencedirect.com/science/article/pii/S1364815216310040. Acesso em: abr. 2025.

TUCCI, C E. M. Inundações Urbanas. 2. ed. Porto Alegre: ABRH, 2007.

UNISDR - United Nations International Strategy for Disaster. Making Development Sustainable: The Future of Disaster Risk Management. Global Assessment Report on Disaster Risk Reduction. Geneva, Switzerland: UNISDR, 2015. Disponível em: https://www.undrr.org/publication/global-assessment-report-disaster-risk-reduction-2015. Acesso em: mar. 2025

U.S. ARMY CORPS OF ENGINEERS. *HEC-RAS River Analysis System: Hydraulic Reference Manual*. Davis, CA: Hydrologic Engineering Center, 2016.

USGS - United States Geological Survey. Shuttle Radar Topography Mission (SRTM) 1 Arc-Second Global. 2016. Disponível em: https://earthexplorer.usgs.gov/. Acesso em: set. 2024.

WAHBA, M.; ESSAM, R.; EL-RAWY, M.; AL-ARIFI, N.; ABDALLA, F.; ELSADEK, W. M. Forecasting of flash flood susceptibility mapping using random forest regression model and geographic information systems. **Heliyon**, v. 10, n. 13, e33982, 2024. DOI: 10.1016/j.heliyon.2024.e33982. Disponível em: https://doi.org/10.1016/j.heliyon.2024.e33982. Acesso em: abr. 2025.

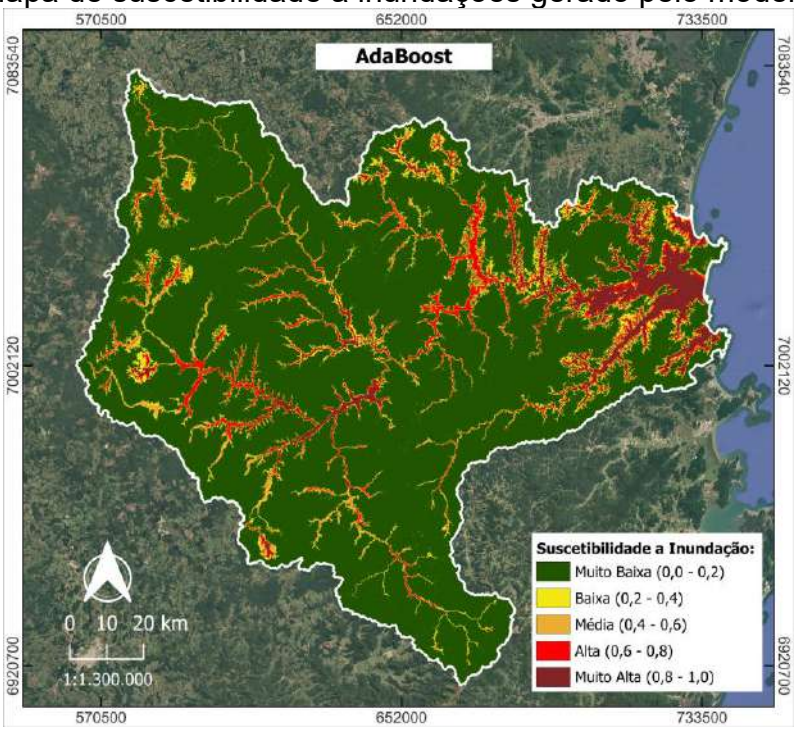
WANG, Y.; HONG, H.; CHEN, W.; LI, S.; PAMUČAR, D.; GIGOVIĆ, L.; DROBNJAK, S.; BUI, D. T.; DUAN, H. A GIS-based multi-criteria decision-making approach for flood susceptibility mapping in Shangyou, China. **Remote Sensing**, v. 11, n. 1, p. 62, 2019. DOI: 10.3390/rs11010062. Disponível em: https://www.mdpi.com/2072-4292/11/1/62. Acesso em: abr. 2025.

WINSEMIUS, Hessel C. et al. Global drivers of future river flood risk. **Nature Climate Change**, v. 6, n. 4, p. 381-385, 2016. Disponível em: https://www.nature.com/articles/nclimate2893.pdf. Acesso em: mar. 2025.

XGBOOST. **XGBoost**. Disponível em: https://xgboost.readthedocs.io/en/stable/. Acesso em: jan. 2025.

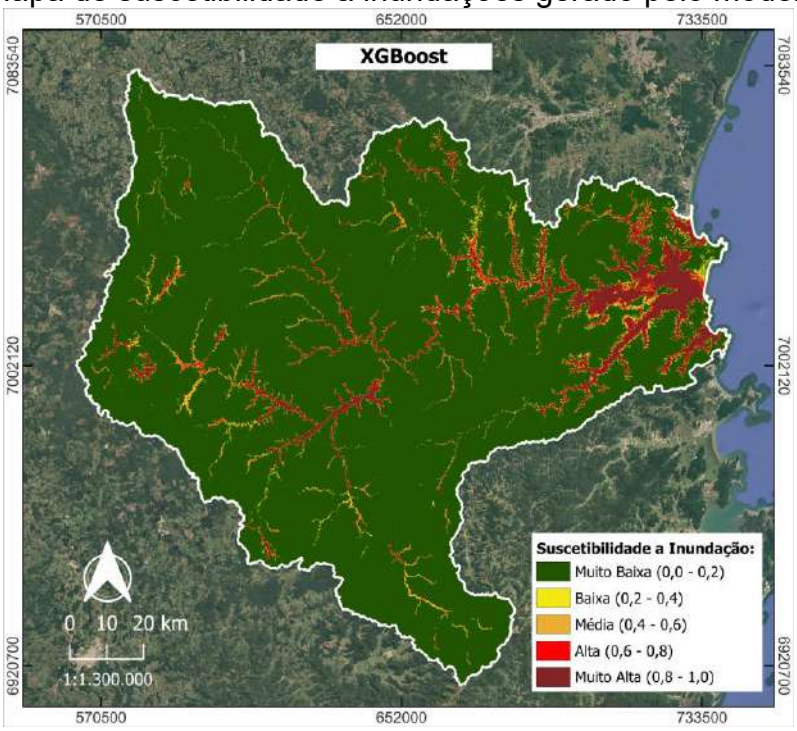
APÊNDICE A – MAPAS DE SUSCETIBILIDADE GERADOS PELOS MODELOS AVALIADOS NO ESTUDO

Figura 20: Mapa de suscetibilidade a inundações gerado pelo modelo AdaBoost.



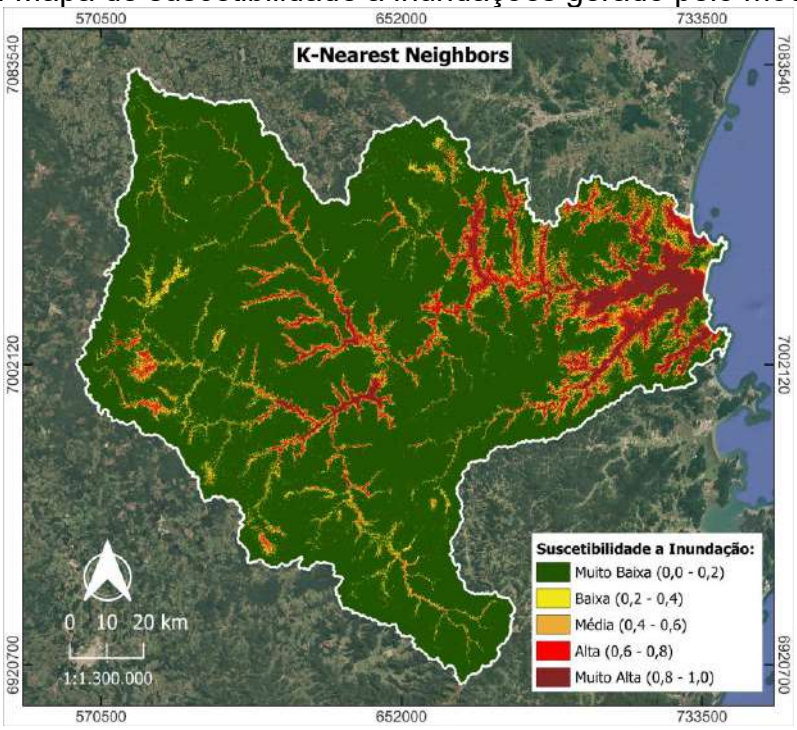
Fonte: O autor (2025).

Figura 21: Mapa de suscetibilidade a inundações gerado pelo modelo XGBoost.



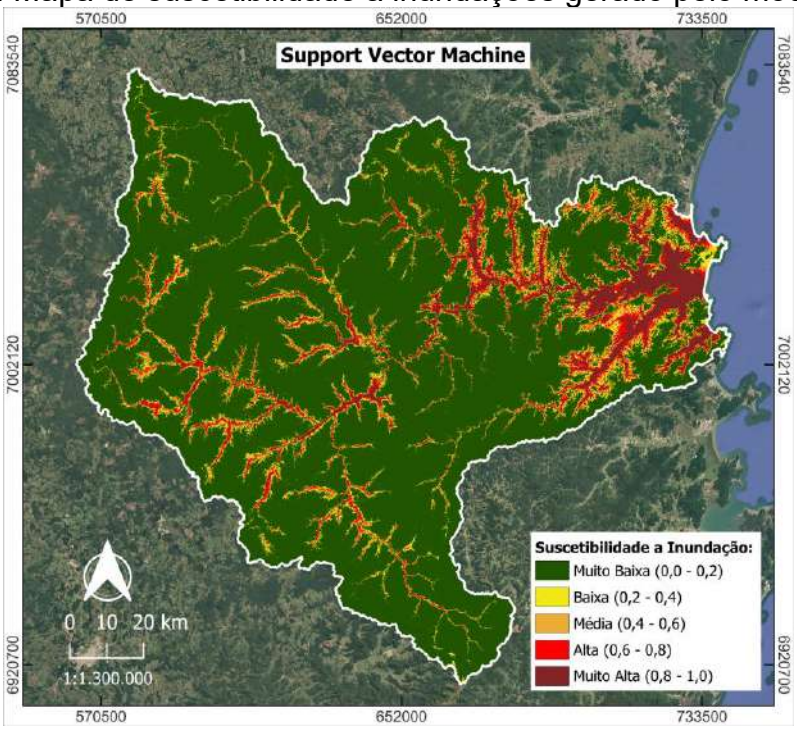
Fonte: O autor (2025).

Figura 22: Mapa de suscetibilidade a inundações gerado pelo modelo KNN.



Fonte: O autor (2025).

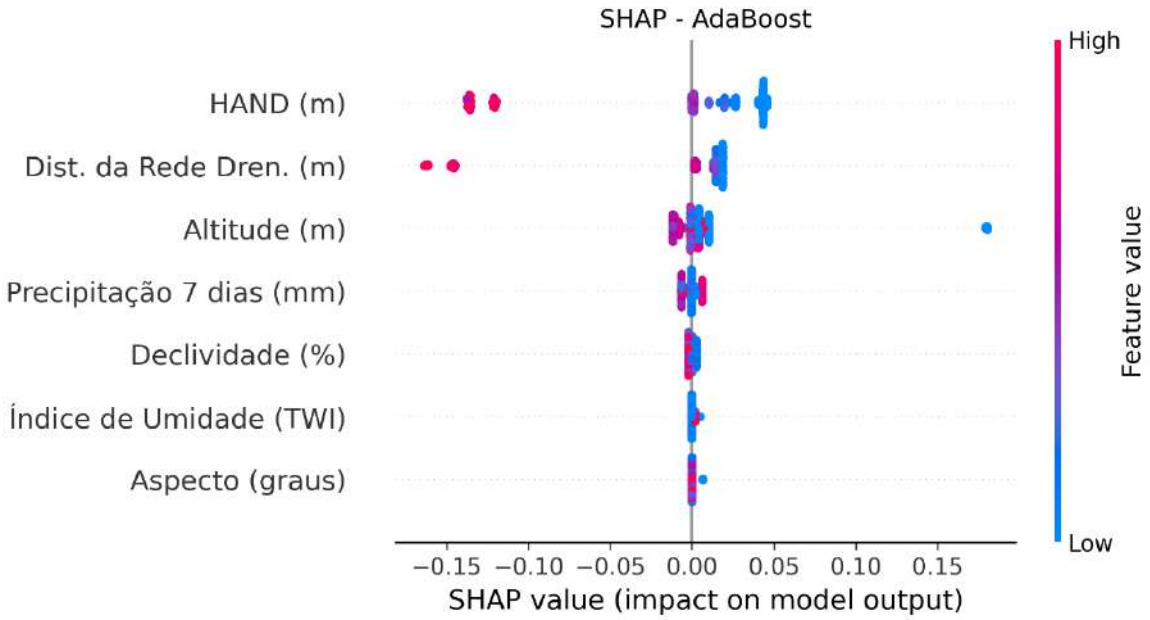
Figura 23: Mapa de suscetibilidade a inundações gerado pelo modelo SVM.



Fonte: O autor (2025).

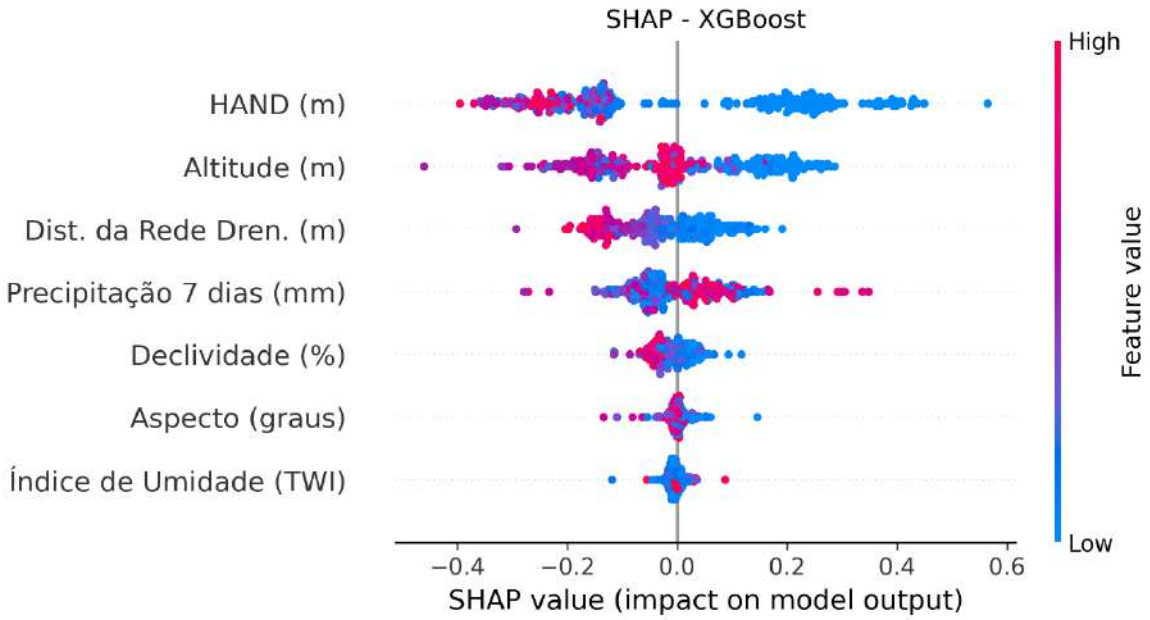
APÊNDICE B – ANÁLISE DE CONTRIBUIÇÃO DOS FATORES CONDICIONANTES - SHAP

Figura 24: SHAP para o modelo AdaBoost.



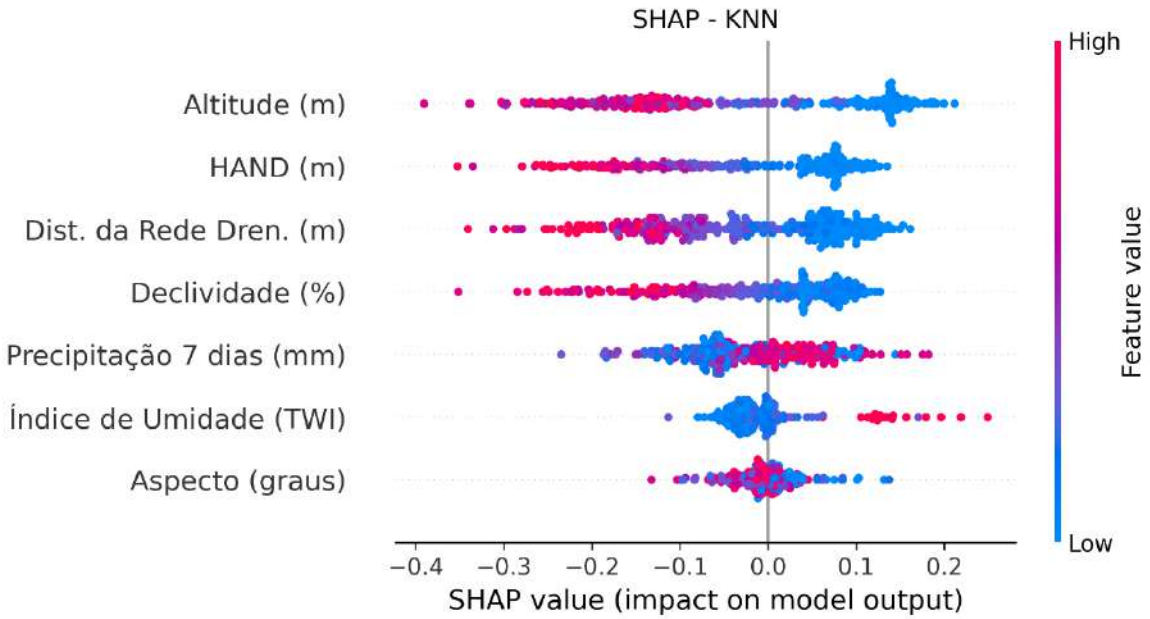
Fonte: O autor (2025).

Figura 25: SHAP para o modelo XGBoost.



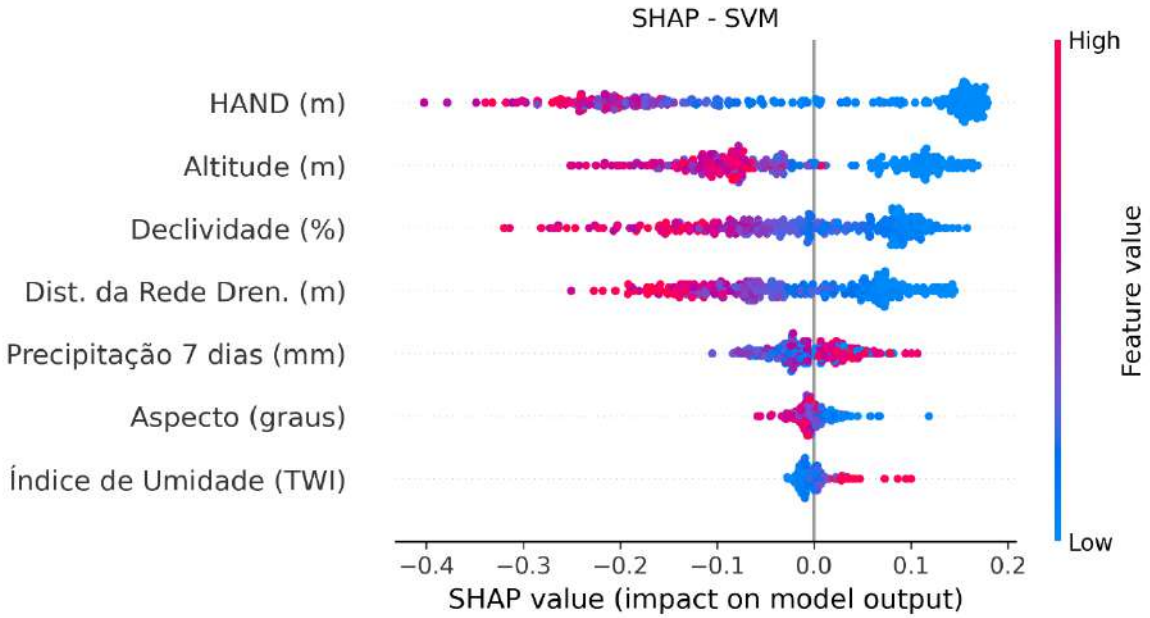
Fonte: O autor (2025).

Figura 26: SHAP para o modelo KNN.



Fonte: O autor (2025).

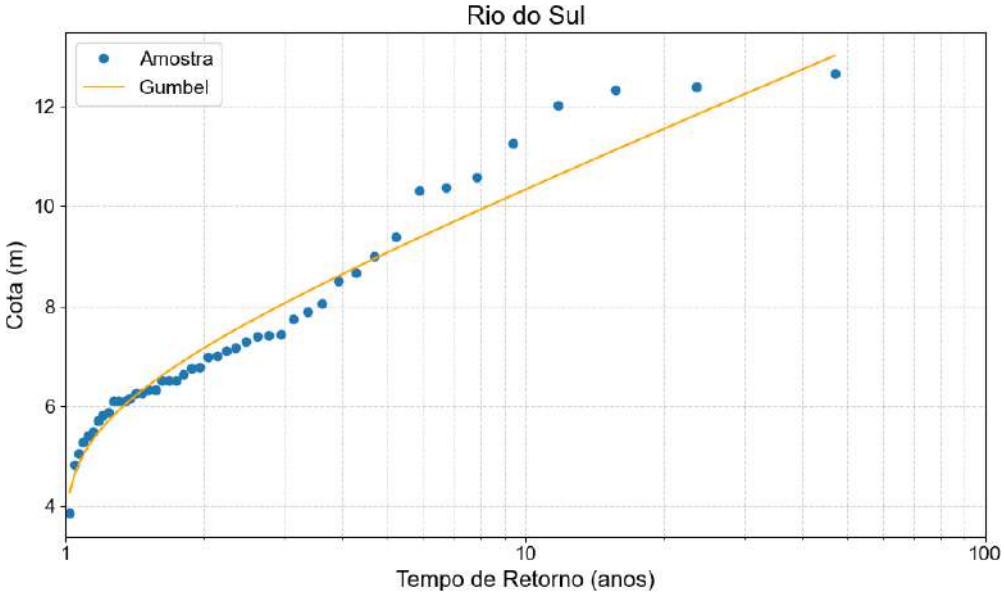
Figura 27: SHAP para o modelo SVM.



Fonte: O autor (2025).

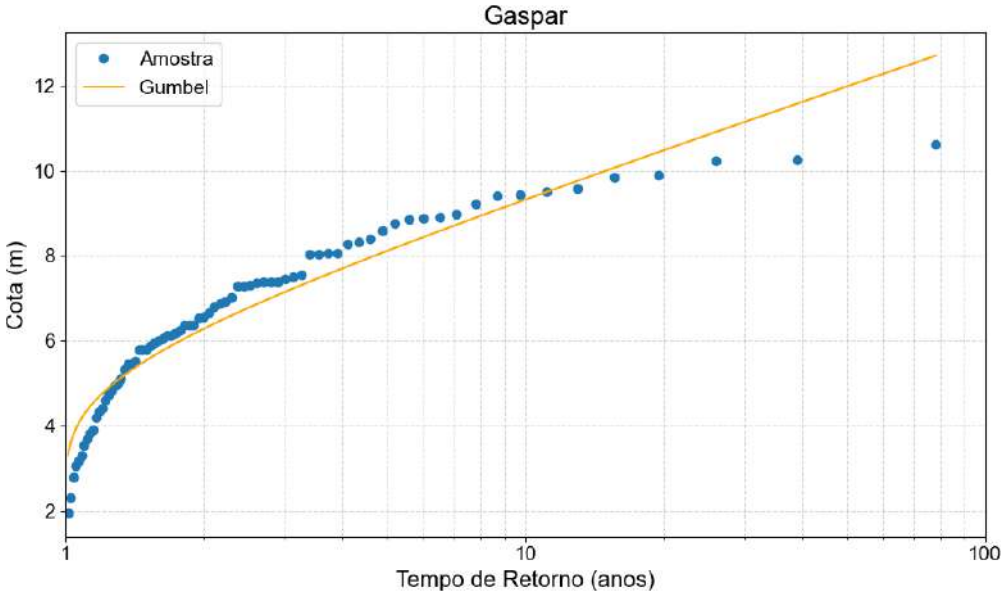
APÊNDICE C – GRÁFICOS DA ANÁLISE DE FREQUÊNCIA COM AJUSTE DA DISTRIBUIÇÃO DE GUMBEL.

Figura 28: Ajuste da amostra para a distribuição de Gumbel – Rio do Sul.



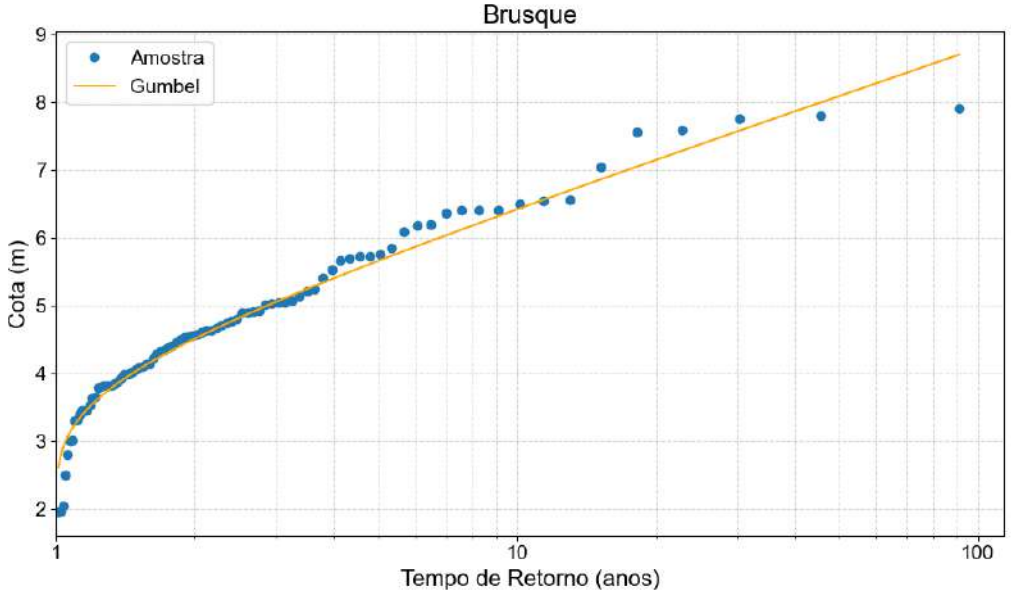
Fonte: O autor (2025).

Figura 29: Ajuste da amostra para a distribuição de Gumbel – Gaspar.



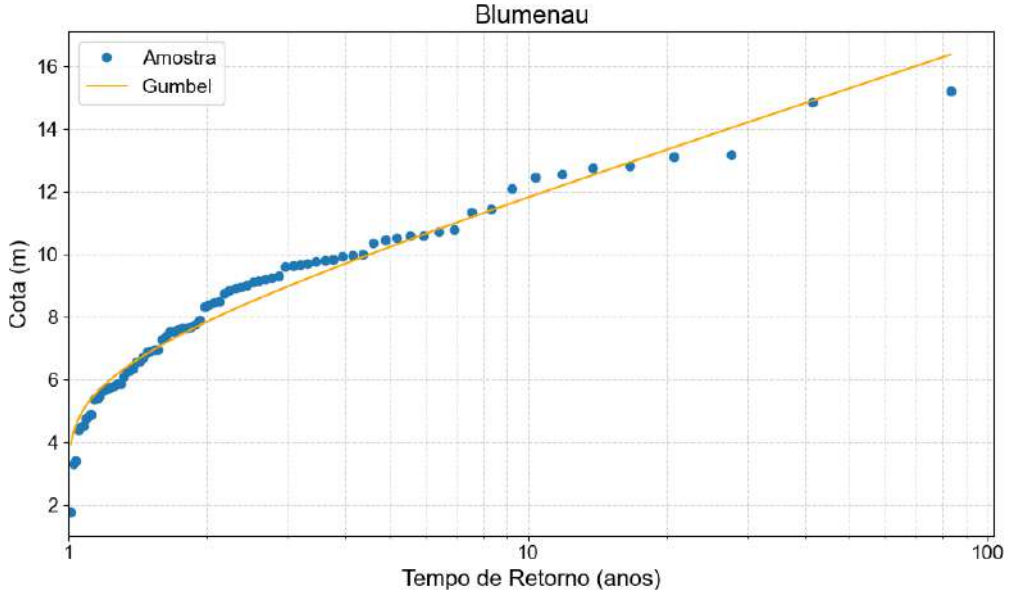
Fonte: O autor (2025).

Figura 30: Ajuste da amostra para a distribuição de Gumbel – Brusque.



Fonte: O autor (2025).

Figura 31: Ajuste da amostra para a distribuição de Gumbel – Blumenau.



Fonte: O autor (2025).